

Clasificación multiclase de lesiones cutáneas en DermaMNIST: comparación entre CNN propia, transferencia generalista, transferencia radiológica y preentrenamiento dermatológico

Patricia Rodrigo Barrio Víctor Rodríguez Albendea

Deep Learning en Python para el Modelado Predictivo

Resumen

Se compara un conjunto de modelos de clasificación multiclase sobre DermaMNIST, subconjunto de MedMNIST derivado de HAM10000, formado por imágenes dermatoscópicas de siete clases. El estudio incluye una CNN propia entrenada desde cero, ResNet50 con pesos ImageNet en *shallow tuning* y *deep tuning* parcial, ResNet50 con pesos RadImageNet/RAC en las mismas dos configuraciones, y una EfficientNet-B1 preentrenada en el entorno ISIC como referencia de preentrenamiento dermatológico. Todos los modelos se entrenaron con resolución 224×224 , aumento de datos moderado, pesos de clase, selección por val_macro_f1 y evaluación final en test mediante bootstrap estratificado ($B = 1000$, $n = 2005$). El mejor modelo comparable fue ResNet50 ImageNet con *deep tuning*, con Macro F1 de 0.736 ± 0.019 y Balanced Accuracy de 0.706 ± 0.022 . EfficientNet-B1 ISIC obtuvo la mayor Accuracy (0.872 ± 0.006) y Kappa (0.753 ± 0.012), aunque se interpreta como referencia de dominio cercano por la proximidad entre ISIC/HAM10000 y DermaMNIST. El análisis confirma que la Accuracy aislada es insuficiente en datasets desbalanceados y que las métricas macro y Grad-CAM aportan una interpretación más robusta.

Palabras clave: CNN, DermaMNIST, transferencia de conocimiento, ResNet50, RadImageNet, EfficientNet, Grad-CAM.

1. Introducción

Las redes neuronales convolucionales (CNN) son uno de los enfoques más utilizados para clasificación de imágenes porque preservan la estructura espacial de los datos. A diferencia de un perceptrón multicapa, que trataría los píxeles como variables independientes, una CNN explota conectividad local, compartición de parámetros y reducción progresiva de dimensión mediante *pooling*. Así, las primeras capas aprenden bordes, texturas y contrastes locales, mientras que las capas profundas combinan dichos patrones en representaciones más abstractas.

En dermatología, la forma, el color, la textura, los bordes y la asimetría de la lesión pueden aportar información relevante para la clasificación. Sin embargo, el aprendizaje se dificulta cuando el conjunto de datos está desbalanceado, existen clases con pocas muestras o aparecen categorías visualmente próximas, como melanoma y *melanocytic nevi*. Por ello, el entrenamiento debe tratarse con cautela, incorporando *data augmentation*, pesos de clase y métricas macro para mejorar la generalización y evaluar el rendimiento de forma más equilibrada entre clases.

Para abordar este problema, se compara una CNN propia entrenada desde cero con diferentes estrategias de transferencia de conocimiento. En concreto, se evalúa ResNet50 con pesos ImageNet como preentrenamiento generalista [1], ResNet50 con pesos RadImageNet/RAC como inicialización médica no dermatológica [2], y EfficientNet-B1 preentrenada en el entorno ISIC como referencia dermatológica de dominio cercano [3, 4, 5]. En ResNet50 se analizan además dos niveles de adaptación: *shallow tuning*, entrenando únicamente la cabeza clasificadora adaptada a la clasificación multiclase de DermaMNIST, y *deep tuning* parcial, desbloqueando la última etapa residual del backbone.

El objetivo del trabajo no es únicamente seleccionar el modelo con mejor rendimiento predictivo, sino analizar cómo influyen el dominio de preentrenamiento y el grado de ajuste sobre un problema dermatológico desbalanceado. Por ello, la evaluación combina métricas globales, métricas macro por clase, matrices de confusión y Grad-CAM como herramienta cualitativa para comprobar si las regiones activadas por el modelo coinciden visualmente con la zona de la lesión.

2. Materiales y métodos

2.1. Código y reproducibilidad

El código empleado para la carga de datos, preprocesado, entrenamiento, evaluación, generación de figuras y análisis Grad-CAM se encuentra disponible en un repositorio conjunto de GitHub: DermaMNIST-skin-lesion-classification.

2.2. Dataset y preprocesado

Se utilizó **DermaMNIST**, incluido en MedMNIST v2 [6] y derivado de HAM10000 [7]. El conjunto contiene 10.015 imágenes dermatoscópicas RGB de siete clases: *actinic keratoses and intraepithelial carcinoma*, *basal cell carcinoma*, *benign keratosis-like lesions*, *dermatofibroma*, *melanoma*, *melanocytic nevi* y *vascular lesions*. Se respetaron los *splits* oficiales: 7.007 imágenes de entrenamiento, 1.003 de validación y 2.005 de test.

Todas las imágenes se procesaron a 224×224 en RGB, con normalización compatible con cada arquitectura. Durante el entrenamiento se aplicaron técnicas de *data augmentation* moderadas: volteo horizontal, rotaciones pequeñas, zoom, traslaciones y ajuste suave de contraste. Como se observa en la Figura 1, el conjunto de entrenamiento presenta un desbalanceo acusado, con predominio de *melanocytic nevi*. Por ello, se emplearon pesos de clase calculados a partir de las frecuencias del conjunto de entrenamiento y suavizados para evitar pesos extremos. Además, los checkpoints se seleccionaron mediante val_macro_f1 , priorizando un rendimiento más equilibrado entre clases.




Figura 1: Distribución de clases en entrenamiento. El predominio de *melanocytic nevi* justifica el uso de métricas macro y pesos de clase.


2.3. Modelos comparados

Se evaluaron seis configuraciones, resumidas en la Tabla 1. M1 corresponde a una CNN propia entrenada desde cero. M2–M3 usan ResNet50 ImageNet para comparar *shallow tuning* frente a *deep tuning* parcial. M4–M5 repiten el mismo protocolo con pesos médicos/radiológicos RadImageNet/RAC. M6 incorpora EfficientNet-B1 ISIC 2019 como *baseline* dermatológico: se sustituyó y entrenó únicamente la capa clasificadora final del *top model*, manteniendo congelado el resto del *backbone*, debido a la proximidad entre ISIC/HAM10000 y DermaMNIST.

Tabla 1: Configuraciones evaluadas. S: *shallow tuning*; D: *deep tuning* parcial; Entr.: parámetros entrenables.

ID	Backbone	Inicialización	Ajuste	Entr.
M1	CNN propia	Aleatoria	Completo	157k
M2	ResNet50	ImageNet	S: cabeza	526k
M3	ResNet50	ImageNet	D: cabeza+bloque final	15.48M
M4	ResNet50	RadImageNet/RAC	S: cabeza	526k
M5	ResNet50	RadImageNet/RAC	D: cabeza+bloque final	15.47M
M6	EfficientNet-B1	ISIC	Cabeza	9k

La Tabla 1 recoge de forma compacta la arquitectura, la inicialización y el número de parámetros entrenables de cada configuración. Para evitar que las diferencias se deban al preprocesado, todos los modelos comparten la misma entrada, aumento de datos y salida Softmax de siete clases.



S = *shallow tuning*; D = *deep tuning* parcial.

Figura 2: Esquema compacto de las arquitecturas comparadas. Todos los modelos comparten entrada, aumento de datos y salida Softmax de 7 clases. M1 aprende desde cero; M2–M3 evalúan transferencia ImageNet; M4–M5 transferencia médica/radiológica; y M6 representa un modelo con preentrenamiento dermatológico basado en ISIC.

La Fig. 2 resume el diseño experimental. La entrada y el aumento de datos se mantienen comunes, mientras que varían la inicialización y el grado de ajuste. Así, la comparación permite separar tres factores: entrenamiento desde cero frente a transferencia, dominio de preentrenamiento y estrategia de adaptación.

3. Entrenamiento y evaluación

Para favorecer una comparación lo más justa posible entre modelos, se mantuvo un protocolo de entrenamiento común, variando principalmente la inicialización y el grado de ajuste. Se entrenó un máximo de 30 épocas, usando *EarlyStopping* para detener el entrenamiento cuando la validación dejaba de mejorar, *ReduceLROnPlateau* para reducir la tasa de aprendizaje en mesetas, *ModelCheckpoint* para guardar el mejor modelo y *CSVLogger* para registrar la evolución de las métricas. En los modelos con *deep tuning* se empleó una tasa de aprendizaje menor, ya que se actualizan pesos previamente aprendidos y se busca una adaptación progresiva al dominio dermatológico.

En coherencia con el desbalanceo observado en el conjunto de entrenamiento, la selección del mejor checkpoint se realizó mediante *val_macro_f1*. Esta decisión es importante porque una *Accuracy* elevada puede obtenerse favoreciendo la clase mayoritaria, mientras que *Macro F1* exige un comportamiento más equilibrado entre clases. Por ello, la evaluación final se centró en *Balanced Accuracy*, *Macro F1* y Kappa de Cohen, manteniendo la *Accuracy* solo como medida global complementaria.

$$\text{Bal. Acc.} = \frac{1}{C} \sum_{c=1}^C \frac{TP_c}{TP_c + FN_c},$$

$$\text{Macro F1} = \frac{1}{C} \sum_{c=1}^C \frac{2P_c R_c}{P_c + R_c}, \quad (1)$$

$$\kappa = \frac{p_o - p_e}{1 - p_e}.$$

Balanced Accuracy mide el recall medio por clase; Macro F1 promedia el equilibrio precisión–recall sin ponderar por frecuencia; y Kappa corrige el acuerdo observado por el acuerdo esperado por azar [8]. Así, las tres métricas permiten detectar si un modelo clasifica bien de forma global o si concentra su rendimiento en las clases dominantes.

La evaluación se realizó una única vez sobre el conjunto de test, cargando el checkpoint seleccionado en validación. Para estimar la incertidumbre de las métricas, se aplicó bootstrap estratificado sobre las 2.005 muestras de test ($B = 1000$), reportando media $\pm$ desviación típica. Este procedimiento no mide la variabilidad entre entrenamientos, pero sí la estabilidad de las métricas frente a la composición concreta del conjunto de test.




Figura 3: Curvas de entrenamiento de M3, ResNet50 ImageNet con *deep tuning*. Se muestra la evolución en entrenamiento y validación para comprobar la convergencia del modelo seleccionado por *val_macro_f1*.

4. Resultados

La Tabla 2 recoge los valores numéricos obtenidos en test, mientras que las Fig. 4 y Fig. 5 resumen visualmente la comparación entre modelos. La Fig. 4 muestra las cuatro métricas principales, y la Fig. 5 relaciona Macro F1 con tiempo de entrenamiento y número de parámetros entrenables. El mejor modelo comparable fue M3, ResNet50 ImageNet con *deep tuning* parcial, que alcanzó el mayor Macro F1 (0.736 ± 0.019) y la mayor Balanced Accuracy (0.706 ± 0.022). Frente a su versión *shallow* (M2), el Macro F1 aumentó de 0.645 ± 0.020 a 0.736 ± 0.019 , lo que indica que desbloquear el último bloque residual permitió adaptar mejor las representaciones profundas al dominio dermatológico.

Tabla 2: Resultados en test mediante bootstrap estratificado ($B = 1000$, $n = 2005$). Se resalta el mejor valor por métrica.

Modelo	Acc.	Bal. Acc.	Kappa	Macro F1
M1 CNN propia	0.711 ± 0.008	0.450 ± 0.018	0.435 ± 0.016	0.419 ± 0.016
M2 ImageNet-S	0.812 ± 0.008	0.649 ± 0.023	0.642 ± 0.015	0.645 ± 0.020
M3 ImageNet-D	0.850 ± 0.008	0.706 ± 0.022	0.706 ± 0.015	0.736 ± 0.019
M4 RadImageNet-S	0.723 ± 0.008	0.416 ± 0.018	0.450 ± 0.016	0.417 ± 0.017
M5 RadImageNet-D	0.728 ± 0.008	0.468 ± 0.018	0.482 ± 0.015	0.445 ± 0.016
M6 ISIC-F	0.872 ± 0.006	0.631 ± 0.011	0.753 ± 0.012	0.619 ± 0.015




Figura 4: Comparación final de modelos en test mediante bootstrap estratificado. Se muestran Accuracy, Balanced Accuracy, Kappa de Cohen y Macro F1 como media $\pm$ desviación típica. M3 obtiene el mejor equilibrio en Balanced Accuracy y Macro F1, mientras que M6 alcanza los mayores valores de Accuracy y Kappa por su preentrenamiento dermatológico de dominio cercano.




Figura 5: Relación entre Macro F1 en test y tiempo de entrenamiento para los seis modelos evaluados. El color indica la fuente de inicialización y el tamaño del círculo representa el número de parámetros entrenables. La figura complementa la comparación de métricas mostrando el compromiso entre rendimiento, coste temporal y capacidad de ajuste.

El análisis por familias muestra diferencias claras. En primer lugar, M1 confirma las limitaciones de entrenar una CNN desde cero en un conjunto desbalanceado: aunque alcanza una Accuracy moderada, su Macro F1 es bajo, lo que confirma su utilidad como línea base pero también sus limitaciones frente a las alternativas con transferencia. En segundo lugar, la comparación M2–M3 muestra el efecto positivo del *deep tuning*: manteniendo la misma arquitectura e inicialización ImageNet, adaptar el bloque final incrementa el Macro F1 en aproximadamente 0.09 puntos, a costa de entrenar muchos más parámetros.

En tercer lugar, M4–M5 evidencian que una inicialización médica no garantiza una transferencia positiva. Aunque RadImageNet/RAC procede de un contexto biomédico, su dominio radiológico es visualmente distinto de la dermatoscopia RGB y queda por debajo de ImageNet tanto en *shallow* como en *deep tuning*. Finalmente, M6 obtiene la mayor Accuracy y Kappa, y además requiere pocos parámetros entrenables; sin embargo, no alcanza la mejor Balanced Accuracy ni Macro F1, por lo que se interpreta como una referencia dermatológica favorable, no como el modelo principal de comparación.

5. Análisis por clase y Grad-CAM

Además de las métricas agregadas, se analizó el comportamiento por clase del modelo M3, seleccionado como mejor modelo comparable. La matriz de confusión normalizada permite identificar no solo cuántas muestras se clasifican correctamente, sino también hacia qué clases se desplazan los errores. M3 muestra un comportamiento globalmente más equilibrado que la CNN propia, con alta sensibilidad en *melanocytic nevi* (recall 0.944) y *vascular lesions* (0.828), y resultados intermedios en *basal cell carcinoma*, *benign keratosis-like lesions* y *dermatofibroma*. Las clases más difíciles fueron *actinic keratoses and intraepithelial carcinoma* (0.515) y *melanoma* (0.601), coherente con la similitud visual entre algunas lesiones pigmentadas.




Figura 6: Matriz de confusión normalizada de M3, ResNet50 ImageNet con *deep tuning*. El modelo concentra la mayor parte de las predicciones en la diagonal, aunque persisten errores entre clases dermatológicas visualmente próximas.

La matriz de confusión matiza la interpretación de las métricas agregadas. M3 presenta una diagonal más consistente que los modelos menos adaptados, pero mantiene errores en clases clínico-visualmente cercanas. En particular, melanoma y lesiones actínicas siguen siendo categorías complejas, probablemente por su similitud con lesiones pigmentadas o queratósicas y por su menor representación relativa en el conjunto de datos.

Grad-CAM se empleó como herramienta cualitativa de interpretabilidad, no como método de segmentación [9]. En M3, los mapas de activación se calcularon a partir de la salida final espacial del *backbone* ResNet50, correspondiente a la última etapa residual conv5_x. El objetivo fue comprobar qué regiones de la imagen contribuían más a la predicción final, analizando si la activación se concentraba sobre estructuras lesionales visualmente plausibles o, por el contrario, sobre fondo, bordes de la imagen o artefactos de adquisición.




Figura 7: Ejemplos representativos de Grad-CAM para M3. En los casos correctamente clasificados, la activación permite comprobar si el modelo se apoya principalmente en la región lesional. En los errores, una activación igualmente localizada sugiere que el fallo puede deberse más a la dificultad de discriminación entre clases próximas que a un problema de localización espacial.

Para complementar esta lectura general, se analizó también un caso específico de *dermatofibroma*, una de las clases más minoritarias del conjunto de entrenamiento. Este tipo de ejemplo resulta útil porque permite valorar si el modelo mantiene una atención visual razonable incluso en categorías con menor representación.




Figura 8: Grad-CAM de M3 en un caso de *dermatofibroma*. Aunque se trata de una clase minoritaria y la confianza de la predicción es moderada, la activación se concentra principalmente sobre la región lesional. Esto sugiere que la dificultad del modelo se relaciona más con la discriminación fina entre patrones dermatológicos que con un fallo claro de localización.

En conjunto, el análisis por clase y Grad-CAM ofrece una visión más completa del comportamiento del modelo. La matriz de confusión identifica las clases problemáticas y las direcciones de error, mientras que los mapas Grad-CAM permiten valorar si la decisión se apoya en regiones visualmente plausibles. La combinación de ejemplos generales y de un caso minoritario refuerza la interpretación de M3: el modelo no solo mejora las métricas macro, sino que además tiende a focalizar regiones coherentes de la lesión, incluso cuando la clasificación exige una discriminación más fina entre clases.

6. Discusión

Los resultados muestran que la estrategia de transferencia no depende únicamente de emplear un modelo preentrenado, sino también del dominio de origen y del grado de ajuste aplicado.

La CNN propia (M1) proporciona una línea base útil: aprende patrones discriminativos y alcanza una Accuracy moderada, pero su bajo Macro F1 evidencia que el rendimiento no se distribuye de forma homogénea entre clases. Esto es coherente con el desbalanceo de DermaMNIST y justifica el uso de métricas macro como criterio principal de comparación.

La comparación entre M2 y M3 constituye el resultado más relevante del estudio. Ambos modelos comparten arquitectura e inicialización ImageNet, pero M3 desbloquea el último bloque residual y permite adaptar representaciones profundas al dominio dermatoscópico. Esta diferencia se traduce en una mejora clara de Macro F1 y Balanced Accuracy, lo que sugiere que el *shallow tuning* resulta insuficiente para capturar patrones dermatológicos específicos, mientras que un *deep tuning* parcial ofrece un mejor equilibrio entre reutilización de conocimiento previo y adaptación al nuevo problema.

En cambio, los modelos M4–M5 muestran que una inicialización médica no garantiza una transferencia positiva. Aunque RadImageNet/RAC procede de un contexto biomédico, el dominio radiológico difiere sustancialmente de la dermatoscopia RGB en textura, color, contraste y estructuras visuales. Por ello, en este experimento queda por debajo de ImageNet tanto en *shallow* como en *deep tuning*. Este resultado es relevante porque indica que la proximidad visual entre dominios puede ser más importante que el hecho de que ambos pertenezcan al ámbito médico.

El modelo M6, basado en EfficientNet-B1 con preentrenamiento dermatológico, debe interpretarse de forma separada. Su Accuracy y Kappa son los mayores del estudio, lo que confirma la ventaja de partir de representaciones aprendidas en un dominio muy próximo. Sin embargo, no alcanza el mejor Macro F1 ni la mejor Balanced Accuracy, por lo que no ofrece el comportamiento más equilibrado por clase. Además, al estar preentrenado en un entorno dermatológico relacionado con ISIC, su resultado sirve como referencia favorable de dominio, pero no debe leerse como una prueba de generalización externa independiente.

En resumen, la comparación muestra que la eficacia de la transferencia de conocimiento no depende solo del tamaño del modelo ni de que el preentrenamiento proceda del ámbito médico. También resulta determinante la proximidad visual entre el dominio de origen y el dominio objetivo, el grado de adaptación del *backbone* y el comportamiento del modelo en las clases minoritarias. Por tanto, los resultados deben interpretarse de forma conjunta, combinando métricas globales, métricas macro y análisis por clase, en lugar de basarse únicamente en la Accuracy.

7. Limitaciones y conclusiones

Este trabajo presenta algunas limitaciones. En primer lugar, los experimentos se realizaron con una única semilla, por lo que el bootstrap sobre test estima la incertidumbre asociada a las muestras evaluadas, pero no la variabilidad entre entrenamientos independientes. En segundo lugar, DermaMNIST deriva de HAM10000 y el modelo con preentrenamiento ISIC puede compartir características de adquisición, distribución o dominio con el conjunto objetivo. Por ello, sus resultados deben interpretarse como una referencia favorable de preentrenamiento dermatológico, no como evidencia de generalización clínica externa.

Como trabajo futuro, sería recomendable repetir los experimentos con varias semillas, validar los modelos sobre un conjunto dermatológico independiente y explorar estrategias específicas para clases minoritarias, como reequilibrado adicional, ajuste de umbrales o técnicas de aumento de datos dirigidas por clase.

En conclusión, la estrategia más sólida entre los modelos comparables fue ResNet50 ImageNet con *deep tuning* parcial, alcanzando el mejor Macro F1 (0.736 ± 0.019) y Balanced Accuracy (0.706 ± 0.022). La CNN propia permitió establecer una línea base desde cero, pero mostró mayor sensibilidad al desbalanceo. RadImageNet/RAC no aportó transferencia positiva al dominio dermatoscópico, lo que sugiere que la proximidad visual entre dominios puede ser más relevante que el carácter médico del preentrenamiento. EfficientNet-B1 ISIC obtuvo la mayor Accuracy y Kappa, pero su interpretación debe separarse por tratarse de un preentrenamiento dermatológico cercano.

En conjunto, el estudio muestra que la comparación de modelos en DermaMNIST no debe basarse únicamente en métricas globales, sino en una lectura conjunta de métricas macro, análisis por clase e interpretabilidad visual. Bajo este criterio, M3 ofrece la alternativa más equilibrada entre capacidad predictiva, robustez frente al desbalanceo y claridad interpretativa.

Referencias

- [1] Olga Russakovsky, Jia Deng, Hao Su, Jonathan Krause, Sanjeev Satheesh, Sean Ma, Zhiheng Huang, Andrej Karpathy, Aditya Khosla, Michael Bernstein, Alexander C. Berg, and Li Fei-Fei. Imagenet large scale visual recognition challenge. *International Journal of Computer Vision*, 115(3):211–252, 2015.
- [2] Xueyan Mei, Ze Liu, Philip M. Robson, Bruno Marinelli, Mingqian Huang, Anuj Doshi, Adam Jacobi, Chendi Cao, Kevin E. Link, Tianrun Yang, Yi Wang, Hayit Greenspan, Timothy Deyer, Zahi A. Fayad, and Yindalon Yang. Radimagenet: An open radiologic deep learning research dataset for effective transfer learning. *Radiology: Artificial Intelligence*, 2022.
- [3] Mingxing Tan and Quoc V. Le. Efficientnet: Rethinking model scaling for convolutional neural networks. In *Proceedings of the 36th International Conference on Machine Learning*, pages 6105–6114, 2019.
- [4] Noel C. F. Codella, Veronica Rotemberg, Philipp Tschandl, M. Emre Celebi, Stephen Dusza, David Gutman, Brian Helba, Aadi Kallou, Konstantinos Liopyris, Michael Marchetti, Harald Kittler, and Allan Halpern. Skin lesion analysis toward melanoma detection 2018: A challenge hosted by the international skin imaging collaboration. *arXiv preprint arXiv:1902.03368*, 2019.
- [5] Marc Combalia, Noel C. F. Codella, Veronica Rotemberg, Brian Helba, Veronica Vilaplana, Ofer Reiter, Cristina Carrera, Alicia Barreiro, Allan C. Halpern, Susana Puig, and Josep Malvehy. Bcn20000: Dermoscopic lesions in the wild. *arXiv preprint arXiv:1908.02288*, 2019.
- [6] Jiancheng Yang, Rui Shi, Donglai Wei, Zequan Liu, Lin Zhao, Bilian Ke, Hanspeter Pfister, and Bingbing Ni. Medmnist v2: A large-scale lightweight benchmark for 2d and 3d biomedical image classification. *Scientific Data*, 10(1):41, 2023.
- [7] Philipp Tschandl, Cliff Rosendahl, and Harald Kittler. The ham10000 dataset, a large collection of multi-source dermatoscopic images of common pigmented skin lesions. *Scientific Data*, 5:180161, 2018.
- [8] Jacob Cohen. A coefficient of agreement for nominal scales. *Educational and Psychological Measurement*, 20(1):37–46, 1960.
- [9] Ramprasaath R. Selvaraju, Michael Cogswell, Abhishek Das, Ramakrishna Vedantam, Devi Parikh, and Dhruv Batra. Grad-cam: Visual explanations from deep networks via gradient-based localization. In *Proceedings of the IEEE International Conference on Computer Vision*, pages 618–626, 2017.