



UNIVERSITAT
POLITÈCNICA
DE VALÈNCIA

**MÁSTER UNIVERSITARIO EN INGENIERÍA
DE ANÁLISIS DE DATOS, MEJORA DE
PROCESOS Y TOMA DE DECISIONES**

**Análisis multivariante del
bienestar psicológico en
población joven**

Análisis, Monitorización y Diagnóstico de Procesos Multivariantes

Patricia Rodrigo Barrio

Víctor Rodríguez Albendea

2025/2026

Contenido del trabajo

Resumen	3
1. Introducción	4
1.1. Motivación del trabajo	4
1.2. Justificación metodológica.....	4
1.3. Objetivos del trabajo	5
1.4. Estructura del documento	5
2. Material y métodos.....	6
2.1. Base de datos y selección muestral	6
2.2. Variables analizadas y definición de bloques	6
2.3. Pretratamiento de los datos	6
2.4. Metodología de análisis y software empleado.....	6
3. Resultados.....	7
3.1. Estructura latente de los hábitos de vida y validación del modelo PCA.....	7
3.2. Modelización de la ansiedad a partir de los hábitos de vida	13
3.2.1. Regresión lineal múltiple (MLR) para Anxiety_Score	13
3.2.2. Modelización de la ansiedad a partir de los hábitos de vida mediante PLS	13
3.2.3. Regresión en componentes principales (PCR) para Anxiety_Score	18
3.2.4. Comparación final de modelos para la explicación de Anxiety_Score	19
3.3. PCA sobre variables psicológicas	20
3.4. PLS-DA sobre variables psicológicas y discriminación del riesgo de burnout.....	22
3.4.1. Ajuste del modelo PLS-DA completo y selección del número de componentes	23
3.4.2. Interpretación del modelo reducido	25
3.4.3. Modelo reducido e interpretación final	28
3.4.4. Evaluación de la capacidad clasificatoria del modelo.....	29
3.4.5. Proyección de nuevas observaciones y explotación del modelo.....	31
3.5. Comparativa con Random Forest clasificatorio.....	34
4. Conclusiones	35
5. Bibliografía	37
6. Anexos	38

Resumen

Este trabajo analiza el conjunto de datos Gen Z Mental Wellness desde una perspectiva multivariante orientada tanto a la comprensión estructural de los datos como a la predicción y clasificación de variables psicológicas relevantes. A partir de una muestra de 2064 observaciones, se definieron dos bloques de estudio. En el primero, centrado en hábitos de vida y uso de tecnología, se combinó PCA con MLR, PCR, PLS y una comparación exploratoria mediante K-means para estudiar la relación con Anxiety_Score. En el segundo, dedicado al bienestar psicológico y al riesgo de burnout, se aplicaron PCA y PLS-DA, complementando el análisis con un clasificador Random Forest como referencia predictiva no lineal.

Los resultados muestran que, en el bloque de hábitos, la principal fuente de variabilidad está dominada por la exposición digital general, mientras que componentes posteriores recogen estructuras asociadas al sueño, al night scrolling y al juego online. En la explicación de Anxiety_Score, MLR, PCR y PLS alcanzaron rendimientos similares, con capacidad predictiva moderada, pero el PLS proporcionó la lectura más rica del problema al concentrar la señal útil en una estructura latente interpretable, dominada por menos horas de sueño, mayor scrolling nocturno y mayor exposición digital.

En el bloque psicológico, el PCA reveló un eje dominante de bienestar frente a malestar psicológico. Sobre esa base, el PLS-DA mostró que la discriminación del riesgo de burnout se sustenta principalmente en ansiedad, fatiga emocional, motivación, sueño, estabilidad emocional y bienestar global, pudiendo resumirse en una única componente latente. Aunque el modelo clasificó adecuadamente los perfiles de riesgo alto y medio, presentó mayores dificultades en la clase Low, en parte por su menor representación y por el solapamiento entre clases. El Random Forest superó claramente al PLS-DA en términos estrictamente predictivos, pero el enfoque basado en variables latentes resultó más valioso para interpretar la estructura del problema. En conjunto, el estudio confirma la utilidad del análisis multivariante para integrar exploración, predicción e interpretación en un contexto de bienestar psicológico juvenil.

1. Introducción

1.1. Motivación del trabajo

La salud mental y el bienestar psicológico de la población joven se han convertido en un tema de creciente interés social, sanitario y académico. La adolescencia y la juventud constituyen etapas especialmente sensibles del desarrollo, en las que muchos problemas de salud mental emergen o se consolidan, lo que justifica la necesidad de profundizar en su estudio desde una perspectiva rigurosa y multidimensional (Kieling et al., 2011; Blakemore, 2019).

En particular, la denominada Generación Z desarrolla una parte importante de su actividad diaria en entornos digitales, combinando hábitos de estudio, trabajo, descanso y ocio con un uso intensivo de redes sociales, pantallas y otras tecnologías. Este contexto plantea la necesidad de comprender mejor cómo se relacionan estos hábitos de vida con variables psicológicas como la ansiedad, la estabilidad emocional, la fatiga o el bienestar general. En este sentido, la literatura reciente ha puesto de manifiesto que el uso de redes sociales puede asociarse con mayores niveles de ansiedad, depresión y malestar psicológico en adolescentes y jóvenes, lo que refuerza el interés de estudiar conjuntamente este tipo de variables (Keles et al., 2020).

El análisis de estos fenómenos resulta especialmente complejo, ya que no depende de una única variable, sino de un conjunto amplio de factores que interactúan entre sí. Variables como las horas de sueño, el tiempo de uso de redes sociales, la frecuencia de actividad física, la calidad del descanso, la motivación o la comparación social no actúan de forma aislada, sino que presentan relaciones de dependencia y estructuras de correlación que deben ser analizadas de manera conjunta. Por ello, el uso de técnicas de análisis multivariante resulta especialmente adecuado para abordar este problema de forma rigurosa.

En este contexto, el presente trabajo aborda el análisis del conjunto de datos *Gen Z Mental Wellness*, con el propósito de estudiar la relación entre hábitos de vida, bienestar psicológico y riesgo de *burnout* en población joven. El interés del trabajo no radica únicamente en obtener modelos predictivos, sino también en explorar la estructura latente de los datos, identificar perfiles de individuos, interpretar relaciones entre variables y comparar distintos enfoques estadísticos y de aprendizaje a partir de los datos.

1.2. Justificación metodológica

Cuando se trabaja con bases de datos con numerosas variables potencialmente correlacionadas, los métodos clásicos univariantes o los enfoques basados únicamente en relaciones aisladas entre pares de variables pueden resultar insuficientes. En este tipo de situaciones, las técnicas basadas en variables latentes permiten comprimir la información contenida en el conjunto de datos, reducir su dimensionalidad y extraer las principales fuentes de variabilidad y relación entre variables. Este planteamiento constituye uno de los fundamentos del análisis multivariante moderno, especialmente en métodos como el Análisis de Componentes Principales (PCA) y los Mínimos Cuadrados Parciales (PLS), muy adecuados cuando existe colinealidad entre predictores o cuando se pretende interpretar estructuras complejas de forma conjunta (Jolliffe, 2025; Wold et al., 2001).

En este trabajo se plantea un enfoque metodológico coherente con esta filosofía. En primer lugar, se utilizará PCA como herramienta exploratoria para estudiar la estructura interna de los bloques de variables, identificar patrones de correlación, detectar posibles perfiles de individuos y localizar observaciones atípicas. En segundo lugar, para el problema de predicción de la ansiedad, se compararán modelos de Regresión Lineal Múltiple (MLR), Regresión en Componentes Principales (PCR) y PLS, con el fin de valorar las ventajas e inconvenientes de cada enfoque en términos de capacidad predictiva e interpretabilidad.

Finalmente, para el estudio del riesgo de burnout, se aplicará PLS-DA como técnica supervisada de clasificación, comparándola con un modelo de Random Forest como referencia no lineal. En particular, PLS-DA resulta de especial interés cuando el objetivo es clasificar observaciones a partir de múltiples variables correlacionadas sin renunciar a la interpretabilidad del modelo (Brereton & Lloyd, 2014).

Este planteamiento resulta especialmente apropiado porque permite combinar tres niveles de análisis complementarios: la exploración de la estructura de los datos, la predicción de variables cuantitativas y la clasificación de individuos en grupos de riesgo. De este modo, no solo se obtiene información sobre la capacidad predictiva de los modelos, sino también sobre la organización interna de los datos y sobre las variables con mayor capacidad explicativa o discriminante.

1.3. Objetivos del trabajo

El objetivo general del trabajo es analizar, desde una perspectiva multivariante basada en variables latentes, la relación entre los hábitos de vida de jóvenes de la Generación Z, su bienestar psicológico y el riesgo de burnout, combinando técnicas exploratorias, predictivas y de clasificación. A partir de este objetivo general, se plantean dos objetivos específicos.

El primer objetivo consiste en estudiar la relación entre los hábitos de vida y uso de tecnología, e investigar en qué medida estos permiten explicar y predecir el nivel de ansiedad de los individuos. Para ello se considerará como variable respuesta principal el Anxiety_Score, y como variables explicativas un conjunto de indicadores relacionados con sueño, redes sociales, tiempo de pantalla, actividad física, cafeína, estudio/trabajo y hábitos digitales. Sobre este bloque se aplicarán técnicas de PCA, MLR, PCR y PLS, además de una comparación exploratoria mediante K-means.

El segundo objetivo consiste en estudiar la estructura de las variables psicológicas y de bienestar, e investigar su capacidad para discriminar entre individuos con diferente nivel de riesgo de burnout. Para ello se empleará como variable respuesta Burnout_Risk, mientras que el bloque explicativo estará formado por variables como ansiedad, sobrepensamiento, estabilidad emocional, comparación social, calidad del sueño, motivación, fatiga emocional e índice de bienestar. En este caso se utilizarán PCA y PLS-DA, incorporando además una comparación con Random Forest para analizar diferencias entre un enfoque lineal basado en variables latentes y un modelo no lineal basado en árboles

1.4. Estructura del documento

El documento se organiza en varias secciones. Tras esta introducción, se presenta la sección de Material y Métodos, en la que se describe la base de datos utilizada, las variables analizadas, el preprocesado y las técnicas estadísticas empleadas. A continuación, en la sección de Resultados se presentan, en primer lugar, los análisis relativos a la estructura de los hábitos de vida y su relación con la ansiedad, y posteriormente los correspondientes al bloque psicológico y a la discriminación del riesgo de burnout.

Posteriormente, se incluye una sección de Conclusiones, en la que se sintetizan los hallazgos más relevantes del trabajo, se discuten las ventajas y limitaciones de los métodos aplicados y se plantean posibles líneas de trabajo futuro. Finalmente, el documento se completa con la Bibliografía y con los Anexos, en los que se recogerán los ficheros utilizados y aquella información complementaria que se considere relevante para la correcta interpretación y reproducibilidad del estudio.

2. Material y métodos

2.1. Base de datos y selección muestral

El trabajo se realizó sobre el conjunto de datos Gen Z Mental Wellness, orientado al estudio conjunto de hábitos de vida, bienestar psicológico y riesgo de burnout en población joven. Para los análisis desarrollados en este documento se trabajó con la muestra finalmente retenida tras el preprocesado y la selección realizada para el estudio, compuesta por 2064 observaciones, que se mantuvo de forma consistente en los distintos modelos realizados.

2.2. Variables analizadas y definición de bloques

Con el fin de mantener una estructura analítica coherente con los objetivos del trabajo, las variables se organizaron en dos bloques. En el primer bloque, centrado en la relación entre hábitos de vida y ansiedad, se consideró como variable respuesta `Anxiety_Score` y como variables explicativas: `Daily_Social_Media_Hours`, `Screen_Time_Hours`, `Night_Scrolling_Frequency`, `Online_Gaming_Hours`, `Exercise_Frequency_per_Week`, `Daily_Sleep_Hours`, `Caffeine_Intake_Cups` y `Study_Work_Hours_per_Day`.

En el segundo bloque, orientado al estudio del riesgo de burnout, se empleó como respuesta categórica `Burnout_Risk` y como variables explicativas: `Anxiety_Score`, `Overthinking_Score`, `Mood_Stability_Score`, `Social_Comparison_Index`, `Sleep_Quality_Score`, `Motivation_Level`, `Emotional_Fatigue_Score` y `Wellbeing_Index`. Esta organización en bloques permitió separar el problema de predicción de una respuesta cuantitativa del problema de discriminación entre clases, manteniendo en ambos casos una lectura multivariante basada en variables latentes.

2.3. Pretratamiento de los datos

Antes del ajuste de los modelos multivariantes, los bloques explicativos se sometieron a centrado y escalado a varianza unitaria, de modo que las variables quedasen en una escala comparable y ninguna dominase el análisis únicamente por su magnitud. Este pretratamiento se aplicó en los modelos PCA, PCR, PLS y PLS-DA. En el caso de nuevas observaciones proyectadas posteriormente sobre los modelos ajustados, se utilizó exactamente la misma media y desviación estándar del conjunto de calibración. Asimismo, las observaciones señaladas por los estadísticos T^2 de Hotelling y SPE se revisaron de forma específica, pero su superación puntual de los límites de control no condujo automáticamente a su eliminación, ya que estos gráficos se utilizaron como herramientas de diagnóstico y no como criterios mecánicos de depuración.

2.4. Metodología de análisis y software empleado

La estrategia metodológica combinó técnicas exploratorias, predictivas y de clasificación. En primer lugar, se empleó PCA para estudiar la estructura interna de cada bloque, interpretar patrones de correlación, analizar la representación de las variables en el espacio latente y diagnosticar observaciones relevantes. Sobre el bloque de hábitos se aplicó, además, de forma complementaria, una partición K-means sobre el subespacio PCA como comprobación exploratoria adicional. Para la modelización de `Anxiety_Score` se compararon MLR, PCR y PLS, valorando conjuntamente su capacidad predictiva, parsimonia e interpretabilidad. Para el estudio de `Burnout_Risk` se utilizó PLS-DA como técnica supervisada de discriminación, complementada con un modelo de Random Forest como referencia no lineal.

El ajuste principal de los modelos y la inspección de sus salidas gráficas se realizaron en Dragonet, mientras que Python se utilizó para los análisis complementarios que requerían mayor flexibilidad de explotación o validación, como la generación de métricas clasificatorias, matrices de confusión, curvas ROC, gráficos auxiliares y algunas comprobaciones adicionales sobre el espacio latente.

3. Resultados

3.1. Estructura latente de los hábitos de vida y validación del modelo PCA

Con el fin de estudiar la estructura conjunta del bloque de hábitos de vida definido previamente en Materiales y métodos, se ajustó un modelo PCA sobre las ocho variables seleccionadas, previo centrado y escalado a varianza unitaria. El análisis se planteó como una herramienta exploratoria para identificar las principales fuentes de variabilidad del bloque, estudiar las relaciones entre variables y observaciones y apoyar después la interpretación en el espacio original.

Antes de interpretar el modelo, se realizó su validación mediante validación cruzada, que retuvo cuatro componentes principales. El modelo final alcanzó $R_X^2 = 0.6146$ y $Q_X^2 = 0.5868$. Como muestra la Figura 1, ambas magnitudes aumentaron progresivamente al incorporar nuevas componentes, pasando de valores próximos a 0.23 con una única componente a 0.6146 y 0.5868 con cuatro, respectivamente. Por tanto, la validación cruzada indicó que la estructura del bloque no quedaba suficientemente recogida en una sola dimensión latente y justificó la retención de cuatro componentes. A partir de ahí, la cuestión pasó a ser interpretativa: determinar si el plano PC1–PC2 recogía ya la parte esencial de la información o si algunas variables requerían considerar también componentes posteriores.




Figura 1. Validación cruzada del modelo: evolución acumulada de R_X^2 y Q_X^2 en función del número de componentes.

Esta cuestión se abordó mediante el gráfico de *goodness of model* en el espacio X, que permite estudiar cómo queda representada cada variable original en las distintas componentes del modelo. Como se observa en la Figura 2, no todas las variables quedaban explicadas de la misma manera por las primeras componentes. En particular, Daily_Social_Media_Hours y Screen_Time_Hours aparecían casi completamente explicadas por la primera variable latente, mientras que Daily_Sleep_Hours, Night_Scrolling_Frequency, Online_Gaming_Hours, Caffeine_Intake_Cups y Study_Work_Hours_per_Day requerían también componentes posteriores para quedar bien descritas. Por ello, la interpretación del modelo no se limitó al plano PC1–PC2, sino que se extendió también al análisis del plano PC3–PC4.




Figura 2. Goodness of model en el espacio X : contribución relativa de cada componente principal a la representación de las variables originales del bloque de hábitos.

Una vez validado que el modelo retenía estructura más allá de una única dimensión latente, se analizó el plano principal PC1–PC2. El *loading plot* correspondiente (Figura 3) mostró una clara proximidad entre Daily_Social_Media_Hours y Screen_Time_Hours, lo que indica que ambas variables comparten la fuente dominante de variabilidad del bloque. Esta lectura se reforzó al representar el *score plot* PC1–PC2 coloreado por Daily_Social_Media_Hours (Figura 4), donde apareció un gradiente prácticamente horizontal a lo largo de la primera componente.




Figura 3. Loading plot de las componentes principales 1 y 2 para el bloque de hábitos de vida.




Figura 4. Score plot PC1–PC2 coloreado por Daily_Social_Media_Hours.

Por ello, estas dos figuras sugieren que la variabilidad capturada por PC1 está fuertemente asociada a un eje de uso digital general, dominado por el tiempo en redes sociales y el tiempo total de pantalla. En cambio, la separación vertical observada en el *score plot* no parecía venir explicada principalmente por estas dos variables, lo que apuntaba a la existencia de una segunda fuente de variabilidad ligada a otros hábitos de vida.

A partir de esta observación surgió una nueva cuestión: si varias variables no quedaban suficientemente descritas en el plano principal, ¿qué estructura adicional aparecía al inspeccionar PC3–PC4? El *loading plot* de este segundo plano, representado en la Figura 5, mostró una oposición destacada entre Daily_Sleep_Hours y Night_Scrolling_Frequency, así como una contribución relevante de Online_Gaming_Hours en la cuarta componente, en sentido opuesto a variables como Caffeine_Intake_Cups y Exercise_Frequency_per_Week.




Figura 5. Loading plot de las CP 3 y 4, mostrando la estructura secundaria del bloque de hábitos de vida.

Esta interpretación se vio reforzada al colorear el *score plot* PC3–PC4 por *Daily_Sleep_Hours* (Figura 6) y por *Online_Gaming_Hours* (Figura 7), observándose gradientes coherentes con la proyección de ambas variables sobre este plano. Por tanto, las componentes tercera y cuarta no se consideraron residuales, sino portadoras de estructura interpretable del bloque de hábitos. Además, el escaso peso de *Daily_Social_Media_Hours* y *Screen_Time_Hours* en este segundo plano reforzó la idea, ya sugerida por el *goodness of model*, de que ambas variables quedan esencialmente recogidas por la estructura principal del modelo.




Figura 6. Score plot PC3–PC4 coloreado por *Daily_Sleep_Hours*, utilizado para apoyar la interpretación de la tercera componente principal.




Figura 7. Score plot PC3–PC4 coloreado por *Online_Gaming_Hours*, utilizado para apoyar la interpretación de la cuarta componente principal.

Antes de profundizar en la interpretación del modelo, se revisaron los gráficos de T^2 de Hotelling y SPE como herramientas de cribado para identificar observaciones que requerían un análisis adicional. La superación aislada de los límites de control no se interpretó automáticamente como evidencia suficiente de observación extrema o anómala, ya que, al fijarse para un determinado nivel de confianza, es esperable que una pequeña proporción de observaciones quede fuera de ellos. Por ello, ambos gráficos se utilizaron como herramientas de revisión, distinguiendo entre observaciones alejadas del centro del subespacio latente y observaciones con mal ajuste al propio subespacio del modelo.

La observación con mayor SPE fue seleccionada para su diagnóstico detallado a partir del gráfico correspondiente (Figura 8). El siguiente paso consistió en examinar su gráfico de contribución y contrastar la interpretación en el espacio original (Figura 9 y Figura 10), identificando primero las variables responsables de la distancia al modelo y comprobando después, mediante gráficos originales, cómo se materializaba dicha desviación.




Figura 8. Gráfico SPE con la observación seleccionada para diagnóstico marcada en rojo.

Su análisis mostró pocas horas de sueño (Daily_Sleep_Hours), muchas horas de juego online (Online_Gaming_Hours) y un comportamiento también llamativo en el consumo de café (Caffeine_Intake_Cups). Esta combinación no seguía bien el patrón general observado en el resto de la muestra, por lo que la observación presentaba un valor elevado de SPE. Es decir, más que tratarse de una observación extrema dentro del modelo, parecía una observación que encajaba mal con la estructura de relaciones resumida por el PCA. No obstante, como no había indicios claros de error de registro, se decidió mantenerla en el análisis.




Figura 9. Representación en el espacio original Online_Gaming_Hours–Daily_Sleep_Hours para la observación seleccionada en el gráfico SPE.




Figura 10. Representación en el espacio original Caffeine_Intake_Cups–Daily_Sleep_Hours para la observación seleccionada en el gráfico SPE.

Por su parte, la observación con mayor T^2 de Hotelling fue seleccionada para su diagnóstico detallado a partir del gráfico correspondiente (Figura 11). A diferencia del caso anterior, aquí la observación no destacaba por mal ajuste al modelo, sino por su posición periférica dentro del espacio de scores. Para entender qué variables estaban provocando esa posición, se revisó su gráfico de contribución respecto a la media y se confirmó la interpretación con la Figura 12 y Figura 13.




Figura 11. Gráfico T^2 de Hotelling con la observación seleccionada para diagnóstico marcada en rojo.




Figura 12. Representación complementaria en el espacio original de variables: *Caffeine_Intake_Cups*–*Exercise_Frequency_per_Week* para la observación seleccionada en el gráfico T^2 .




Figura 13. Representación complementaria en el espacio original de *Study_Work_Hours_per_Day*–*Exercise_Frequency_per_Week* para la observación seleccionada en el gráfico T^2 .

El diagnóstico mostró que dicha posición estaba asociada principalmente a una frecuencia de ejercicio muy elevada, un número alto de horas de estudio/trabajo y un consumo muy reducido de cafeína. En consecuencia, no se interpretó como una observación que rompiera la estructura del modelo, sino como un perfil extremo pero coherente dentro del subespacio PCA. Por ello, se consideró una observación extrema o periférica en el espacio de scores, pero no una observación anómala ni incoherente con la estructura del modelo.

Finalmente, una vez interpretada la estructura principal del modelo y revisadas las observaciones señaladas por los gráficos de T^2 y SPE, surgió una última cuestión: qué información adicional estaba recogiendo la segunda componente, dado que no parecía estar dominada por las variables asociadas al uso digital general. Con el fin de profundizar en esta cuestión, se seleccionaron dos pequeños grupos de observaciones situados en la parte superior e inferior del score plot PC1–PC2, manteniendo aproximadamente constante la primera componente (Figura 14).

El gráfico de contribución entre ambos grupos, Figura 15, mostró que la separación a lo largo de PC2 estaba dominada positivamente por *Online_Gaming_Hours* y *Caffeine_Intake_Cups*, y negativamente por *Study_Work_Hours_per_Day*, *Exercise_Frequency_per_Week* y *Daily_Sleep_Hours*.




Figura 14. Selección de dos grupos de observaciones con valores altos y bajos de PC2, manteniendo aproximadamente constante PC1.




Figura 15. Contribución de las variables originales a la separación entre los grupos seleccionados en la PC2.

Esta interpretación se confirmó en el espacio original mediante el gráfico Study_Work_Hours_per_Day–Online_Gaming_Hours (Figura 16), donde el grupo situado en la parte alta de PC2 presentaba, en general, una mayor dedicación al juego online y una menor dedicación al estudio/trabajo que el grupo situado en la parte baja. Por ello, la segunda componente pudo interpretarse como una fuente secundaria de variabilidad asociada al contraste entre hábitos de ocio digital intensivo y hábitos más estructurados.




Figura 16. Confirmación en el espacio original de la interpretación de PC2 mediante la relación entre Study_Work_Hours_per_Day y Online_Gaming_Hours para los grupos comparados.

Por consiguiente, el PCA permitió identificar una estructura interpretable en el bloque de hábitos, dominada en el plano principal por el uso digital general y complementada por componentes posteriores asociadas al sueño, al *night scrolling* y al juego online. Este análisis sirvió como base exploratoria para el posterior estudio supervisado de su relación con Anxiety_Score.

De forma complementaria, se exploró también una partición mediante K-means sobre el subespacio de scores generado por el PCA del bloque de hábitos. El interés de esta comprobación no radicaba en sustituir la interpretación del PCA, sino en valorar si la nube de observaciones presentaba agrupamientos naturales que aportasen una lectura adicional de la estructura ya identificada. Como se detalla en el Anexo A, la partición obtenida reprodujo fundamentalmente el gradiente principal capturado por la primera componente, sin revelar una estructura claramente nueva.

3.2. Modelización de la ansiedad a partir de los hábitos de vida

3.2.1. Regresión lineal múltiple (MLR) para Anxiety_Score

Una vez caracterizada la estructura interna del bloque de hábitos mediante PCA, se consideró en primer lugar un modelo de regresión lineal múltiple para estudiar la relación entre las variables de hábitos de vida y Anxiety_Score en el espacio original de los predictores. El modelo completo, ajustado con las ocho variables del bloque de hábitos, mostró una capacidad predictiva moderada, con $R_Y^2 = 0.316$ y $Q_Y^2 = 0.309$. La Tabla 1 resume la comparación entre el modelo completo y la versión finalmente retenida.

Tabla 1. Comparación del rendimiento del modelo de MLR completo y reducido para la predicción de Anxiety_Score.

Modelo	Nº de predictores	R_Y^2	Q_Y^2
MLR completo	8	0.3160	0.3093
MLR reducido final	3	0.3153	0.3126

A partir de estos resultados, se llevó a cabo una reducción progresiva del modelo, eliminando de forma secuencial aquellas variables cuya contribución individual resultaba menos clara. Este proceso condujo finalmente a un modelo reducido formado por Night_Scrolling_Frequency, Daily_Social_Media_Hours y Daily_Sleep_Hours. El detalle completo del proceso de simplificación, así como los modelos intermedios evaluados y sus correspondientes indicadores de ajuste, se incluye en el Anexo B.

Como se observa en la Tabla 1, el rendimiento de esta versión final fue prácticamente equivalente al del modelo completo e incluso mostró una ligera mejora en validación, por lo que se seleccionó como versión final por su mayor parsimonia. La Tabla 2 recoge los coeficientes beta estandarizados del modelo reducido final.

Tabla 2. Coeficientes beta estandarizados del modelo MLR reducido final para Anxiety_Score.

Predictor	Coeficiente beta	p-valor
Night_Scrolling_Frequency	0.1811	0.000
Daily_Social_Media_Hours	0.1206	0.000
Daily_Sleep_Hours	-0.5072	0.000

En el modelo reducido final, Night_Scrolling_Frequency y Daily_Social_Media_Hours mostraron una asociación positiva con Anxiety_Score, mientras que Daily_Sleep_Hours presentó una asociación negativa. Estos resultados sugieren que, dentro del bloque de hábitos considerado, el *night scrolling*, el uso intensivo de redes sociales y la reducción de las horas de sueño son las variables que mantienen una relación lineal más clara con la ansiedad.

3.2.2. Modelización de la ansiedad a partir de los hábitos de vida mediante PLS

Dado que el bloque de hábitos de vida presentaba una estructura correlacionada, se ajustó un modelo PLS para estudiar su relación con Anxiety_Score en un espacio latente orientado específicamente a maximizar la covariación entre predictores y respuesta.

En este contexto, el interés del modelo no residía únicamente en su capacidad predictiva, sino también en identificar qué parte de la variabilidad del bloque de hábitos estaba realmente asociada a la ansiedad.

La validación cruzada retuvo dos componentes latentes, con un rendimiento global de $R_Y^2 = 0.3153$ y $Q_Y^2 = 0.3078$. Como se observa en la Figura 17, la inclusión de la segunda componente apenas incrementó la capacidad predictiva del modelo respecto a la primera, lo que indicaba ya desde el inicio que la relación útil entre hábitos y ansiedad estaba concentrada casi por completo en una única dirección latente dominante.




Figura 17. Evolución acumulada de R_Y^2 y Q_Y^2 en función del número de componentes del modelo PLS.

Esta afirmación se confirmó al examinar el *goodness of model*, ya que Anxiety_Score quedaba ya recogida en gran medida por la primera componente, mientras que la segunda apenas añadía mejora. En el bloque X, Daily_Sleep_Hours aparecía bien representada por LV1, mientras que Daily_Social_Media_Hours y Screen_Time_Hours requerían también la segunda componente para quedar plenamente descritas. Night_Scrolling_Frequency mostraba una contribución intermedia, mientras que el resto de variables apenas aportaban estructura relevante.

Por ello, el PLS no apuntaba a una relación difusa entre ansiedad y todos los hábitos analizados, sino a una estructura sostenida por un subconjunto más concreto de variables.




Figura 18. Goodness of model del PLS: representación acumulada de las X y de Anxiety_Score por componente latente.

Una vez validado el modelo, el plano de scores mostró que la primera componente ordenaba a los individuos según un gradiente claro de ansiedad. Al colorear el espacio latente por Anxiety_Score (Figura 19), los individuos con valores bajos se concentraban en un extremo del eje y los de mayor ansiedad en el opuesto, sin formar grupos cerrados, sino una transición continua entre perfiles.

La lectura del mismo plano según Daily_Sleep_Hours (Figura 20) resultó prácticamente inversa, lo que indicó que LV1 estaba captando un contraste muy definido entre más descanso y menor malestar frente a menos descanso y mayor malestar.




Figura 19. Score plot del modelo PLS coloreado por Anxiety_Score.




Figura 20. Score plots del modelo PLS coloreado por Daily_Sleep_Hours

Esta interpretación ganó fuerza al representar el score plot según Burnout_Risk, variable no usada en el ajuste, cuya ordenación siguió una tendencia coherente con la observada para la ansiedad. Así, la primera componente no solo fue interpretable desde el propio modelo, sino también consistente con una variable externa de malestar psicológico.




Figura 21. Score plots del modelo PLS coloreado por Burnout_Risk.

La interpretación en términos de variables se apoyó en el gráfico de weights y en el VIP. Anxiety_Score apareció alineada con Night_Scrolling_Frequency, Daily_Social_Media_Hours y Screen_Time_Hours, mientras que Daily_Sleep_Hours se situó claramente en el sentido opuesto. Esta disposición quedó respaldada por los coeficientes beta y sus p-valores: la variable con mayor peso en el modelo fue Daily_Sleep_Hours, seguida por Night_Scrolling_Frequency; por detrás aparecieron Daily_Social_Media_Hours y Screen_Time_Hours, mientras que el resto de variables mostraron una aportación muy débil o no significativa. Por ello, el PLS identificó una estructura muy concreta: la ansiedad se relacionaba principalmente con menos horas de sueño, mayor scrolling nocturno y mayor exposición digital.




Figura 22. Relación entre variables explicativas y respuesta en el modelo PLS: gráfico W^*/Q y gráfico VIP.

El modelo también mostró capacidad de diagnóstico. La observación más alejada en el espacio de scores (marcada en la Figura 21) coincidía con la de mayor valor de T^2 como era de suponer, por lo que se interpretó como un posible individuo extremo dentro del espacio latente. Sin embargo, no destacó de forma comparable en términos de SPE, de modo que no se consideró un caso que rompiera la estructura del modelo, sino un perfil muy desplazado, pero todavía coherente con ella. Su contribution plot mostró que esa extremidad estaba dominada sobre todo por una combinación de muchas horas de pantalla y pocas horas de sueño, interpretación que se confirmó en el espacio original.




Figura 23. Diagnóstico de la observación extrema del modelo PLS. Panel A: gráfico de T^2 de Hotelling. Panel B: representación en el espacio original que apoya la interpretación del caso.

A la vista de estos resultados, se ajustó un PLS reducido reteniendo únicamente las variables que realmente sostenían la relación con la ansiedad: Daily_Sleep_Hours, Night_Scrolling_Frequency, Daily_Social_Media_Hours y Screen_Time_Hours. El rendimiento del modelo apenas cambió respecto al completo ($R_Y^2 = 0.3145$, $Q_Y^2 = 0.3104$), lo que confirmó que la estructura útil identificada por el PLS estaba concentrada en ese núcleo de variables y no dependía del resto. Por tanto, la reducción no empobreció el modelo y reforzó su parsimonia.

Tabla 3. Comparación entre el PLS completo y el PLS reducido: número de predictores y componentes, R_Y^2 y Q_Y^2 .

Modelo	Nº de predictores	Nº de componentes	R_Y^2	Q_Y^2
PLS completo	8	2	0.3153	0.3078
PLS reducido	4	2	0.3145	0.3104

Además de comparar el rendimiento global del modelo completo y del modelo reducido, se analizó la estabilidad de los coeficientes beta del modelo PLS mediante intervalos de confianza Jackknife, como muestra la Figura 24. Este análisis mostró que *Daily_Sleep_Hours*, *Night_Scrolling_Frequency*, *Daily_Social_Media_Hours* y *Screen_Time_Hours* concentraban la parte más estable e interpretable de la relación entre hábitos de vida y *Anxiety_Score*, ya que mostraron coeficientes con intervalos Jackknife alejados de cero y estadísticos *t* asociados de mayor magnitud, lo que respaldó su papel en la relación entre hábitos de vida y ansiedad. En cambio, el resto de variables mostraron una contribución más débil dentro del modelo completo.




Figura 24. Coeficientes beta e intervalos Jackknife del modelo PLS completo para *Anxiety_Score*.

Finalmente, el modelo reducido se utilizó para ilustrar cómo se explotaría el PLS ante la llegada de nuevos individuos. Para ello se definieron dos perfiles sintéticos plausibles a partir de percentiles reales del conjunto de datos: un perfil de mayor riesgo esperado, con alta exposición digital, alta frecuencia de *scrolling* nocturno y pocas horas de sueño, y un perfil de menor riesgo esperado, con el patrón opuesto. Ambos quedaron dentro del dominio estructural del modelo, al no superar los límites de T^2 ni de SPE, pero sus predicciones de ansiedad fueron claramente distintas: aproximadamente 6.05 para el perfil de mayor riesgo frente a 3.19 para el de menor riesgo.

Tabla 4. Perfiles sintéticos definidos y resultados de su proyección en el modelo PLS reducido

Variable	Perfil A: alto riesgo	Perfil B: bajo riesgo
Daily_Social_Media_Hours	5.877	2.040
Screen_Time_Hours	9.320	4.690
Night_Scrolling_Frequency	4.507	1.343
Daily_Sleep_Hours	5.000	8.167
T^2	4.2090	4.2272
SPE	0.6780	0.8037
Anxiety_Score predicha	6.0511	3.1922




Figura 25. Proyección de los dos perfiles sintéticos sobre el espacio latente del PLS reducido.

En resumen, el PLS permitió identificar una estructura latente nítida en la relación entre hábitos de vida y ansiedad. Esa estructura quedó dominada por un patrón consistente de menor descanso, mayor uso nocturno y mayor exposición digital, y se mantuvo estable tanto al reducir el modelo como al proyectar nuevos perfiles plausibles.

3.2.3. Regresión en componentes principales (PCR) para Anxiety_Score

Con el fin de comparar la regresión lineal múltiple con un enfoque basado en variables latentes, se ajustó un modelo de regresión en componentes principales (PCR) sobre el mismo bloque de hábitos de vida. En este caso, las componentes se obtuvieron exclusivamente a partir de la estructura de X y, posteriormente, se utilizaron como predictores de Anxiety_Score. La validación cruzada seleccionó ocho componentes, con un rendimiento final de $R_Y^2 = 0.3160$ y $Q_Y^2 = 0.3083$. Como muestra la Figura 26, la capacidad predictiva del modelo fue aumentando al incorporar componentes, pero el mejor resultado solo se alcanzó al retener prácticamente toda la estructura del bloque X.




Figura 26. Evolución de R_Y^2 y Q_Y^2 del modelo PCR en función del número de componentes retenidas.

Los coeficientes estandarizados del modelo final mostraron que las variables con mayor peso fueron Daily_Sleep_Hours, con asociación negativa, y Night_Scrolling_Frequency y Daily_Social_Media_Hours, con asociación positiva. En cambio, el resto de variables presentaron coeficientes muy reducidos, destacando especialmente el escaso peso de Screen_Time_Hours. Por tanto, el PCR volvió a señalar el mismo núcleo de variables que ya había aparecido en la MLR.




Figura 27. Coeficientes beta estandarizados del modelo PCR final.

Por ello, el PCR confirmó la existencia de señal explicativa en el bloque de hábitos, pero no aportó una mejora práctica clara ni en capacidad predictiva ni en parsimonia frente a la MLR y el PLS. De hecho, solo alcanzó un rendimiento comparable al de ambos modelos al retener casi todas las componentes, lo que indica que, en este problema, la compresión de X no ofreció una ventaja clara respecto a trabajar en el espacio original o mediante componentes orientadas específicamente a la relación entre predictores y respuesta.

3.2.4. Comparación final de modelos para la explicación de Anxiety_Score

Observando los resultados de las anteriores secciones referidas a la explicación de Anxiety_Score, los tres enfoques mostraron una capacidad predictiva muy similar, con valores de R_Y^2 y Q_Y^2 en torno a 0.31 en todos los casos. No obstante, las diferencias entre ellos aparecieron con mayor claridad al considerar su parsimonia y su capacidad de interpretación.

La MLR permitió obtener un modelo reducido muy compacto, formado por Night_Scrolling_Frequency, Daily_Social_Media_Hours y Daily_Sleep_Hours, manteniendo prácticamente el mismo rendimiento que el modelo completo. El PCR, por su parte, alcanzó un rendimiento igualmente comparable, pero solo al retener ocho componentes, es decir, prácticamente toda la estructura del bloque X . En consecuencia, en este problema la compresión de X no aportó una ventaja clara ni en capacidad predictiva ni en parsimonia. Por último, el PLS mantuvo un rendimiento similar con solo dos componentes y, además, permitió identificar de forma explícita la estructura latente que vinculaba los hábitos de vida con la ansiedad, así como reducir el modelo a un núcleo de cuatro variables sin pérdida apreciable de capacidad predictiva.

Por tanto, aunque los tres enfoques ofrecieron una calidad predictiva muy próxima, el PLS fue el que proporcionó una lectura más rica al combinar rendimiento, parsimonia e interpretabilidad. La MLR reducida resultó útil como referencia en el espacio original, mientras que el PCR tuvo principalmente interés comparativo, al poner de manifiesto que resumir la variabilidad de X no garantizaba por sí solo una ventaja práctica en la explicación de Anxiety_Score.

Tabla 5. Comparación de los modelos ajustados para la explicación de Anxiety_Score en el bloque de hábitos de vida

Modelo	Nº de predictores	Nº de componentes	R_Y^2	Q_Y^2
MLR completo	8	—	0.3160	0.3093
MLR reducido	3	—	0.3153	0.3126
PLS completo	8	2	0.3153	0.3078
PLS reducido	4	2	0.3145	0.3104
PCR	8	8	0.3160	0.3083

3.3. PCA sobre variables psicológicas

Antes de interpretar el modelo PCA, se evaluó la posible presencia de observaciones extremas o atípicas mediante las estadísticas T^2 de Hotelling y SPE. En este contexto, T^2 resume la distancia de la proyección de cada observación al centro del modelo en el subespacio latente, mientras que SPE cuantifica la parte de variabilidad no explicada por las componentes retenidas.

Como se observa en la Figura 28, en ambos gráficos aparecen algunas observaciones por encima del límite de control al 95%, lo cual es esperable en conjuntos de datos de gran tamaño. No obstante, no se identifican observaciones claramente aisladas ni con un comportamiento anómalo severo que justifique su eliminación. Por ello, se decidió mantener inicialmente todas las observaciones y continuar con la interpretación del modelo.




Figura 28. Diagnóstico de observaciones mediante las estadísticas T^2 de Hotelling y SPE en el modelo PCA. Se representan los límites de control al 95%, identificando posibles observaciones extremas en el espacio latente.

De forma complementaria, se examinaron varias observaciones señaladas en los gráficos de control mediante su contribución al modelo y su representación en el espacio original. Como se muestra en la Figura 29 las variables con mayor peso en su desviación fueron principalmente Anxiety_Score y Wellbeing_Index, y la inspección en el espacio original confirmó que se trataba de individuos situados en zonas extremas de la nube de datos, pero no incoherentes con la estructura general de correlación. Esta revisión permitió concluir que las observaciones marcadas en rojo debían interpretarse como perfiles extremos, pero no como observaciones anómalas o erróneas.




Figura 29. Revisión de observaciones más extremas en los gráficos de control. Izquierda: contribución de las variables originales a su desviación en el modelo PCA. Derecha: representación en el espacio original Anxiety_Score-Wellbeing_Index.

Una vez verificada la ausencia de anomalías severas, se procedió al análisis de la capacidad explicativa del modelo. La evolución acumulada de R_X^2 y Q_X^2 , mostrada en la Figura 30, evidenció un comportamiento estable, con valores prácticamente idénticos para ambas métricas. La primera componente explica aproximadamente el 49% de la variabilidad total, mientras que las dos primeras alcanzan cerca del 63% y las cuatro componentes aproximadamente el 83%.

En consecuencia, aunque el modelo completo retuvo cuatro componentes, el plano definido por las dos primeras recoge una parte sustancial de la información relevante del bloque psicológico.




Figura 30. Evolución acumulada de R^2 y Q^2 en función del número de componentes principales. Ambas métricas muestran un comportamiento estable y permiten evaluar la capacidad explicativa y predictiva del modelo.

Además, en la Figura 31 se observa que la variabilidad explicada no es homogénea entre variables. Mientras algunas, como Anxiety_Score y Wellbeing_Index, quedan recogidas en gran medida por la primera componente, otras reparten su R^2 entre varias componentes. Esto sugiere que, aunque existe un eje dominante de bienestar frente a malestar psicológico, la estructura del bloque no debe reducirse de forma mecánica a una única dimensión, ya que algunas variables conservan información secundaria relevante.




Figura 31. Variabilidad explicada por variable en las distintas componentes principales del modelo PCA. Se observa que no todas las variables quedan igualmente bien representadas en las primeras componentes.

El gráfico de loadings mostrado en la Figura 32 permitió interpretar la estructura de correlación entre las variables psicológicas a partir de las dos primeras componentes principales. En la primera componente, las variables con mayor peso fueron Wellbeing_Index, Motivation_Level, Sleep_Quality_Score y Mood_Stability_Score, en oposición a Anxiety_Score y Emotional_Fatigue_Score. Por tanto, esta componente puede interpretarse como un eje dominante que contrapone bienestar y equilibrio psicológico frente a malestar emocional.

Por su parte, la segunda componente recoge sobre todo la variabilidad asociada a Overthinking_Score y Social_Comparison_Index, que aparecen más diferenciadas respecto al resto de variables. Esto sugiere que, además del gradiente principal de bienestar–malestar, existe una segunda dirección de variabilidad relacionada con la tendencia a dar demasiadas vueltas a las cosas y a compararse socialmente. Con el fin de facilitar la interpretación de los ejes, se exploró adicionalmente una rotación varimax de las componentes.




Figura 32. Representación conjunta de loadings del modelo PCA en el plano definido por las dos primeras componentes. Se observa una estructura de oposición entre variables asociadas al bienestar y al malestar psicológico.

Por último, la proyección de las observaciones en el espacio de scores, coloreadas según la variable de respuesta `Burnout_Risk`, se muestra en la Figura 33. Aunque el PCA se ajustó con finalidad exploratoria, se observa una cierta ordenación de los individuos a lo largo de la primera componente, con los niveles de mayor riesgo desplazándose hacia valores negativos y los de menor riesgo hacia valores positivos.




Figura 33. Proyección de las observaciones en el espacio de scores del PCA, coloreadas según la variable `Burnout_Risk`.

No obstante, existe un solapamiento considerable entre clases, lo que confirma que el PCA, por sí solo, no resulta suficiente para una separación clara entre categorías, pero sí proporciona una base útil para el análisis posterior mediante técnicas supervisadas como PLS-DA.

3.4. PLS-DA sobre variables psicológicas y discriminación del riesgo de burnout

Con el fin de estudiar la capacidad discriminante del bloque de variables psicológicas respecto al nivel de riesgo de burnout, se ajustó un modelo PLS-DA empleando como matriz X las ocho variables psicológicas seleccionadas y como respuesta Y la variable categórica `Burnout_Risk`, codificada mediante variables *dummy*.

Desde el punto de vista algebraico, el modelo se construyó como un PLS sobre dicha matriz respuesta, de forma que la información de las variables originales quedó proyectada en un subespacio latente definido por los scores T , según las relaciones:

$$X = TP^T + E, \quad T = XW^*, \quad Y = TC^T + F.$$

En este contexto, las nuevas variables latentes no se obtienen únicamente para resumir la variabilidad de X , sino para capturar preferentemente aquella parte de la estructura de X que resulta más útil para discriminar entre clases. Esta es precisamente la lógica del PLS frente a otras técnicas basadas en variables latentes: las componentes retenidas describen variabilidad de X relacionada con Y , y no solo la estructura interna de X .

3.4.1. Ajuste del modelo PLS-DA completo y selección del número de componentes

La primera decisión consistió en determinar el número adecuado de componentes PLS. Para ello se recurrió a la validación cruzada, comparando la capacidad descriptiva y predictiva del modelo en función del número de variables latentes retenidas. Como se observa en la Figura 34, el modelo alcanzó su mejor equilibrio con dos componentes, ya que a partir de este punto la mejora adicional fue escasa y no justificó aumentar la complejidad del subespacio latente. Por tanto, el modelo completo con las ocho variables psicológicas se interpretó inicialmente en un plano bidimensional $t_1 - t_2$, suficiente para recoger la parte principal de la estructura discriminante del problema.




Figura 34. Evolución de los indicadores de validación del modelo PLS-DA completo en función del número de componentes retenidas.

Tal como se ha venido señalando a lo largo del desarrollo de este trabajo, y una vez fijado provisionalmente el número de componentes, se procedió al diagnóstico de las observaciones mediante T^2 de Hotelling y SPE. Como se mencionó anteriormente, la primera estadística resume la distancia de cada observación al centro del modelo en el subespacio latente, mientras que la segunda cuantifica la variabilidad no explicada. Bajo esta lógica, T^2 actúa detectando observaciones extremas en el espacio de scores, mientras que SPE identifica aquellas que no logran ajustarse correctamente al modelo.

Como puede apreciarse en la Figura 35, el modelo completo presentaba varias observaciones por encima de los límites del 95% tanto en T^2 como en SPE. Sin embargo, esta circunstancia no se interpretó como motivo suficiente para eliminar individuos, ya que es esperable que algunas observaciones superen dichos límites. Además, siguiendo el criterio adoptado en la asignatura, solo se consideraría razonable plantear la exclusión cuando la desviación fuese claramente extrema, del orden de tres veces superior al límite de control, situación que no se observó en este caso. En consecuencia, se decidió mantener las observaciones y continuar con la interpretación del modelo completo.




Figura 35. Diagnóstico de observaciones del modelo PLS-DA completo mediante las estadísticas T^2 de Hotelling y SPE, con límites de control al 95%.

A continuación, se procedió al diagnóstico de variables del modelo completo. Para ello se analizaron conjuntamente los coeficientes beta, los intervalos Jackknife, los p-valores asociados y los valores VIP, con el fin de identificar qué variables contribuían de forma consistente a la discriminación entre clases y cuáles desempeñaban un papel secundario.

En primer lugar, se examinaron los valores VIP del modelo completo. Como se observa en la Figura 36, las variables con mayor importancia relativa en la construcción del espacio latente y en la discriminación de la respuesta fueron Wellbeing_Index, Anxiety_Score, Motivation_Level, Sleep_Quality_Score y Mood_Stability_Score. Emotional_Fatigue_Score presentó también una contribución relevante, mientras que Overthinking_Score y, especialmente, Social_Comparison_Index mostraron valores claramente inferiores.




Figura 36. Valores VIP del modelo PLS-DA completo para las ocho variables psicológicas. Los mayores valores corresponden a las variables con mayor contribución global a la proyección latente y a la discriminación del riesgo.

Esta lectura se reforzó mediante el análisis conjunto de los p-valores y de los coeficientes beta del modelo para la clase High. Como se aprecia en la Figura 37, Anxiety_Score, Mood_Stability_Score, Sleep_Quality_Score, Motivation_Level, Emotional_Fatigue_Score y Wellbeing_Index presentaron p-valores muy reducidos en las tres clases, lo que indicaba una contribución estadísticamente significativa y consistente. En cambio, Overthinking_Score y Social_Comparison_Index no alcanzaron significación en ninguna de ellas.




Figura 37. Diagnóstico de variables del modelo PLS-DA completo. Izquierda: p-valores Jackknife asociados a los coeficientes de regresión para cada clase. Derecha: coeficientes beta estandarizados del modelo para la clase High con sus correspondientes intervalos Jackknife.

Estos resultados indican que la discriminación del riesgo de burnout se apoya principalmente en un núcleo formado por bienestar, ansiedad, motivación, sueño, estabilidad y fatiga emocionales, mientras que comparación social y sobrepensamiento desempeñan un papel secundario. Por ello, se consideró razonable simplificar el bloque explicativo eliminando ambas variables y reajustando un nuevo modelo PLS-DA reducido.

3.4.2. Interpretación del modelo reducido

La primera decisión en este nuevo modelo consistió nuevamente en determinar el número adecuado de componentes. Como se observa en la Figura 38, la validación cruzada indicó que una única componente era suficiente, ya que los valores de R^2_Y y Q^2_Y prácticamente coincidían y no se obtenía mejora al añadir complejidad adicional. Este resultado indica que la estructura discriminante del problema puede resumirse en un único eje latente, lo que refuerza la parsimonia del modelo reducido.




Figura 38. Evolución de los indicadores de validación del modelo PLS-DA reducido en función del número de componentes retenidas. La validación cruzada indicó que una única variable latente era suficiente.

Con el fin de interpretar mejor este resultado, se analizó la estructura de correlación entre las variables psicológicas retenidas. Como se muestra en la Figura 39, existe un patrón claro de correlaciones: por un lado, Wellbeing_Index, Mood_Stability_Score, Sleep_Quality_Score y Motivation_Level presentan correlaciones positivas elevadas entre sí, mientras que Anxiety_Score y Emotional_Fatigue_Score muestran correlaciones negativas con este bloque.




Figura 39. Matriz de correlaciones entre las variables psicológicas del modelo reducido. Se observa un patrón de correlación estructurado en torno a un eje bienestar–malestar; que justifica la existencia de una única componente latente dominante.

En particular, destaca la fuerte correlación de Wellbeing_Index con el resto de variables, tanto en sentido positivo como negativo, lo que evidencia la existencia de un eje dominante que contrapone bienestar frente a malestar psicológico. Esta estructura se refleja también en los pesos W^* del modelo, donde se observa el mismo patrón de oposición entre variables. En consecuencia, la mayor parte de la variabilidad relevante para la discriminación se organiza en torno a una única dirección, lo que justifica que el modelo PLS-DA reducido pueda representarse adecuadamente con una sola componente latente. Por tanto, la elección de una sola componente no solo está respaldada por la validación cruzada, sino también por la propia estructura de correlación de los datos, que muestra un patrón claramente unidimensional.

Una vez fijada la dimensionalidad del modelo, se examinó de nuevo el diagnóstico de observaciones mediante las estadísticas T^2 de Hotelling y SPE. Como puede apreciarse en la Figura 40, se identificó una observación destacada en el gráfico de T^2 , marcada en rojo, lo que indicaba un perfil extremo dentro del subespacio latente. Sin embargo, no se observó un comportamiento igualmente acusado en SPE, por lo que no se trataba de una observación mal ajustada al modelo, sino de un individuo periférico pero coherente con la estructura general de los datos.




Figura 40. Diagnóstico de observaciones del modelo PLS-DA reducido mediante las estadísticas T^2 de Hotelling y SPE, con indicación de los límites de control al 95%. La observación señalada en rojo destaca por su elevada distancia en el espacio de scores.

Antes de plantear cualquier exclusión, se revisó dicha observación en el espacio original, analizando las variables con mayor contribución a su desviación. Como se muestra en la Figura 41, las variables más implicadas fueron *Wellbeing_Index* y *Motivation_Level*. La inspección conjunta del gráfico de contribuciones y de la representación en el espacio original indicó que la observación presentaba valores muy elevados en ambas variables, lo que sugería un perfil claramente extremo dentro del conjunto de datos.




Figura 41. Diagnóstico de la observación extrema señalada en el modelo PLS-DA reducido. Izquierda: contribución de las variables originales a su desviación en el espacio latente. Derecha: representación en el espacio original *Motivation_Level*–*Wellbeing_Index*, donde la observación aparece como un perfil extremo pero coherente con la estructura de correlación del modelo.

No obstante, esta pauta no se interpretó como un dato incoherente ni como una ruptura de la estructura de correlación del modelo, sino como un individuo extremo pero consistente con el problema estudiado. En consecuencia, se decidió mantener esta observación en el modelo, al considerar que aportaba información válida sobre la variabilidad real presente en la muestra.

A continuación, se procedió al diagnóstico de variables del modelo reducido. Como se observa en la Figura 42, las variables retenidas presentaron valores VIP próximos o superiores a 0.8, sin que apareciera ninguna con una importancia claramente marginal. Además, los coeficientes beta para la clase High mostraron signos coherentes con la interpretación del eje latente: *Anxiety_Score* y *Emotional_Fatigue_Score* se asociaron positivamente con el riesgo alto, mientras que *Mood_Stability_Score*, *Sleep_Quality_Score*, *Motivation_Level* y *Wellbeing_Index* lo hicieron en sentido negativo.




Figura 42. Diagnóstico de variables del modelo PLS-DA reducido. Izquierda: valores VIP de las seis variables retenidas. Derecha: coeficientes beta estandarizados para la clase High, con sus correspondientes intervalos Jackknife. La lectura conjunta de ambas representaciones permite valorar tanto la importancia global de cada variable como el sentido de su asociación con el riesgo alto de burnout.

De forma complementaria, la Tabla 6 confirmó que el modelo reducido no solo conservaba significación estadística, sino también coherencia interpretativa para las tres clases de la respuesta. Así, las variables retenidas mostraron efectos bien definidos, sin que apareciera ninguna con un comportamiento ambiguo o claramente residual.

Tabla 6. Coeficientes beta estandarizados y p-valores Jackknife del modelo PLS-DA reducido para las tres clases de la respuesta.

Variable	Beta High	p-value High	Beta Low	p-value Low	Beta Medium	p-value Medium
Anxiety_Score	0,171405	1,860626e-09	-0,094936	0,000095	-0,138477	7,791500e-08
Mood_Stability_Score	-0,150889	2,125717e-10	0,083573	0,000126	0,121903	1,858314e-08
Sleep_Quality_Score	-0,155740	2,916885e-09	0,086259	0,000040	0,125821	3,785108e-07
Motivation_Level	-0,164066	3,616173e-08	0,090871	0,000026	0,132548	0,000001
Emotional_Fatigue_Score	0,130203	1,330827e-09	-0,072115	0,000146	-0,105191	2,328757e-08
Wellbeing_Index	-0,212589	1,275051e-10	0,117746	0,000055	0,171749	1,138816e-07

Estos resultados indican que, tras la simplificación realizada, el modelo reducido queda sustentado por un bloque compacto de variables con un papel discriminante consistente. La interpretación conjunta de VIP y coeficientes con incertidumbre es precisamente la recomendada en la validación de variables en PLS, donde no conviene basarse en un único criterio aislado.

3.4.3. Modelo reducido e interpretación final

Dado que el modelo reducido quedó definido por una única componente latente, la interpretación estructural no se realizó mediante un plano bidimensional de scores, sino a lo largo del eje t_1 . Para ello, en primer lugar, se examinaron los pesos W^* de las variables originales en la componente retenida. Como se observa en la Figura 43, las variables con pesos positivos se sitúan en un extremo del eje, mientras que las de pesos negativos aparecen en el opuesto. En particular, el patrón obtenido muestra que esta única dirección latente resume un gradiente interpretable de bienestar frente a malestar psicológico. Esta lectura resulta coherente tanto con los coeficientes del modelo como con la propia lógica del PLS: si una sola componente es suficiente, ello indica que existe una única dirección dominante de discriminación en el bloque de variables.




Figura 43. Contribución de las variables originales a la componente latente del modelo PLS-DA reducido. El signo de la contribución indica el extremo del eje en el que se sitúa cada variable.

A continuación, se analizó cómo se distribuían los scores t_1 entre las distintas clases de burnout. Como Dragonet no permitía representar de forma suficientemente informativa los scores cuando el modelo solo retenía una componente, se extrajeron los valores de t_1 y se generó en Python un boxplot complementario para estudiar su distribución por categorías. Como se muestra en la Figura 44, los individuos de la clase Low se concentran en valores altos del score, los de la clase High en valores bajos y la clase Medium ocupa una posición intermedia. Esta ordenación confirma que la única componente retenida recoge adecuadamente un continuo de severidad del burnout.




Figura 44. Distribución de los scores t_1 del modelo PLS-DA reducido por categoría de *Burnout_Risk*. El boxplot se generó en Python a partir de los valores de score exportados del modelo, con el fin de visualizar con mayor claridad la localización relativa de las clases sobre la única componente retenida.

La representación mediante boxplot permitió visualizar con mayor claridad la localización relativa de cada grupo sobre el eje latente y comprobar que la clase Medium se situaba entre los dos extremos, como cabría esperar en un problema ordinal de este tipo. No obstante, esta representación debe entenderse únicamente como una ayuda descriptiva sobre la distribución de los scores

3.4.4. Evaluación de la capacidad clasificatoria del modelo

Una vez interpretada la estructura latente del modelo reducido, se evaluó su capacidad clasificatoria mediante métricas habituales de clasificación. Para ello, el modelo se replicó en Python a partir de la misma estructura obtenida en Dragonet, comprobando previamente que los resultados internos del ajuste eran equivalentes en ambos entornos, en particular en lo relativo a los scores, el diagnóstico mediante SPE y los pesos W^* . Una vez verificada esta coherencia, se aplicó el modelo en Python para calcular la matriz de confusión, las curvas ROC y las métricas de clasificación.

La Figura 45 recoge la matriz de confusión, tanto en términos absolutos como normalizados. En ella se observa que el modelo identifica muy bien la clase High, con un porcentaje de clasificación correcta muy elevado, mientras que la clase Medium también presenta un comportamiento adecuado. En cambio, la clase Low no queda bien delimitada y tiende a ser absorbida por la clase Medium, lo que pone de manifiesto la dificultad adicional asociada a su menor representación muestral.




Figura 45. Matriz de confusión absoluta y normalizada del modelo PLS-DA reducido. La comparación entre ambas representaciones permite evaluar tanto el número de individuos correctamente clasificados como el rendimiento relativo dentro de cada clase.

Esta lectura se complementa con las métricas globales de clasificación, recogidas en la Tabla 7. Aunque el modelo presenta un valor elevado de accuracy, esta métrica debe interpretarse con cautela debido al desbalance entre clases. Por ello, se prestó especial atención a indicadores más robustos como el balanced accuracy, el F1 macro, el MCC y el AUROC macro, que confirman que el modelo discrimina adecuadamente la estructura principal del problema, aunque con limitaciones en la clase minoritaria.

Tabla 7. Métricas de clasificación del modelo PLS-DA.

Accuracy	Balanced accuracy	Precision macro	Recall macro	F1 macro	F1 weighted	Cohen kappa	MCC	AUROC macro (OVR)	AUROC weighted (OVR)	AUROC macro (OVO)
0,934	0,642	0,623	0,642	0,632	0,919	0,871	0,873	0,761	0,948	0,761

La evaluación mediante curvas ROC permitió analizar la separabilidad de cada clase frente al resto. En este contexto, el área bajo la curva ROC (AUROC) puede interpretarse como un índice global de exactitud discriminante: valores próximos a 1 indican clasificación prácticamente perfecta, mientras que valores cercanos a 0.5 corresponden a un comportamiento equivalente al azar. Como se muestra en la Figura 46, las clases High y Medium presentan una capacidad discriminante elevada, con curvas próximas al vértice superior izquierdo, mientras que la clase Low muestra un comportamiento claramente más modesto.




Figura 46. Curvas ROC one-vs-rest del modelo PLS-DA reducido para las tres clases de Burnout_Risk. Las clases High y Medium presentan una mayor capacidad discriminante que la clase Low.

Esta misma interpretación se refleja en la Tabla 8, donde se recogen las métricas de clasificación por clase. En ella se observa que la clase High alcanza los mejores valores en precisión, recall, F1 y AUROC, seguida de la clase Medium, mientras que la clase Low presenta un rendimiento significativamente inferior en todas las métricas. Estos resultados refuerzan la idea de que el modelo es especialmente eficaz para identificar perfiles de alto riesgo, pero menos preciso en la clasificación de la clase minoritaria.

Tabla 8. Métricas de clasificación por clase del modelo PLS-DA.

Clase	Precision	Recall	F1	Support	AUROC (OVR)	Brier
Low	0,000	0,000	0,000	64	0,349	0,071
Medium	0,911	0,957	0,933	1000	0,937	0,198
High	0,958	0,970	0,964	1000	0,997	0,169

Al mismo tiempo, el modelo PLS-DA reducido permite capturar de forma adecuada la estructura discriminante principal del problema y ofrece una interpretación clara del gradiente psicológico asociado al riesgo de burnout. Sin embargo, desde el punto de vista estrictamente clasificatorio, el modelo presenta una limitación importante: la clase Low no queda correctamente recuperada, con precision, recall y F1 iguales a 0.000 y un AUROC OVR inferior a 0.5. Por tanto, aunque el accuracy global es elevado, este valor está fuertemente condicionado por el peso de las clases Medium y High. En consecuencia, el PLS-DA debe interpretarse en este trabajo principalmente como una herramienta de discriminación e interpretación del espacio latente, no como el clasificador óptimo para todas las clases.

3.4.5. Proyección de nuevas observaciones y explotación del modelo

Con el fin de ilustrar la explotación del modelo PLS-DA, se definieron tres nuevas observaciones sintéticas, asociadas *a priori* a perfiles de riesgo alto, intermedio y bajo de *burnout*. El objetivo fue comparar posteriormente esa caracterización inicial con la clasificación proporcionada por el modelo. Estas observaciones se organizaron en una matriz X_{new} de dimensión 3×6 , donde cada fila representa un individuo y cada columna una de las variables psicológicas retenidas en el modelo reducido.

Burnout real	Anxiety_Score	Mood_Stability_Score	Sleep_Quality_Score	Motivation_Level	Emotional_Fatigue_Score	Wellbeing_Index
High	8.8	2.2	2.4	2.8	8.4	2.1
Medium	5.1	4.8	6.0	5.2	5.0	4.9
Low	2.0	8.0	8.1	8.5	2.1	8.7

Donde realmente nuestra nueva matriz X_{new} es:

$$X_{new} = \begin{bmatrix} 8.8 & 2.2 & 2.4 & 2.8 & 8.4 & 2.1 \\ 5.1 & 4.8 & 6.0 & 5.2 & 5.0 & 4.9 \\ 2.0 & 8.0 & 8.1 & 8.5 & 2.1 & 8.7 \end{bmatrix}$$

donde las columnas corresponden, en este orden, a *Anxiety_Score*, *Mood_Stability_Score*, *Sleep_Quality_Score*, *Motivation_Level*, *Emotional_Fatigue_Score* y *Wellbeing_Index*. La primera fila representa un perfil de alto riesgo esperado, la segunda un perfil intermedio y la tercera un perfil psicológicamente más favorable.

Siguiendo el procedimiento descrito en la asignatura, estas nuevas observaciones no se introducen directamente en el modelo con sus valores brutos, sino que primero deben centrarse y escalarse utilizando la misma media y desviación estándar empleadas en el conjunto de calibración.

En notación matricial, este preprocesado se expresa como:

$$X_{\text{new}}^{cs} = (X_{\text{new}} - 1\bar{X}^T)D_X^{-1}$$

Una vez preprocesadas, se proyectan sobre el subespacio latente mediante la matriz de pesos corregidos W^* , según:

$$T_{\text{new}} = X_{\text{new}}^{cs} W^*.$$

Aunque la tabla W^*/Q se obtuvo utilizando un modelo con dos componentes para poder visualizar los coeficientes en Dragonet, se comprobó que los pesos asociados a la primera componente latente apenas varían respecto al modelo con una sola componente. Este comportamiento es coherente con la validación cruzada, que indicaba que la estructura del problema es esencialmente unidimensional, por lo que la primera componente captura prácticamente toda la información relevante y permanece estable al añadir componentes adicionales. Para la primera componente latente, los pesos de las variables X fueron:

$$W^* = \begin{bmatrix} -0.421375 \\ 0.370940 \\ 0.382863 \\ 0.403333 \\ -0.320086 \\ 0.522618 \end{bmatrix}$$

Por tanto, el score de una nueva observación puede calcularse como una combinación lineal de las variables centradas y escaladas. Así, para cualquier nuevo individuo i ,

$$t_{i1} = -0.421375 x_{i1}^{cs} + 0.370940 x_{i2}^{cs} + 0.382863 x_{i3}^{cs} + 0.403333 x_{i4}^{cs} - 0.320086 x_{i5}^{cs} + 0.522618 x_{i6}^{cs}.$$

Esta expresión muestra cómo el modelo construye la variable latente: *Anxiety_Score* y *Emotional_Fatigue_Score* contribuyen en sentido negativo, mientras que *Wellbeing_Index*, *Motivation_Level*, *Sleep_Quality_Score* y *Mood_Stability_Score* lo hacen en sentido positivo, configurando un gradiente interpretable de malestar a bienestar psicológico.

Aplicando esta proyección a las tres observaciones sintéticas, se obtuvieron los siguientes valores de score:

$$T_{\text{new}} = \begin{bmatrix} -5.3022 \\ 0.0102 \\ 5.4570 \end{bmatrix}$$

Estos resultados sitúan al perfil de mayor riesgo esperado en el extremo negativo del eje latente, al perfil intermedio cerca del origen y al perfil más favorable en la región positiva. Esta ordenación fue coherente con la interpretación previa del modelo y con la distribución observada en la Figura 44. Una vez calculados los scores, la predicción de la respuesta se obtiene mediante la matriz C , según:

$$\hat{Y}_{\text{new}} = T_{\text{new}} C^T.$$

En Dragonet, la parte correspondiente a Y en la tabla W/Q^* proporciona precisamente los coeficientes de C . En este caso, para la primera componente latente se obtuvo:

$$C = \begin{bmatrix} C_{\text{High}} \\ C_{\text{Low}} \\ C_{\text{Medium}} \end{bmatrix} = \begin{bmatrix} -0.406776 \\ 0.225300 \\ 0.328632 \end{bmatrix}$$

Por tanto, cada score *t*_{il} se transforma en tres puntuaciones asociadas a las variables dummy de la respuesta, una para cada clase. Estas puntuaciones no deben interpretarse necesariamente como probabilidades calibradas, sino como valores de asignación del modelo PLS-DA. La clasificación final se realizó seleccionando la clase con mayor puntuación predicha:

$$\hat{Y}_{new} = \begin{bmatrix} \hat{y}_{1,High} & \hat{y}_{1,Low} & \hat{y}_{1,Medium} \\ \hat{y}_{2,High} & \hat{y}_{2,Low} & \hat{y}_{2,Medium} \\ \hat{y}_{3,High} & \hat{y}_{3,Low} & \hat{y}_{3,Medium} \end{bmatrix}$$

Sustituyendo los valores obtenidos, resulta:

$$\hat{Y}_{new} = \begin{bmatrix} \text{High} & \text{Low} & \text{Medium} \\ 2.156816 & -1.194585 & -1.742944 \\ -0.004149 & 0.002298 & 0.003352 \\ -2.219777 & 1.229492 & 1.793744 \end{bmatrix}$$

Comparando estas predicciones con las etiquetas reales, se observa que el perfil de alto riesgo se clasifica correctamente como High, el perfil intermedio como Medium y el perfil favorable como Medium, lo que confirma la dificultad previamente observada para delimitar la clase Low.

Además de la predicción, el modelo permite evaluar la coherencia estructural de las nuevas observaciones. Para ello, se reconstruye la parte explicada de X :

$$\hat{X}_{new} = T_{new}P^T$$

y se calcula el residuo:

$$E_{new} = X_{new}^{cs} - \hat{X}_{new}$$

a partir del cual se obtiene el estadístico SPE. De forma complementaria, se calcula la distancia T^2 de Hotelling. Por tanto, a través de Dragonet, la Figura 47 muestra los valores de T^2 y SPE para las tres observaciones. Se observa que las observaciones 1 y 3 superan el límite de T^2 , pero ninguna supera el límite de SPE. Esto indica que se trata de observaciones extremas dentro del subespacio latente, pero coherentes con la estructura del modelo, mientras que la observación intermedia presenta un comportamiento típico.




Figura 47. Diagnóstico de las nuevas observaciones mediante los estadísticos T^2 de Hotelling y SPE

Finalmente, la Tabla 9 recoge de forma conjunta los resultados de proyección, diagnóstico y clasificación de las nuevas observaciones. Para facilitar la lectura de la Tabla 9, las salidas del modelo se expresaron como puntuaciones normalizadas dentro de cada observación. Estas puntuaciones se utilizaron únicamente como criterio comparativo de asignación de clase y no deben interpretarse como probabilidades calibradas.

Tabla 9. Proyección, diagnóstico y clasificación de nuevas observaciones en el modelo PLS-DA.

Observación	t_1	SPE	Límite SPE	T^2	Límite T^2	Clase predicha	Puntuación Low	Puntuación Medium	Puntuación High
Perfil alto riesgo	-5,302	3,448	5,606	7,547	3,848	High	0,133	0,108	0,759
Perfil intermedio	0,010	0,967	5,606	0,000	3,848	Medium	0,241	0,380	0,379
Perfil bajo riesgo	5,457	1,777	5,606	7,994	3,848	Medium	0,221	0,687	0,093

En ella se observa que:

- El perfil de alto riesgo se clasifica correctamente como High y presenta un comportamiento extremo pero coherente.
- El perfil intermedio se sitúa cerca del origen y se clasifica como Medium.
- El perfil favorable se clasifica como Medium, reflejando la dificultad del modelo para separar completamente la clase Low.

En conjunto, este ejemplo muestra de forma explícita cómo el modelo PLS-DA procesa nuevas observaciones: primero las centra y escala, después las proyecta mediante W^* , obtiene los scores, realiza la predicción a través de la matriz C y, finalmente, evalúa su coherencia estructural mediante T^2 y SPE. Esto confirma que el modelo no solo permite clasificar, sino también interpretar y diagnosticar nuevos individuos dentro del espacio latente.

3.5. Comparativa con Random Forest clasificatorio

Con el objetivo de contrastar el comportamiento del PLS-DA con un método visto en otras asignaturas, se ajustó adicionalmente un clasificador Random Forest sobre el mismo bloque de variables psicológicas. Esta comparación no persigue sustituir el análisis basado en variables latentes, sino evaluar en qué medida la capacidad discriminante observada con PLS-DA puede mejorarse desde una perspectiva estrictamente predictiva.

Para el Random Forest se utilizó una partición estratificada de los datos en conjunto de entrenamiento y conjunto de test, manteniendo la proporción de clases de Burnout_Risk. Sobre el conjunto de entrenamiento se evaluó la estabilidad del modelo mediante validación cruzada estratificada, mientras que el conjunto test se reservó como comprobación adicional del rendimiento fuera de la muestra de ajuste. De este modo, las métricas globales permiten valorar la capacidad predictiva media del modelo, y las matrices de confusión en test permiten comprobar si dicho comportamiento se mantiene sobre observaciones no utilizadas directamente en el entrenamiento.

Como resumen comparativo, la Tabla 10 recoge las principales métricas de clasificación obtenidas para ambos modelos. En ella se observa que el modelo Random Forest supera claramente al PLS-DA en todas las métricas consideradas, incluyendo accuracy, balanced accuracy, F1 macro, MCC y AUROC macro. Esta diferencia refleja la mayor capacidad predictiva del Random Forest, especialmente por su capacidad para capturar relaciones no lineales e interacciones complejas entre las variables psicológicas. Sin embargo, este resultado debe interpretarse con cautela, ya que el análisis de importancia por permutación mostró una dependencia muy acusada de Wellbeing_Index, una variable global estrechamente relacionada con el constructor de bienestar psicológico y, por extensión, con el riesgo de burnout.

Por tanto, el Random Forest alcanza un rendimiento predictivo muy elevado, pero parte de esta superioridad puede estar favorecida por la presencia de una variable resumen con gran capacidad discriminante.

Tabla 10. Comparación de rendimiento entre PLS-DA y Random Forest

Modelo	Accuracy	Balanced accuracy	F1 macro	MCC	AUROC macro (OVR)
PLS-DA	0,934	0,642	0,632	0,873	0,761
Random Forest	0,997	0,993	0,993	0,994	1,000

La comparación muestra que el Random Forest supera claramente al PLS-DA en todas las métricas evaluadas, especialmente en balanced accuracy y F1 macro, lo que indica una mejor capacidad para clasificar correctamente las distintas clases de Burnout_Risk. Esta mejora es especialmente relevante porque el PLS-DA presentaba dificultades para recuperar la clase Low, mientras que el Random Forest consigue un rendimiento mucho más equilibrado entre clases.

Aun así, ambos modelos responden a objetivos distintos. El PLS-DA se basa en la construcción de variables latentes y permite interpretar la estructura discriminante del problema, identificando qué combinación de variables psicológicas separa los perfiles de riesgo. En cambio, el Random Forest prioriza la precisión clasificatoria, pero no proporciona una representación latente directa ni una lectura tan transparente del espacio de variables.

Por ello, en este trabajo se mantuvo el PLS-DA como modelo principal de interpretación, ya que permite comprender el gradiente psicológico asociado al riesgo de burnout, mientras que el Random Forest se utilizó como referencia predictiva complementaria. Esta combinación permite integrar dos perspectivas: la interpretabilidad del enfoque multivariante basado en variables latentes y la capacidad predictiva de un modelo no lineal más flexible.

Los resultados detallados del ajuste del Random Forest, junto con las métricas completas, las matrices de confusión, las curvas ROC y el análisis de importancia por permutación, se recogen en el Anexo C.

4. Conclusiones

Los resultados obtenidos permiten extraer varias conclusiones relevantes. En primer lugar, el bloque de hábitos de vida no mostró una organización en grupos naturales bien separados, sino una estructura continua en la que la exposición digital general actuó como fuente dominante de variabilidad, complementada por patrones asociados al sueño, al night scrolling y al juego online.

En segundo lugar, la explicación de Anxiety_Score fue moderada y muy similar en MLR, PCR y PLS, lo que indica que el bloque de hábitos contiene señal útil pero limitada para predecir ansiedad. No obstante, el PLS fue el enfoque más completo desde el punto de vista del trabajo, porque permitió concentrar la relación relevante en pocas dimensiones latentes y mostrar con claridad que el patrón más asociado a mayor ansiedad combina menos horas de sueño, mayor scrolling nocturno y mayor exposición digital. La MLR reducida resultó una referencia útil en el espacio original, mientras que el PCR tuvo sobre todo interés comparativo.

En tercer lugar, el análisis del bloque psicológico mostró una estructura mucho más nítida. El riesgo de burnout se organizó principalmente a lo largo de un gradiente de bienestar frente a malestar psicológico, donde ansiedad y fatiga emocional se oponen a bienestar, motivación, calidad del sueño y estabilidad emocional.

El PLS-DA reducido resumió esta discriminación en una única componente interpretable, confirmando que la mayor parte de la información útil del problema se concentra en una sola dirección latente. Desde el punto de vista clasificatorio, el modelo PLS-DA mostró buen comportamiento para las clases High y Medium, pero presentó limitaciones en la clase Low, lo que debe interpretarse en el contexto del desbalance muestral y del solapamiento existente entre perfiles psicológicos favorables e intermedios. Por ello, su principal fortaleza en este estudio no fue maximizar la precisión, sino ofrecer una representación clara y diagnóstica del continuo psicológico asociado al burnout.

Finalmente, la comparación con Random Forest puso de manifiesto una diferencia metodológica importante: cuando el objetivo es puramente predictivo, un modelo no lineal puede explotar mejor la estructura de los datos y alcanzar rendimientos muy superiores; sin embargo, cuando el interés se centra en comprender qué variables sostienen la discriminación y cómo se organiza el problema en el espacio latente, el PLS-DA ofrece una ventaja clara de interpretabilidad. En consecuencia, el trabajo respalda el uso complementario de ambos enfoques: variables latentes para comprender y diagnosticar la estructura del fenómeno, y modelos no lineales como referencia de techo predictivo.

Como limitación principal, debe tenerse en cuenta que el análisis se realizó sobre una base de datos observacional, por lo que las relaciones identificadas deben interpretarse como asociaciones multivariantes y no como efectos causales. Además, la clase Low presentó una representación muestral muy inferior a las clases Medium y High, lo que condicionó especialmente el rendimiento del PLS-DA en dicha categoría. Por último, el rendimiento casi perfecto del Random Forest debe valorarse con cautela, ya que la importancia por permutación mostró un papel dominante de Wellbeing_Index. Como trabajo futuro, sería recomendable validar estos resultados en una muestra externa y analizar modelos adicionales sin variables resumen globales, con el fin de comprobar si la discriminación del riesgo de burnout se mantiene a partir de variables psicológicas más específicas.

5. Bibliografia

- Brereton, R. G., & Lloyd, G. R. (2014). Partial least squares discriminant analysis: taking the magic away. *Journal of Chemometrics*, 28(4), 213-225.
- Blakemore, S. J. (2019). Adolescence and mental health. *The lancet*, 393(10185), 2030-2031.
- Breiman, L. (2001). Random forests. *Machine learning*, 45(1), 5-32.
- Jolliffe, I. (2025). Principal Component Analysis. In *International Encyclopedia of Statistical Science* (pp. 1945-1948). Berlin, Heidelberg: Springer Berlin Heidelberg.
- Kieling, C., Baker-Henningham, H., Belfer, M., Conti, G., Ertem, I., Omigbodun, O., ... & Rahman, A. (2011). Child and adolescent mental health worldwide: evidence for action. *The lancet*, 378(9801), 1515-1525.
- Keles, B., McCrae, N., & Grealish, A. (2020). A systematic review: the influence of social media on depression, anxiety and psychological distress in adolescents. *International journal of adolescence and youth*, 25(1), 79-93.
- MacQueen, J. (1967). Multivariate observations. In *Proceedings of the 5th Berkeley symposium on mathematical statistics and probability* (Vol. 1, pp. 281-297). Oakland, CA, USA: University of California press.
- Wold, S., Sjöström, M., & Eriksson, L. (2001). PLS-regression: a basic tool of chemometrics. *Chemometrics and intelligent laboratory systems*, 58(2), 109-130.

6. Anexos

Anexo A. Comparación exploratoria mediante K-means sobre el espacio PCA del bloque de hábitos

Con el fin de completar el análisis exploratorio del bloque de hábitos de vida, se aplicó adicionalmente un algoritmo K-means sobre el subespacio de *scores* retenido por el modelo PCA. Esta comparación se incluyó porque formaba parte del planteamiento inicial del trabajo y permitía comprobar si, además del gradiente continuo identificado por las componentes principales, existían agrupamientos naturales de individuos según su estilo de vida. En particular, se buscó valorar en qué medida las particiones obtenidas se correspondían con las direcciones principales del PCA y con distintos niveles de Anxiety_Score.

La partición se evaluó sobre las cuatro componentes retenidas por validación cruzada en el PCA de hábitos. Se compararon varias soluciones con distinto número de grupos ($K = 2, 3, 4, 5, 6$), utilizando criterios internos de partición únicamente como apoyo técnico para seleccionar una solución razonable, sin convertir dichos índices en el centro de la interpretación.

Tabla 11. Comparación de las particiones K-means evaluadas sobre el espacio PCA del bloque de hábitos

K	Inercia	Silhouette	Calinski_Harabasz
2	7715,226	0,214	650,478
6	4951,030	0,180	432,138
3	6781,946	0,177	511,649
5	5436,618	0,176	446,184
4	6042,880	0,176	466,596

La solución más simple y coherente correspondió a $K = 2$. Aunque esta partición presentó los mejores valores relativos de calidad interna entre las soluciones evaluadas, su interés principal no radicó en ese resultado numérico, sino en su interpretación geométrica. Al proyectar los clústeres sobre el plano PC1–PC2, se observó que la separación se producía esencialmente a lo largo de la primera componente principal, mientras que, en planos posteriores como PC3–PC4, el solapamiento entre grupos seguía siendo elevado. Por ello, K-means no reveló una organización nueva claramente diferenciada, sino que reprodujo de forma más rígida el gradiente principal ya identificado por el PCA.




Figura 48. Representación de la partición K-means seleccionada ($K = 2$) en el espacio PCA del bloque de hábitos, mostrando su separación principal en PC1–PC2 y el elevado solapamiento en PC3–PC4.

Esta lectura resultó coherente con la interpretación previa del PCA. La primera componente ya había puesto de manifiesto un eje dominante de uso digital general, fuertemente asociado a `Daily_Social_Media_Hours` y `Screen_Time_Hours`. De hecho, los dos clústeres obtenidos se diferenciaron sobre todo en esas variables: uno de ellos presentó valores medios claramente superiores de `Daily_Social_Media_Hours` y `Screen_Time_Hours`, mientras que el otro concentró niveles más bajos de exposición digital. En cambio, variables como `Online_Gaming_Hours`, `Exercise_Frequency_per_Week` o `Caffeine_Intake_Cups` apenas contribuyeron a generar una separación adicional entre grupos. Por tanto, la partición no definió perfiles complejos y multidimensionales de estilo de vida, sino una segmentación relativamente simple a lo largo del eje principal ya resumido por PC1.




Figura 49. Distribución de Anxiety_Score por clúster en la partición seleccionada

Desde el punto de vista de la ansiedad, los clústeres mostraron diferencias moderadas, pero no una separación nítida. El grupo con mayor exposición digital presentó un valor medio de `Anxiety_Score` algo superior al del grupo con menor exposición, pero la distribución de la variable en ambos clústeres siguió mostrando un solapamiento considerable. Este resultado sugiere que la relación entre hábitos de vida y ansiedad no se organiza de forma natural en grupos bien separados, sino más bien como un gradiente continuo. En otras palabras, K-means captó una diferencia media coherente con la dirección principal del PCA, pero no puso de manifiesto tipologías claramente diferenciadas de ansiedad.

En paralelo, este comportamiento encajó bien con lo observado posteriormente en el modelo PLS (Sección 3.2.2. Modelización de la ansiedad a partir de los hábitos de vida mediante PLS) para `Anxiety_Score`. Mientras que K-means, como técnica no supervisada, buscaba posibles agrupamientos naturales dentro del bloque de hábitos, el PLS permitió identificar directamente qué direcciones de variación de dicho bloque estaban más relacionadas con la ansiedad. En ambos casos, la conclusión de fondo fue similar: no apareció una estructura de individuos organizada en grupos discretos y bien separados, sino un patrón más continuo, dominado por la exposición digital y matizado por variables como el night scrolling y las horas de sueño. Por ello, K-means no aportó una segmentación nueva de especial relevancia, pero sí reforzó la interpretación posterior obtenida mediante PLS.

Anexo B. Reducción progresiva del modelo de MLR para `Anxiety_Score`

Con el fin de documentar de forma completa el proceso de simplificación del modelo de regresión lineal múltiple ajustado para `Anxiety_Score`, en este anexo se recoge la secuencia de modelos evaluados durante la reducción progresiva del bloque de predictores. En cada etapa se eliminó

una variable con escasa contribución individual y se valoró el efecto de dicha eliminación sobre la capacidad explicativa y predictiva del modelo.

Este material se presenta como información complementaria al texto principal, donde únicamente se discuten el modelo completo y el modelo reducido final seleccionados.

Tabla 12. Proceso de reducción progresiva del modelo MLR para Anxiety_Score.

Modelo	Variables eliminadas	Nº variables	R^2_Y	Q^2_Y
M1	Ninguna	8	0.3160	0.3093
M2	Screen_Time_Hours	7	0.3160	0.3101
M3	Online_Gaming_Hours	6	0.3159	0.3108
M4	Exercise_Frequency_per_Week	5	0.3158	0.3112
M5	Caffeine_Intake_Cups	4	0.3156	0.3118
M6	Study_Work_Hours_per_Day	3	0.3153	0.3126

Como puede observarse, la eliminación progresiva de predictores no produjo una pérdida apreciable de rendimiento. Por el contrario, el valor de Q^2_Y mostró una ligera mejora a medida que el modelo se simplificaba, lo que respaldó la elección de la versión reducida final por criterios de parsimonia e interpretabilidad.

Anexo C. Resultados del Random Forest clasificatorio

Con el fin de documentar de forma completa la comparación entre el modelo PLS-DA y un clasificador no lineal, en este anexo se recogen los resultados detallados del modelo Random Forest ajustado sobre el bloque de variables psicológicas. Se incluyen los parámetros utilizados, los indicadores de ajuste y predicción, las métricas globales y por clase, las matrices de confusión, las curvas ROC y la importancia por permutación de las variables. Este último análisis permite valorar hasta qué punto el excelente rendimiento predictivo del modelo está condicionado por la presencia de Wellbeing_Index.

Tabla 13. Parámetros del modelo Random Forest.

Parámetro	Valor
Max depth	50
Min samples split	0,010
Min samples leaf	0,005
Max samples	1,000
Max features	1,000

El modelo se ajustó con los parámetros mostrados en la Tabla 13 manteniendo una configuración estable y suficientemente flexible como para capturar posibles relaciones no lineales entre predictores y clases de burnout.




Figura 50. Resumen global del modelo Random Forest: valores de R^2 y Q^2 en la matriz respuesta y gráfico Obs vs Pred para una de las variables dummy de burnout.

Los resultados de la Figura 50 y la Figura 51 muestran que el modelo Random Forest alcanza un ajuste y una capacidad predictiva extraordinariamente altos, con valores de R^2 y Q^2 próximos a 1. La proximidad entre ambos indicadores sugiere que el excelente rendimiento del modelo no se limita al ajuste sobre los datos observados, sino que se mantiene también en validación cruzada.

RF	M2	-M1-M0
Info		
Type	RF	
A	1	
N	2064	
K	8	
R2	0.9968	
Q2	0.9888	

Figura 51. Indicadores globales del modelo Random Forest obtenidos en Dragonet, incluyendo el número de observaciones (N), el número de variables (K) y los valores de R^2 y Q^2 asociados al ajuste y a la validación cruzada del modelo.

Tabla 14. Métricas globales del modelo Random Forest obtenidas mediante validación cruzada

Accuracy	Balanced accuracy	Precision macro	Recall macro	F1 macro	F1 weighted	Cohen kappa	MCC	AUROC macro (OVR)	AUROC weighted (OVR)	AUROC macro (OVO)
0,997	0,993	0,993	0,993	0,993	0,997	0,994	0,994	1,000	1,000	1,000

Tabla 15. Métricas por clase del modelo Random Forest.

Clase	Precision	Recall	F1	Support	AUROC (OVR)	Brier
Low	0,984	0,984	0,984	64	1,000	0,001
Medium	0,997	0,996	0,996	1000	1,000	0,002
High	0,997	0,998	0,998	1000	1,000	0,001

La Tabla 14 y la Tabla 15 confirman el comportamiento casi perfecto del modelo. El rendimiento se mantuvo muy elevado para las tres clases, tanto en términos globales como en el análisis por clase, con valores de precisión, recall, F1 y AUROC cercanos a 1. Este resultado refuerza la idea de que el bloque psicológico contiene una separación entre clases muy marcada cuando se explota mediante un modelo no lineal suficientemente flexible.




Figura 52. Matrices de confusión absoluta y normalizada del modelo Random Forest en el conjunto test.

La Figura 52. Matrices de confusión absoluta y normalizada del modelo Random Forest en el conjunto test. muestra que el modelo Random Forest alcanza un rendimiento clasificatorio muy elevado sobre el conjunto test, lo que refuerza la idea de que su buen comportamiento no se debe únicamente al ajuste sobre los datos de entrenamiento. La matriz de confusión absoluta evidencia un número muy reducido de errores, mientras que la matriz normalizada confirma que las tres clases de burnout quedan identificadas con gran precisión. En particular, la clase Low, que resultaba especialmente problemática en el PLS-DA por su baja representación muestral, queda mucho mejor delimitada en el Random Forest. En conjunto, estos resultados ponen de manifiesto una clara superioridad del modelo no lineal en términos de clasificación, aunque esta superioridad debe interpretarse junto con el análisis de importancia por permutación.




Figura 53. Curvas ROC one-vs-rest del modelo Random Forest para las tres clases de burnout.

La Figura 53 complementa la información de la matriz de confusión mostrando la capacidad discriminante del modelo para cada clase frente al resto al variar el umbral de decisión. Las áreas bajo la curva ROC (AUROC) resultaron prácticamente iguales a 1 en las tres categorías, lo que indica una separabilidad excelente entre clases. Este comportamiento confirma que el Random Forest no solo clasifica correctamente la gran mayoría de las observaciones, sino que además lo hace con una discriminación muy robusta a lo largo de distintos umbrales. Por tanto, desde el punto de vista predictivo, el modelo ofrece un rendimiento claramente superior al del PLS-DA.




Figura 54. Importancia por permutación de las variables del bloque psicológico en el modelo Random Forest completo

La Figura 54 muestra que, en el modelo Random Forest ajustado con todas las variables psicológicas, la capacidad predictiva se concentra de forma muy acusada en Wellbeing_Index. La permutación de esta variable provoca una caída muy marcada del rendimiento, mientras que el resto apenas modifica la balanced accuracy del clasificador.

Este resultado indica que el rendimiento casi perfecto del Random Forest debe interpretarse con cautela, ya que una parte muy importante de su capacidad discriminante parece concentrarse en una variable resumen de bienestar global. Por tanto, aunque el modelo constituye una referencia predictiva muy potente, su superioridad frente al PLS-DA no debe interpretarse únicamente como consecuencia de una mejor modelización de relaciones complejas, sino también como efecto de la elevada capacidad discriminante de Wellbeing_Index.