UNIVERSITAT POLITÈCNICA DE VALÈNCIA

MÁSTER UNIVERSITARIO EN INGENIERÍA DE ANÁLISIS DE DATOS, MEJORA DE PROCESOS Y TOMA DE DECISIONES

EL MULTIVERSO DE LOS DATOS

Rafael Macian Castilla **José Ramón Mena Pérez**

Patricia Rodrigo Barrio **Víctor Rodríguez Albendea**

Asignatura: Análisis Multivariante **Curso: 2025/2026**

Contenido del trabajo

1. Introducción 3
2. Objetivos del trabajo 5
3. Datos 6
4. Metodología estadística 8
   4.1. Herramientas y entorno de análisis 8
   4.2. Análisis de Componentes Principales (PCA) 9
   4.3. Análisis de Correspondencias Múltiples (MCA) 10
   4.4. Análisis Discriminante Lineal (LDA) 11
5. Resultados y discusión 12
   5.1. Análisis de Componentes Principales (PCA) 12
   5.2. PCA combinado con análisis de regresión 15
   5.3. Análisis de Correspondencias Múltiples (MCA) 20
   5.4. MCA combinado con análisis de conglomerados (k-means y jerárquico) 23
   5.5. Análisis Discriminante Lineal 27
6. Conclusiones 31
7. Referencias 32
8. Anexos 33

1. Introducción

El presente estudio se basa en el dataset '*Medical Insurance Cost Prediction'* publicado en *Kaggle*, que recopila información detallada sobre aproximadamente 100.000 individuos asegurados y sus costos médicos. Cada observación del conjunto de datos corresponde a un individuo con seguro médico privado, descrito mediante decenas de variables que abarcan diversos aspectos de su perfil.

Según la descripción proporcionada en *Kaggle*, el dataset incluye datos demográficos, socioeconómicos, condiciones de salud, hábitos de vida, uso de servicios sanitarios, detalles de la póliza de seguro y los costes asociados a la atención médica. Aunque el conjunto de datos no especifica expresamente su país de origen ni incluye una fuente institucional concreta, el uso de términos como *deductible* (deducible) y *copay* (copago) sugiere que está inspirado en un sistema sanitario similar al estadounidense. Todo apunta a que se trata de un conjunto de datos simulado o sintético, elaborado con valores plausibles y realistas para su uso con fines educativos. Además, la ausencia de valores perdidos refuerza la idea de que ha sido construido de manera controlada para facilitar el análisis estadístico.

En total, el dataset contiene 54 variables registradas por individuo, agrupadas en seis bloques temáticos principales:

- **Demografía y situación socioeconómica**: información básica del asegurado: edad, sexo, región geográfica, ámbito urbano/rural, ingreso anual, nivel educativo, estado civil, situación laboral, tamaño familiar y número de dependientes.

- **Estilo de vida**: hábitos que pueden incidir en la salud: índice de masa corporal (IMC), consumo de tabado (*smoker*) y frecuencia de consumo de alcohol.

- **Salud y estado clínico**: antecedentes y parámetros médicos: presencia de enfermedades crónicas (hipertensión, diabetes, asma, etc.), historial de enfermedades graves (ej. enfermedad cardiovascular, cáncer), indicadores clínicos (presión arterial sistólica/diastólica, colesterol LDL, hemoglobina glicosilada *HbA1c*), un riesgo sanitario global cuantificado (*risk_score*) y una etiqueta de paciente de alto riesgo (*is_high_risk*).

- **Utilización de servicios sanitarios**: uso reciente de la atención médica: número de visitas médicas en el último año, hospitalizaciones en los últimos 3 años (y días totales hospitalizado), cantidad de medicamentos prescritos, y recuentos de distintos procedimientos recibidos (imágenes diagnósticas, cirugías, fisioterapia, consultas especializadas, pruebas de laboratorio), así como si el paciente tuvo algún procedimiento mayor (*had_major_procedure*).

- **Seguro y características de la póliza**: detalles del plan de seguro de salud: tipo de plan contratado (*plan_type*, por ejemplo básico, premium), nivel de la red sanitaria (*network_tier*), importe del deducible anual, copago medio por servicio (*copay*), duración de la póliza en años, número de cambios de póliza en los últimos 2 años, y una evaluación de la calidad del proveedor (escala ordinal).

- **Costes médicos y reclamaciones**: resultados económicos: gasto médico anual total del individuo (*annual_medical_cost*), prima anual y prima mensual del seguro, número de reclamaciones (*claims_count*) presentadas en el año, coste promedio por reclamación (*avg_claim_amount*) y total abonado por la aseguradora en reclamaciones (*total_claims_paid*).

Este amplio conjunto de variables multidimensionales convierte al dataset en un caso de estudio idóneo para el análisis multivariante. Por un lado, permite investigar relaciones entre múltiples factores: por ejemplo, cómo la edad, las comorbilidades y los hábitos de vida se combinan para influir en el coste sanitario, o cómo ciertos perfiles de pacientes se asocian a mayores reclamaciones. Por otro lado, la alta dimensionalidad (con varias decenas de variables tanto numéricas como categóricas) plantea la necesidad de aplicar técnicas de reducción de dimensión y de identificación de patrones latentes.

En este trabajo se aprovechará esta riqueza de datos para aplicar técnicas estadísticas multivariantes aprendidas, como análisis de componentes principales (PCA), análisis factorial, *cluster analysis* o modelos de regresión multivariada, con el doble objetivo de extraer conocimiento significativo sobre los factores determinantes del coste médico y de ilustrar el valor práctico de dichas técnicas en un contexto realista. Así, la introducción de este caso práctico no solo contextualiza el problema de predicción de costes médicos, sino que también justifica su selección con fines didácticos: ofrece la oportunidad de poner en práctica métodos avanzados sobre un conjunto de datos complejo y verosímil, preparando al estudiante para enfrentarse a análisis de big data sanitarios en entornos profesionales.

2. Objetivos del trabajo

Objetivo general

Analizar y modelizar el coste médico anual de los asegurados mediante técnicas de análisis multivariante, con el fin de identificar las principales dimensiones latentes que estructuran la información, caracterizar perfiles diferenciados de asegurados y evaluar la capacidad discriminante de variables clínicas, económicas y de utilización del seguro en la clasificación de individuos según su nivel de coste.

Objetivos específicos

1. Explorar y sintetizar la información contenida en un conjunto amplio de variables económicas, contractuales y de utilización del seguro mediante técnicas de reducción de dimensionalidad, identificando las principales componentes latentes que explican la variabilidad del sistema.

2. Evaluar la utilidad del Análisis de Componentes Principales (PCA) como herramienta para reducir la multicolinealidad entre variables explicativas y como base para la construcción de modelos de regresión del coste médico anual, comparando su rendimiento con modelos basados en variables originales.

3. Analizar la estructura de asociación entre variables categóricas relacionadas con el perfil clínico, los hábitos de consumo y la situación personal de los asegurados mediante el Análisis de Correspondencias Múltiples (MCA), identificando patrones de proximidad y oposición entre categorías.

4. Reforzar la interpretación del MCA mediante técnicas de clustering, aplicadas sobre las coordenadas factoriales, con el objetivo de identificar conglomerados estables y homogéneos de categorías que faciliten la caracterización de perfiles de comportamiento.

5. Construir y evaluar modelos de clasificación supervisada mediante Análisis Discriminante Lineal (LDA) para discriminar a los asegurados en grupos de bajo, medio y alto coste, definidos a partir de terciles del coste médico anual.

6. Comparar modelos discriminantes completos y parsimoniosos, evaluando el impacto de procedimientos de selección de variables (stepwise) sobre la capacidad clasificatoria, la estabilidad del modelo y su interpretabilidad.

7. Extraer conclusiones integradas a partir de la combinación de técnicas descriptivas, exploratorias y predictivas, destacando el valor del enfoque multivariante para el estudio del coste sanitario en contextos con alta dimensionalidad y heterogeneidad de variables.

3. Datos

El conjunto de datos analizado contiene información detallada correspondiente a 100.000 individuos asegurados en un sistema sanitario de tipo privado. Está compuesto por un total de 54 variables, organizadas en seis bloques temáticos:

- **Demografía y situación socioeconómica**
- **Estilo de vida y hábitos**
- **Estado clínico y condiciones de salud**
- **Utilización de servicios sanitarios y procedimientos**
- **Características de la póliza de seguro**
- **Costes médicos y reclamaciones**

Las variables incluidas abarcan distintas escalas de medida:

- **Numéricas continuas**, como ingresos, medidas clínicas o costes asociados a la atención sanitaria.
- **Numéricas discretas**, como número de personas en el hogar, visitas médicas o procedimientos realizados.
- **Categóricas nominales**, como el sexo, la región de residencia o el tipo de plan de seguro.
- **Categóricas ordinales**, como el nivel educativo o la frecuencia de consumo de alcohol.
- **Categóricas binarias**, como la presencia o ausencia de determinadas condiciones de salud o eventos médicos.

Para una mejor comprensión, en el Anexo 1 se presenta una tabla descriptiva con el nombre original de cada variable y una descripción sobre lo que indica cada una de ellas.

A continuación, se presenta un resumen estadístico (Tabla 12. Estadísticos descriptivos de las variables) de las variables del análisis, incluyendo medidas de tendencia central y dispersión (media, mediana, desviación estándar, mínimo y máximo), así como indicadores de forma de la distribución (asimetría *skewness* y curtosis). Este resumen también se encuentra situado en el Anexo 1.

El conjunto de datos no presenta valores perdidos ni inconsistencias aparentes, lo que permite aplicar directamente técnicas estadísticas multivariantes sin necesidad de imputación ni depuración adicional. La amplitud, heterogeneidad y estructura clara de la base de datos la convierte en un escenario idóneo para emplear métodos como análisis de componentes principales, análisis factorial, análisis discriminante o análisis de conglomerados, con el objetivo de identificar patrones latentes y relaciones entre múltiples variables interrelacionadas.

Tras la caracterización general del dataset, se llevó a cabo un análisis descriptivo inicial con el fin de examinar la distribución de las variables y comprobar la adecuación del conjunto de datos para las técnicas multivariantes que se aplicarán posteriormente. Dado el elevado número de variables y la diversidad de escalas presentes (continuas, discretas, categóricas y binarias), las representaciones gráficas completas se incluyen en el Anexo 2, a fin de no sobrecargar el cuerpo principal del documento.

Las variables continuas presentan, en general, distribuciones aproximadamente simétricas en aquellas relacionadas con características fisiológicas (edad, presión arterial, colesterol LDL, índice de masa corporal). Por el contrario, las variables vinculadas al gasto sanitario y a la utilización económica del sistema (coste médico anual, primas del seguro, ingresos, importe medio por reclamación, total reclamado) muestran una asimetría positiva marcada, un patrón típico en datos económico-sanitarios, donde la mayoría de los individuos concentra valores bajos y un subconjunto reducido acumula valores extremos. En cambio, las variables discretas reflejan, de manera consistente, recuentos muy concentrados en valores bajos (principalmente 0, 1 o 2 eventos), lo cual es característico de datos relacionados con utilización de servicios sanitarios: visitas médicas, procedimientos realizados o episodios hospitalarios. La presencia de colas largas hacia valores elevados indica casos menos frecuentes, pero clínicamente relevantes.

Las variables categóricas presentan distribuciones equilibradas y sin anomalías: mayor proporción de población urbana, predominio de niveles educativos intermedios y una distribución razonable entre los tipos de plan de seguro (PPO, HMO, EPO y POS). También se observan patrones esperables en estado civil, situación laboral o hábitos de consumo.

Las prevalencias de las variables binarias son coherentes con lo descrito en la literatura para poblaciones aseguradas: valores moderados en patologías comunes (hipertensión, artritis) y prevalencias reducidas en condiciones graves o poco frecuentes (enfermedad renal, hepática, antecedente de cáncer). No presentan valores anómalos ni proporciones incompatibles con poblaciones amplias de seguros privados.

Por todo ello, el análisis descriptivo confirma que el dataset es consistente, completo y adecuado para los objetivos analíticos planteados en este trabajo.

4. Metodología estadística

El análisis se diseñó como un flujo multivariante integrado, adecuado a la elevada dimensionalidad del conjunto de datos y a la coexistencia de variables cuantitativas y cualitativas. Dado que la base no presenta valores perdidos ni inconsistencias estructurales relevantes, el preprocesado se centró en recodificaciones puntuales, cuando fue necesario, y en transformaciones de escala, con el objetivo de garantizar la comparabilidad entre variables y evitar distorsiones en los métodos posteriores.

El planteamiento metodológico se estructura en cuatro bloques complementarios y articulados entre sí:

1. Síntesis de información y detección de estructuras latentes mediante técnicas de reducción de dimensionalidad:
    a. Un primer PCA sobre variables económicas y contractuales para caracterizar la estructura del aseguramiento y del gasto.
    b. Un segundo PCA sobre variables clínicas y de riesgo para condensar el perfil de salud en unas pocas dimensiones latentes, que después se utilizarán en modelos de regresión.
2. Modelización explicativa del coste médico anual mediante regresión lineal, comparando:
    a. Un modelo directo basado en variables clínicas originales.
    b. Un modelo apoyado en las componentes principales del PCA clínico (PCA + regresión), con el fin de reducir multicolinealidad y evaluar el compromiso entre interpretabilidad y estabilidad de los estimadores.
3. Caracterización de perfiles cualitativos y segmentación de categorías a partir de análisis de correspondencias múltiples:
    a. Un primer MCA global que integra variables demográficas, clínicas, de utilización sanitaria y de coste, para identificar grandes perfiles sociosanitarios.
    b. Un segundo MCA focalizado sobre variables de hábitos de vida y estado civil, complementado con técnicas de agrupamiento (clustering jerárquico y k-means) aplicadas a las coordenadas factoriales, para refinar la lectura de los patrones de comportamiento.
4. Clasificación supervisada de asegurados según su nivel de coste mediante Análisis Discriminante Lineal (LDA), comparando modelos completos y parsimoniosos obtenidos mediante selección stepwise basada en la Lambda de Wilks y pruebas F parciales.

Este diseño metodológico permite abordar el fenómeno del coste sanitario desde perspectivas descriptivas, explicativas y predictivas dentro de un mismo marco analítico, garantizando la coherencia entre las distintas técnicas aplicadas y facilitando una interpretación integrada de los resultados.

4.1. Herramientas y entorno de análisis

Todos los análisis estadísticos se llevaron a cabo utilizando el lenguaje de programación Python, empleando librerías especializadas en análisis de datos y estadística multivariante. En particular, se utilizaron las bibliotecas pandas y numpy para la manipulación y gestión de los datos, scikit-learn para la implementación de los modelos de reducción de dimensionalidad, clasificación y agrupamiento, y prince para la realización del Análisis de Correspondencias Múltiples. Asimismo, se emplearon matplotlib y seaborn para la visualización gráfica de los resultados.

El uso de este entorno permitió garantizar la reproducibilidad de los procedimientos aplicados mediante scripts ejecutables y fácilmente documentables, así como integrar de forma coherente las distintas técnicas multivariantes dentro de un mismo flujo de trabajo.

4.2. Análisis de Componentes Principales (PCA)

El Análisis de Componentes Principales se empleó como técnica de reducción de la dimensionalidad sobre dos subconjuntos de variables cuantitativas continuas: (i) un bloque de variables económicas y de póliza, y (ii) un bloque de variables clínicas y de riesgo. En ambos casos, el objetivo fue resumir la variabilidad observada en un número menor de componentes ortogonales entre sí, obteniendo combinaciones lineales de las variables originales que concentran la mayor parte de la varianza total y facilitan la identificación de patrones globales y estructuras latentes en el conjunto de datos.

El PCA se aplicó sobre la matriz de datos previamente estandarizada mediante una transformación tipo z (centrado en la media y escalado por la desviación estándar), de modo que el análisis se efectuó sobre la matriz de correlaciones y no sobre la matriz de covarianzas. A partir de cada modelo se obtuvieron los autovalores y las proporciones de varianza explicada por componente, que se sintetizaron en tablas de resultados y gráficos de sedimentación (scree plots), utilizando como referencia el criterio de Kaiser (retención de componentes con autovalor mayor o igual que 1) y la inspección visual del punto de inflexión de la curva.

Adicionalmente, se calcularon las cargas o correlaciones entre las variables originales y las componentes principales (matrices de loadings), que se emplearon como base para la interpretación de las dimensiones latentes identificadas, distinguiendo explícitamente entre ejes de naturaleza económica y ejes de naturaleza clínica.

4.2.1. PCA combinado con análisis de regresión

Para analizar la relación existente entre el perfil de salud de los individuos y su coste médico anual, se combinó el PCA clínico con un modelo de regresión lineal. Dado que las variables de salud presentan una fuerte colinealidad (por ejemplo, entre indicadores cardiovasculares, metabólicos y de riesgo agregado), el PCA se utilizó para transformar el conjunto original en un número reducido de componentes ortogonales, obteniendo predictores no correlacionados y estimaciones más estables de los coeficientes del modelo de regresión.

El procedimiento consistió en aplicar un PCA al subconjunto de variables relacionadas con el estado de salud y seleccionar las primeras cuatro componentes principales, en función de la varianza explicada acumulada y del criterio de Kaiser, asegurando una representación adecuada de la estructura clínica subyacente. Estas cuatro componentes se utilizaron posteriormente como variables explicativas en un modelo de regresión lineal con el coste médico anual como variable dependiente, lo que permitió evaluar la significación individual de cada dimensión latente y la significación global del modelo.

De forma complementaria, se planteó una segunda estrategia basada en utilizar directamente, como regresores, aquellas variables originales con mayor peso en cada componente principal identificada, con el fin de comparar un enfoque más interpretable (variables observables) frente a otro más estable desde el punto de vista estadístico (componentes). La comparación entre ambos enfoques permitió analizar el compromiso entre interpretabilidad, presencia de multicolinealidad y capacidad explicativa del modelo de coste sanitario.

4.3. Análisis de Correspondencias Múltiples (MCA)

El Análisis de Correspondencias Múltiples se utilizó como técnica multivariante exploratoria orientada al estudio conjunto de variables categóricas, representando en un espacio factorial de dimensión reducida las asociaciones entre categorías de distintas variables cualitativas. Bajo este enfoque, categorías que tienden a aparecer conjuntamente quedan próximas en el plano factorial, mientras que aquellas con patrones de ocurrencia diferenciados aparecen alejadas, lo que permite detectar estructuras latentes y describir perfiles característicos dentro de la población analizada.

Se diseñaron dos aplicaciones complementarias del MCA. En primer lugar, se construyó un MCA global a partir de un conjunto de variables activas que combinan información demográfica, clínica, de utilización sanitaria, hábitos de vida y resultado económico agregado. Las variables incluidas fueron: *grupo_edad*, *patologias_cronicas*, hospitalizado, *had_major_procedure*, *is_high_risk*, *smoker* y *grupo_coste*. Dentro de este conjunto, algunas variables ya eran cualitativas (por ejemplo, *smoker* o las binarias de riesgo/procedimiento), mientras que otras procedían de variables cuantitativas que se categorizaron para hacerlas compatibles con el método:

- Edad (age → grupo_edad): se definieron tres tramos coherentes con etapas vitales y perfiles típicamente diferenciados de utilización sanitaria: joven (<24), adulto (24–65) y mayor (>65).
- Carga de cronicidad (chronic_count → patologias_cronicas): se recodificó en ninguna (0 crónicas) y alguna (≥1 crónica), capturando de forma simple la presencia de enfermedad crónica.
- Hospitalización (hospitalizations_last_3yrs → hospitalizado): se recodificó en no (0 ingresos en 3 años) y sí (≥1 ingreso en 3 años), como indicador directo de episodios clínicos relevantes.
- Coste anual (annual_medical_cost → grupo_coste): se definieron tres niveles bajo_coste (<3.000), medio_coste (3.000–7.000) y alto_coste (>7.000). Esta elección se realizó con un enfoque sustantivo e interpretable (evitando una partición puramente por cuantiles), apoyándose en referencias de distribución de gasto sanitario en población asegurada en Estados Unidos en el año de creación de la base de datos [2], para diferenciar perfiles de bajo, medio y alto coste de manera directamente comunicable.

En segundo lugar, se ajustó un MCA focalizado sobre variables de hábitos y estado civil (*marital_status*, *smoker, alcohol_freq*), orientado a estudiar con mayor resolución los patrones de asociación específicos entre comportamiento de consumo y situación personal.

En ambos casos, el procedimiento se implementó en Python mediante la librería prince, construyendo la matriz disyuntiva completa (codificación *one-hot*) y obteniendo autovalores, porcentaje de inercia explicado y coordenadas factoriales de las categorías. La interpretación se centró en las dos primeras dimensiones, por ser las que concentran mayor inercia y permitir una representación bidimensional clara, cuyos resultados se desarrollan posteriormente en la sección de Resultados y discusión.

4.3.1. MCA combinado con análisis de conglomerados (k-means)

En este MCA focalizado se trabajó específicamente con las variables categóricas *marital_status*, *smoker* y *alcohol_freq*. Previamente se prepararon los datos realizando recodificaciones para compactar categorías: en *marital_status* se integró *Divorced* dentro de *Single* y *Widowed* dentro de *Married*, y en *alcohol_freq* se agrupó *Daily* dentro de *Weekly,* con el fin de evitar categorías con frecuencias muy reducidas y mejorar la estabilidad del análisis.

Sobre las coordenadas factoriales de las categorías en el plano definido por las dos primeras dimensiones del MCA, se realizó un análisis de conglomerados en dos etapas: primero, un clustering jerárquico con criterio de Ward para identificar un número razonable de grupos, y después un algoritmo k-means fijando ese número de conglomerados para estabilizar la partición. Las categorías se representaron finalmente coloreadas según su conglomerado en el mapa factorial, de modo que el agrupamiento actuara como apoyo visual a la interpretación de los perfiles de hábitos y estado civil.

4.4. Análisis Discriminante Lineal (LDA)

El Análisis Discriminante Lineal se empleó como técnica de clasificación supervisada para discriminar entre grupos de asegurados definidos en función de su coste médico anual. Con este fin, se construyó previamente una variable categórica de respuesta que segmenta el coste anual en tres grupos ordenados (bajo, medio y alto), utilizando una partición en cuantiles con frecuencias aproximadamente iguales, de modo que cada categoría contuviera un número similar de observaciones.

Como predictores se consideró un conjunto de variables numéricas de carácter clínico, económico y de utilización de servicios sanitarios, seleccionadas por su relevancia potencial en la explicación del nivel de coste. Antes de ajustar el modelo discriminante, todas las variables explicativas se estandarizaron mediante una transformación tipo z (centrado en la media y escalado por la desviación estándar), de forma que el análisis se realizase sobre variables comparables en escala y se evitase que diferencias de magnitud influyeran de manera desproporcionada en las funciones discriminantes.

El modelo discriminante completo se estimó mediante un LDA clásico, obteniéndose un conjunto de funciones lineales que maximizan la separación entre los grupos definidos por la variable de coste. A partir de este modelo se derivaron las puntuaciones discriminantes individuales, la matriz de clasificación y las medidas de rendimiento global y por grupo, que se utilizarán posteriormente en la sección de resultados.

Adicionalmente, se aplicó un procedimiento de selección de variables por pasos (*stepwise*) con el objetivo de obtener un modelo más parsimonioso sin pérdida apreciable de capacidad discriminante. Este procedimiento se basó en la minimización sucesiva de la Lambda de Wilks y en la evaluación de pruebas F parciales, imponiendo umbrales mínimos de mejora ($\Delta\lambda$ y F) para la entrada de nuevas variables, de modo que solo se incorporasen predictores con contribución discriminante significativa y no redundante. El modelo reducido resultante se comparó posteriormente con el modelo completo en términos de rendimiento clasificatorio y simplicidad.

5. Resultados y discusión

En este apartado se presentan los resultados obtenidos tras la aplicación de las técnicas multivariantes descritas en la sección de Metodología Estadística. La exposición sigue el mismo orden metodológico, de modo que para cada técnica se resumen los resultados principales y se discuten sus implicaciones en relación con el coste sanitario y la caracterización de perfiles de asegurados.

5.1. Análisis de Componentes Principales (PCA)

Con el objetivo de reducir la dimensionalidad del conjunto de variables económicas, contractuales y de utilización del seguro, así como de identificar dimensiones latentes que estructuren la información, se aplicó un Análisis de Componentes Principales (PCA) sobre diez variables cuantitativas: *income, deductible, copay, policy_term_years, policy_changes_last_2yrs, annual_medical_cost, annual_premium, monthly_premium, avg_claim_amount* y *total_claims_paid*.

Dado que dichas variables presentan escalas de medida y órdenes de magnitud claramente diferentes, el análisis se llevó a cabo sobre la matriz de correlaciones (Anexo 3), previa estandarización de las variables originales mediante una transformación tipo z (media cero y desviación típica unitaria). De este modo se garantiza la comparabilidad entre variables y se evita que aquellas con mayor varianza dominen artificialmente la estructura de los componentes.

5.1.1. Varianza explicada y selección del número de componentes

La Tabla 1 recoge los valores propios asociados a cada componente principal, así como los porcentajes de varianza explicada y acumulada obtenidos en el PCA.

Tabla 1. Valores propios y varianza explicada por las componentes principales

Componente	Valor propio (λ)	% Varianza explicada	% Varianza acumulada
CP1	4.098	40.978	40.978
CP2	1.014	10.142	51.120
CP3	1.001	10.005	61.125
CP4	1.000	9.998	71.123
CP5	0.997	9.968	81.091
CP6	0.990	9.902	90.993
CP7	0.612	6.119	97.112
CP8	0.245	2.451	99.564
CP9	0.044	0.436	100.000
CP10	0.000	0.000	100.000

Como puede observarse, la primera componente principal (CP1) concentra una proporción muy relevante de la variabilidad total, explicando por sí sola el 40,978% de la varianza. La segunda componente (CP2) aporta un 10,142% adicional, de modo que las dos primeras componentes explican conjuntamente el 51,120% de la variabilidad total.

Las componentes tercera y cuarta presentan valores propios muy próximos a la unidad y contribuyen con un 10,005% y un 9,998% de varianza, respectivamente, alcanzándose un 71,123% de varianza acumulada con las cuatro primeras componentes. La concentración de varianza en la primera componente refleja la fuerte interdependencia entre las variables económicas del seguro: primas, importes reclamados y costes médicos se encuentran estrechamente ligados por la propia estructura del producto asegurador, de modo que un mayor gasto sanitario tiende a asociarse con primas más elevadas y mayores volúmenes de reclamaciones.

En lo referido al gráfico de sedimentación (Figura 1), este refuerza dicha interpretación, mostrando una caída pronunciada del valor propio tras la primera componente y una estabilización progresiva a partir de las siguientes. Asimismo, el criterio de Kaiser ($\lambda \geq 1$) sugiere la retención de las primeras componentes como las más relevantes desde el punto de vista informativo. No obstante, en este trabajo se opta por retener cuatro componentes principales, ya que permiten capturar dimensiones conceptualmente diferenciadas y relevantes, evitando que variables importantes queden insuficientemente representadas en el análisis.

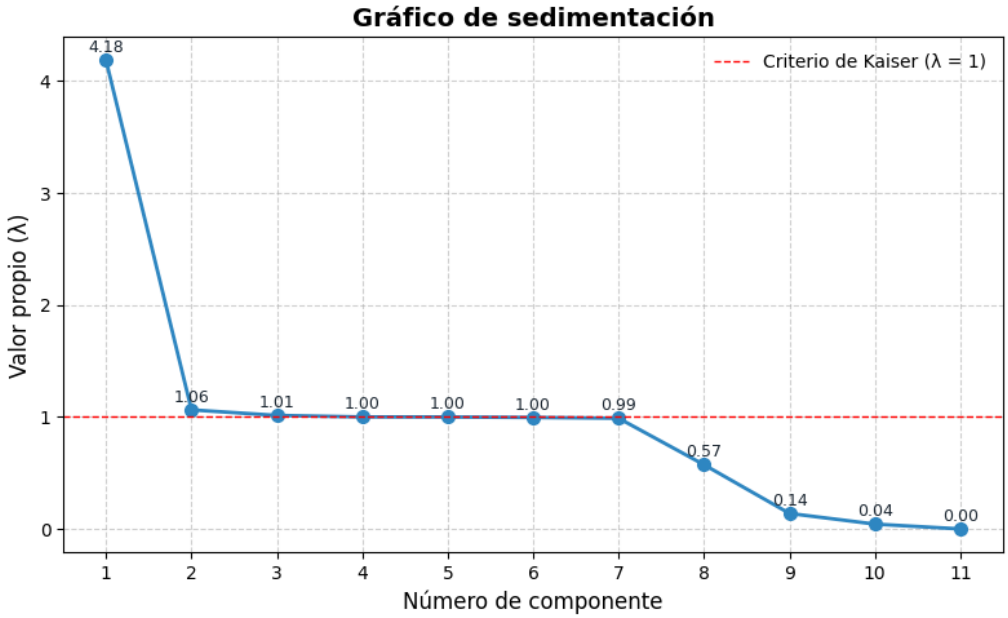

Figura 1. Gráfico de sedimentación

5.1.2. Interpretación de las componentes

La interpretación de las componentes se realiza a partir de las correlaciones entre las variables originales y las componentes principales, que se muestran en la Tabla 2 para las cuatro componentes retenidas.

Tabla 2. Correlaciones entre las variables originales y las componentes principales (CP1–CP4)

Variable	CP1	CP2	CP3	CP4
income	-0.007	0.413	0.637	0.339
deductible	0.009	0.617	0.259	-0.035
copay	0.004	-0.495	0.547	0.160
policy_term_years	0.002	0.285	-0.076	0.782
policy_changes_last_2yrs	0.000	-0.369	0.473	-0.497
annual_medical_cost	0.961	-0.002	-0.002	-0.001
annual_premium	0.959	0.016	0.005	-0.003
monthly_premium	0.959	0.016	0.005	-0.003
avg_claim_amount	0.777	-0.020	-0.005	0.004
total_claims_paid	0.856	-0.015	-0.005	0.004

- Primera componente principal (CP1): Carga económica / coste sanitario

La primera componente presenta correlaciones muy elevadas y positivas con *annual_medical_cost* (0.961), *annual_premium* (0.959), *monthly_premium* (0.959), *avg_claim_amount* (0.777) y *total_claims_paid* (0.856), mientras que el resto de variables muestran cargas prácticamente nulas en esta dimensión.

Este patrón indica que la CP1 resume un eje claramente económico, asociado al nivel global de gasto sanitario, primas y volumen económico de los siniestros. Valores elevados en esta componente caracterizan perfiles de asegurados con mayores costes médicos y mayor impacto financiero para la aseguradora.

- Segunda componente principal (CP2): Tipo de póliza (copago frente a deducible)

La segunda componente está dominada por *deductible* (0.617) y *copay* (–0.495), con contribuciones adicionales de *income* (0.413) y *policy_changes_last_2yrs* (–0.369).

Esta estructura diferencia entre pólizas basadas en deducibles elevados y pólizas con mayor peso del copago, y sugiere que esta elección está relacionada tanto con el perfil económico del asegurado como con su comportamiento contractual reciente. En esta dimensión, el foco recae en la estructura del diseño de la póliza (predominio relativo de deducible frente a copago), más que en el nivel de ingresos en sí mismo, que actúa como modificador secundario del patrón observado.

- Tercera componente principal (CP3): Nivel socioeconómico

La tercera componente presenta cargas elevadas en *income* (0.637), *copay* (0.547), *policy_changes_last_2yrs* (0.473) y, en menor medida, *deductible* (0.259). Esta combinación de variables permite interpretar la CP3 como una dimensión de perfil económico–contractual dinámico, en la que confluyen tanto el nivel de renta del asegurado como su intensidad de cambios recientes en la póliza y la estructura de pagos directos asociados al seguro.

- Cuarta componente principal (CP4): Estabilidad del contrato

La cuarta componente está claramente definida por *policy_term_years* (0.782) y *policy_changes_last_2yrs* (–0.497), mientras que el resto de variables presentan cargas reducidas.

Esta estructura identifica un eje de estabilidad contractual, diferenciando pólizas antiguas y estables frente a pólizas con cambios recientes. La CP4 resume, por tanto, el grado de antigüedad y estabilidad del contrato de seguro.

Por todo ello, las cuatro componentes retenidas permiten condensar la información en dimensiones interpretables: (1) carga económica y volumen de gasto (CP1), (2) diseño de póliza: deducible vs copago (CP2), (3) perfil económico–contractual (CP3) y (4) estabilidad del contrato (CP4). Esta síntesis resulta especialmente útil para describir patrones globales del aseguramiento y, al mismo tiempo, reduce la complejidad del análisis manteniendo la estructura esencial de variabilidad del sistema y proporciona un marco compacto para relacionar perfiles económicos de aseguramiento con los patrones de coste sanitario analizados en las secciones posteriores.

5.2. PCA combinado con análisis de regresión

En esta sección se presentan los resultados obtenidos a partir de los modelos de regresión lineal planteados con el objetivo de analizar y modelizar el coste médico anual de los individuos. La variable dependiente considerada es el gasto sanitario anual (annual_medical_cost), mientras que como variables explicativas se emplean, por un lado, distintos indicadores fisiológicos y clínicos seleccionados de forma directa y, por otro, componentes principales obtenidas a partir de un Análisis de Componentes Principales (PCA) aplicado sobre un conjunto más amplio de variables de salud. Estas variables recogen información relacionada con el riesgo cardiovascular, el control metabólico, la obesidad y otros parámetros fisiológicos relevantes, lo que permite evaluar en qué medida los distintos perfiles de salud se asocian con el nivel de gasto sanitario anual.

El análisis se orienta, por tanto, a identificar las dimensiones del estado de salud con mayor capacidad explicativa del coste médico y a comparar el comportamiento de los diferentes enfoques de modelización considerados, tanto desde el punto de vista interpretativo como metodológico.

Por último, la validación de los supuestos clásicos del modelo de regresión lineal, así como el análisis detallado de los residuos asociados a ambos modelos, se presenta de forma específica en el Anexo 7.

5.2.1. Varianza explicada y selección del número de componentes

En primer lugar, se analizó la varianza explicada por las componentes principales obtenidas, tal y como se observa en la Tabla 3. La primera componente principal explica aproximadamente un 35,7 % de la variabilidad total, mientras que la segunda y la tercera aportan un 14,7 % y un 12,6%, respectivamente. La cuarta componente contribuye con un 12,4 % adicional, de modo que las cuatro primeras componentes concentran en conjunto alrededor del 75,4 % de la variabilidad total. Estos resultados indican que una parte sustancial de la información original puede representarse adecuadamente mediante un número reducido de dimensiones latentes.

Tabla 3. Valores propios y varianza explicada por las componentes principales.

Componente	Valor propio (λ)	% Varianza explicada	% Varianza acumulada
CP1	2.853	35.667	35.667
CP2	1.170	14.621	50.288
CP3	1.010	12.620	62.907
CP4	0.993	12.411	75.319
CP5	0.791	9.885	85.204
CP6	0.659	8.238	93.442
CP7	0.449	5.607	99.048
CP8	0.076	0.952	100.000

Asimismo, con el fin de establecer el número óptimo de componentes a retener, se recurrió al criterio de Kaiser, que recomienda conservar aquellas componentes con un autovalor mayor o igual que uno. Como se aprecia en la Tabla 3, las tres primeras componentes cumplen claramente este criterio, mientras que la cuarta presenta un valor propio muy próximo a la unidad. Esta circunstancia, junto con su aportación relevante a la varianza explicada, justifica su inclusión en el análisis. Esta decisión se ve además respaldada por el gráfico de sedimentación (Figura 2), en el que se observa un punto de inflexión claro a partir de la cuarta componente, indicando que las componentes posteriores aportan información marginal.

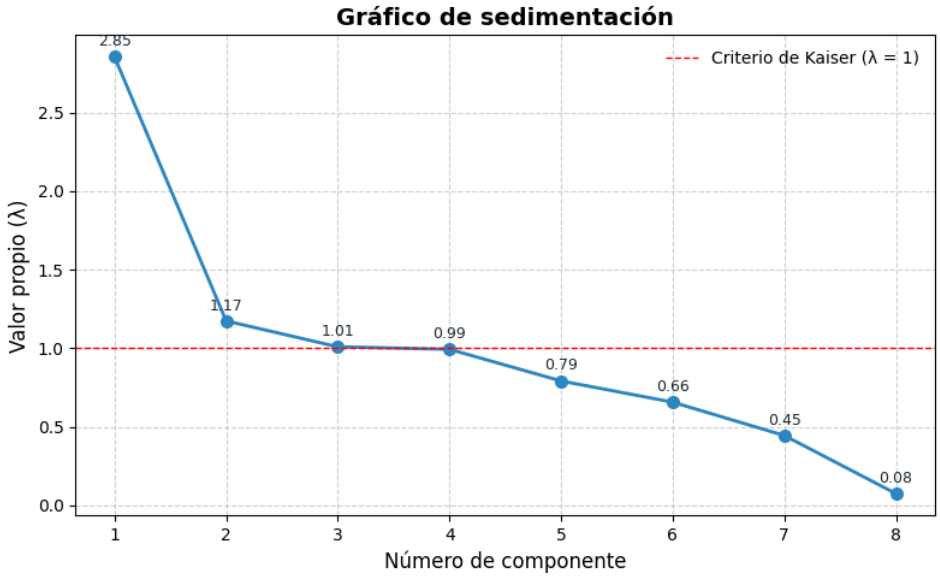

Figura 2. Gráfico de sedimentación

Por otra parte, el análisis de las comunalidades (Tabla 4) muestra que, al retener cuatro componentes, la mayoría de las variables quedan razonablemente bien representadas, aunque algunas, como la presión diastólica, presentan una comunalidad moderada, en torno al 45 %. Si bien la inclusión de una quinta componente permitiría mejorar parcialmente esta representación, el incremento obtenido resulta limitado en relación con la complejidad adicional introducida.

Dado que el objetivo del estudio no es maximizar la representación individual de cada variable, sino capturar las principales dimensiones del estado de salud para su posterior uso en un modelo de regresión del coste médico anual, se optó por retener cuatro componentes como solución equilibrada entre capacidad explicativa y parsimonia.

Tabla 4. Comunalidades por variable

Variable	Comunalidad
age	0.6764
bmi	0.9875
systolic_bp	0.6762
diastolic_bp	0.4562
ldl	0.9562
hba1c	0.7311
risk_score	0.8499
chronic_count	0.6961

5.2.2. Interpretación de las componentes

La interpretación de las componentes principales se realiza a partir de la matriz de componentes rotada (Varimax), que permite asociar cada componente con un perfil clínico bien definido (Tabla 5).

Tabla 5. Matriz de componentes rotados (Varimax).

Variable	CP1	CP2	CP3	CP4
systolic_bp	0.819	0.028	-0.028	0.023
risk_score	0.808	0.409	0.151	0.085
age	0.799	-0.033	0.038	0.180
diastolic_bp	0.659	0.037	-0.068	-0.129
hba1c	-0.108	0.850	-0.011	0.036
chronic_count	0.442	0.703	0.009	-0.051
bmi	0.001	0.000	0.993	-0.009
ldl	0.048	0.010	-0.009	0.977

En primer lugar, la primera componente principal se asocia fundamentalmente con un perfil de riesgo cardiovascular y hemodinámico. En concreto, esta componente presenta cargas elevadas en la presión arterial sistólica y diastólica, la edad y el score de riesgo, junto con una contribución adicional del número de enfermedades crónicas. Así pues, esta dimensión recoge un eje de salud relacionado con el envejecimiento y el deterioro cardiovascular, reflejando un patrón global de mayor riesgo clínico asociado a alteraciones hemodinámicas.

Por otro lado, la segunda componente principal se interpreta como un eje de comorbilidad crónica y control glucémico. En esta dimensión destacan especialmente las cargas elevadas de la HbA1c y del número de enfermedades crónicas, con una contribución secundaria del score de riesgo. Asimismo, esta componente caracteriza a individuos con un peor control metabólico y una mayor presencia de patologías crónicas, capturando un perfil clínico dominado por la comorbilidad y los trastornos relacionados con el metabolismo de la glucosa. Por tanto, la diferenciación de esta componente respecto a la anterior pone de manifiesto que el control glucémico y la carga de enfermedad constituyen una dimensión latente distinta del riesgo cardiovascular estrictamente hemodinámico.

Por último, la tercera y la cuarta componentes principales recogen dimensiones clínicas más específicas e independientes del resto. La tercera componente está dominada casi exclusivamente por el índice de masa corporal, representando un eje de adiposidad prácticamente puro, en línea con la escasa correlación observada entre el IMC y el resto de variables de salud. Por su parte, la cuarta componente se asocia de forma casi exclusiva con el colesterol LDL, configurando un perfil lipídico específico independiente de las demás dimensiones clínicas. Esta separación indica que tanto la adiposidad como el perfil lipídico constituyen factores diferenciados dentro del estado de salud de los individuos, no necesariamente alineados con los ejes de riesgo cardiovascular o comorbilidad metabólica.

5.2.3. Análisis y comparativa de los modelos generados

Una vez identificadas e interpretadas las cuatro componentes principales que resumen la información contenida en las variables de salud, se procedió a analizar su relación con el coste médico anual mediante modelos de regresión lineal. El objetivo de este análisis es evaluar en qué medida los distintos perfiles de salud identificados se asocian con el gasto sanitario y, al mismo tiempo, comparar dos estrategias de modelización complementarias. Para ello, en primer lugar, se estimó un modelo de regresión utilizando las componentes principales como variables explicativas, aprovechando su ortogonalidad para evitar problemas de multicolinealidad. Posteriormente, se consideró un segundo modelo alternativo basado en las variables originales más representativas de cada componente, con el fin de contrastar los resultados obtenidos desde un enfoque más directamente interpretable en términos clínicos.

```
==============================================================================
                 coef    std err          t      P>|t|      [0.025      0.975]
------------------------------------------------------------------------------
const       3009.4519      9.436    318.928      0.000    2990.957    3027.947
CP1          505.3922      5.587     90.460      0.000     494.442     516.342
CP2          347.6495      8.709     39.917      0.000     330.579     364.720
CP3           80.6889      9.393      8.591      0.000      62.279      99.099
CP4          -14.2308      9.466     -1.503      0.133     -32.784       4.322
==============================================================================
Omnibus:                    88262.856   Durbin-Watson:                   2.005
Prob(Omnibus):                  0.000   Jarque-Bera (JB):          5142717.466
Skew:                           4.027   Prob(JB):                         0.00
Kurtosis:                      37.196   Cond. No.                         1.69
==============================================================================

Notes:
[1] Standard Errors assume that the covariance matrix of the errors is correctly specified.

R² = 0.0897
R² ajustado = 0.0897

==================== ANOVA GLOBAL DEL MODELO ====================
           Suma de cuadrados     gl  Cuadrado medio
Modelo         8.772767e+10      4    2.193192e+10
Residual       8.903649e+11  99995    8.904094e+06
Total          9.780926e+11  99999             NaN

Estadístico F = 2463.1272
p-valor global = 0.0000e+00
```

Figura 3. Resumen del modelo de regresión con CP

En relación con el modelo de regresión basado en las componentes principales, los resultados indican que el modelo es globalmente significativo, tal y como refleja el contraste ANOVA, lo que confirma que las dimensiones latentes del estado de salud explican de forma conjunta una parte significativa de la variabilidad del coste médico anual. A nivel individual, las tres primeras componentes muestran efectos estadísticamente significativos, lo que pone de manifiesto la relevancia del riesgo cardiovascular global, la comorbilidad metabólica y la adiposidad corporal en la explicación del gasto sanitario. Por el contrario, la cuarta componente, asociada al perfil lipídico LDL, no resulta significativa una vez controlado el resto de dimensiones, lo que sugiere que este factor, considerado de forma aislada, no constituye un determinante principal del coste anual. En resumen, estos resultados permiten identificar qué perfiles de salud presentan una mayor relación con el gasto sanitario, manteniendo una estructura del modelo estable y libre de colinealidad.

```
==============================================================================
                 coef    std err          t      P>|t|      [0.025      0.975]
------------------------------------------------------------------------------
const        375.9700     88.936      4.227      0.000     201.657     550.283
risk_score  3745.3036     38.579     97.082      0.000    3669.690    3820.917
hba1c        104.9230     11.318      9.270      0.000      82.740     127.106
bmi            6.4881      1.896      3.422      0.001       2.772      10.204
ldl           -0.6403      0.312     -2.051      0.040      -1.252      -0.028
==============================================================================
Omnibus:                    88772.759   Durbin-Watson:                   2.006
Prob(Omnibus):                  0.000   Jarque-Bera (JB):          5311719.090
Skew:                           4.055   Prob(JB):                         0.00
Kurtosis:                      37.771   Cond. No.                     1.20e+03
==============================================================================

Notes:
[1] Standard Errors assume that the covariance matrix of the errors is correctly specified.
[2] The condition number is large, 1.2e+03. This might indicate that there are
strong multicollinearity or other numerical problems.

R² = 0.0945
R² ajustado = 0.0945

==================== ANOVA GLOBAL DEL MODELO ====================
          Suma de cuadrados     gl  Cuadrado medio
Modelo         9.246695e+10      4    2.311674e+10
Residual       8.856256e+11  99995    8.856699e+06
Total          9.780926e+11  99999             NaN

Estadístico F = 2610.0849
p-valor global = 0.0000e+00
```

Figura 4. Resumen del modelo de regresión lineal con las variables fisiológicas

A continuación, se estimó un segundo modelo de regresión empleando directamente las variables originales con mayor peso en cada una de las componentes principales (risk_score, HbA1c, IMC y LDL). En este caso, todas las variables resultan estadísticamente significativas y el coeficiente de determinación ajustado es ligeramente superior al obtenido en el modelo basado en componentes. Sin embargo, este enfoque presenta indicios claros de multicolinealidad, reflejados en un elevado número de condición de la matriz de diseño, lo que sugiere una posible inestabilidad en la estimación de los coeficientes. Este resultado es coherente con la existencia de relaciones internas entre las variables clínicas seleccionadas, especialmente en el ámbito del riesgo cardiovascular y metabólico, y pone de manifiesto las limitaciones de interpretar los efectos individuales de cada variable en presencia de dependencia entre predictores.

En cuanto a la comparación entre el modelo de regresión basado en componentes principales y el modelo construido a partir de las variables originales más representativas, en ambos se observan resultados coherentes, pero con diferencias metodológicas relevantes.

Por un lado, el modelo con variables originales presenta un coeficiente de determinación ajustado ligeramente superior, lo que indica una mayor capacidad explicativa en términos puramente numéricos. Sin embargo, este incremento es reducido y se obtiene a costa de introducir problemas claros de multicolinealidad entre los predictores, como refleja el elevado número de condición de la matriz de diseño. Por su parte, el modelo basado en componentes principales presenta un R^2 ajustado algo menor, pero mantiene la significación global del modelo y evita la dependencia lineal entre variables explicativas, proporcionando estimaciones más estables y fiables. Además, pese a que ambos valores de R^2 obtenidos son moderados, esto es habitual en el análisis del coste sanitario, un fenómeno intrínsecamente complejo y condicionado por numerosos factores clínicos, sociales y contextuales no observados.

En conclusión, a la luz de estos resultados, el modelo de regresión basado en componentes principales se considera metodológicamente más adecuado para el objetivo del estudio. En concreto, el uso previo del Análisis de Componentes Principales permite reducir la dimensionalidad del problema, eliminar la multicolinealidad y trabajar con dimensiones latentes bien definidas que resumen de forma eficiente la información clínica relevante. Por tanto, aunque el modelo con variables originales facilita una interpretación directa, el enfoque basado en componentes ofrece un marco más robusto y conceptualmente más sólido, especialmente cuando el interés se centra en analizar relaciones globales entre perfiles de salud y gasto sanitario. En este sentido, el PCA se justifica no solo como una técnica de reducción de la dimensionalidad, sino como una herramienta clave para mejorar la estabilidad, la coherencia y la interpretabilidad global del modelo de regresión.

5.3. Análisis de Correspondencias Múltiples (MCA)

En este apartado se presentan los resultados obtenidos tras la aplicación del Análisis de Correspondencias Múltiples (MCA) sobre las variables categóricas seleccionadas.

En primer lugar, la Tabla 6 recoge las frecuencias absolutas y relativas de las distintas categorías consideradas en el análisis. En términos generales, se observa una distribución equilibrada y coherente con la estructura esperable de una población asegurada amplia, lo que permite asumir que las categorías analizadas representan adecuadamente la realidad subyacente de los datos. Esta homogeneidad relativa en las frecuencias evita la presencia de categorías residuales y favorece la estabilidad de la solución factorial.

Tabla 6.Distribución de frecuencias de las categorías incluidas en el MCA

Variable	Categoría	Frecuencia	%
Grupo de edad	joven	6.637	6.6%
	adulto	80.234	80.2%
	mayor	13.129	13.1%
Patologías crónicas	ninguna	46.532	46.5%
	alguna	53.468	53.5%
Hospitalizado	no	91.031	91.0%
	sí	8.969	9.0%

Coste anual sanitario	bajo_coste	66.583	66.6%
	medio_coste	25.556	25.6%
	alto_coste	7.861	7.9%

En relación con la estructura dimensional del modelo, la Tabla 7 recoge los autovalores asociados a cada dimensión factorial, junto con el porcentaje de inercia explicada y su acumulado. La primera dimensión presenta un autovalor de 0,2869, explicando el 20,08% de la inercia total, mientras que la segunda dimensión muestra un autovalor de 0,1955, aportando un 13,69% adicional. De forma conjunta, las dos primeras dimensiones concentran aproximadamente el 33,77% de la variabilidad total del sistema.

De acuerdo con los criterios habitualmente aceptados en el Análisis de Correspondencias Múltiples (y siguiendo el enfoque expuesto en el material teórico adicional), se considera adecuado retener aquellas dimensiones cuyos autovalores se sitúan en torno o por encima del umbral de 0,2, al representar una contribución relevante a la inercia total del modelo. En este caso, las dos primeras dimensiones cumplen dicho criterio de forma aproximada, lo que justifica su consideración como estructura factorial principal.

Atendiendo a estos resultados y con el objetivo de facilitar una interpretación clara y operativa, el análisis se centra en el plano definido por las dos primeras dimensiones. Esta elección permite trabajar en un espacio bidimensional que recoge una proporción significativa de la inercia total y resulta especialmente adecuado para la identificación visual de patrones y perfiles diferenciados dentro del conjunto de asegurados.

Tabla 7. Autovalores e inercia explicada del MCA

Dimensión	Autovalor	% Varianza (inercia)	% Acumulada
Dim 1	0.2869	20.0818	20.0818
Dim 2	0.1955	13.6854	33.7672
Dim 3	0.1495	10.4649	44.2321
Dim 4	0.1452	10.1670	54.3990
Dim 5	0.1425	9.9733	64.3724
Dim 6	0.1413	9.8914	74.2638
Dim 7	0.1295	9.0650	83.3288
Dim 8	0.1103	7.7216	91.0504
Dim 9	0.0818	5.7287	96.7790
Dim 10	0.0460	3.2210	100.0000

La representación gráfica del plano factorial definido por las dos primeras dimensiones se muestra en la Figura 5, donde se identifican varios perfiles bien diferenciados de asegurados en función de la proximidad entre categorías. A partir de esta representación, pueden distinguirse claramente cuatro grupos principales con características sociodemográficas y sanitarias diferenciadas.

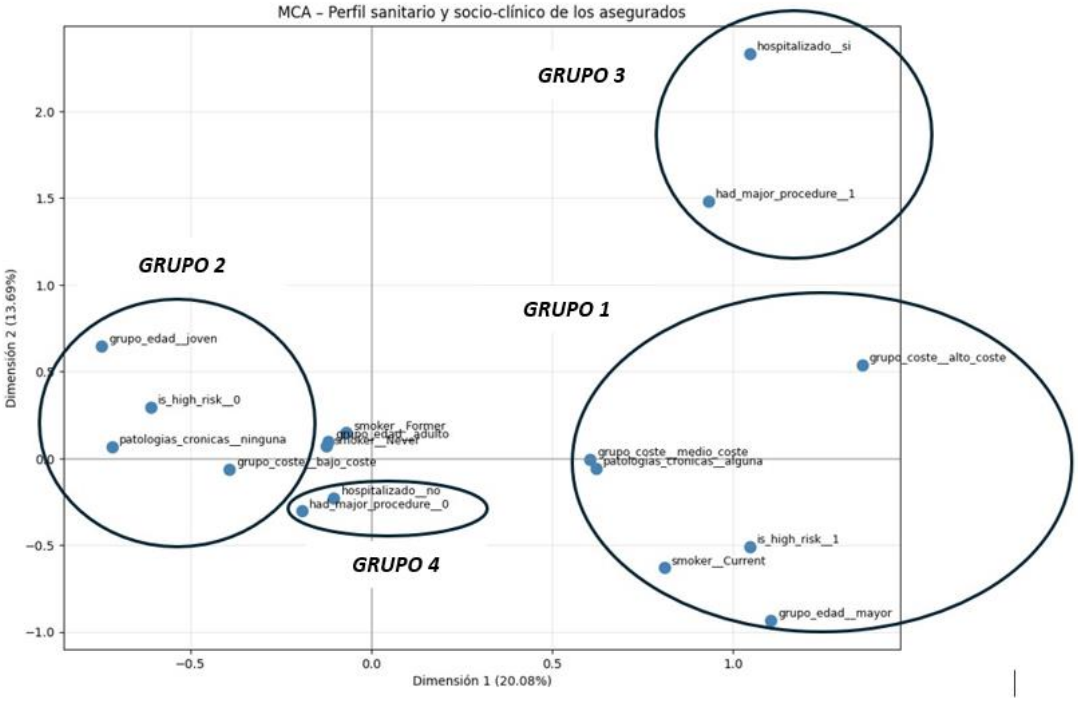

Figura 5. Representación factorial del MCA

Grupo 1: Perfil de alto riesgo y elevado consumo sanitario.

Este grupo se caracteriza por la proximidad de categorías asociadas a mayor edad, presencia de patologías crónicas, condición de alto riesgo clínico y niveles medio-alto de coste sanitario. Asimismo, aparecen próximos a este grupo los individuos fumadores actuales, lo que refuerza su interpretación como un perfil clínicamente complejo, con mayor carga de enfermedad y mayor utilización de recursos sanitarios. Este grupo representa a los asegurados con mayor impacto económico y sanitario para el sistema.

Grupo 2: Jóvenes sanos de bajo riesgo y bajo coste.

El segundo grupo agrupa principalmente a individuos jóvenes, sin patologías crónicas, clasificados como de bajo riesgo y asociados a un nivel bajo de coste sanitario. Este perfil corresponde a asegurados con escasa utilización de servicios sanitarios, buena situación clínica general y un impacto económico reducido, constituyendo el segmento más saludable de la población analizada.

Grupo 3: Pacientes con eventos sanitarios relevantes y alta utilización puntual.

En este grupo se concentran las categorías relacionadas con hospitalización reciente y la realización de procedimientos mayores. Se trata de asegurados que, independientemente de otras características sociodemográficas, han experimentado episodios clínicos relevantes que implican una utilización intensiva de recursos sanitarios en el corto o medio plazo. Este perfil refleja una alta utilización puntual del sistema, asociada a eventos clínicos específicos.

Grupo 4: Perfil estable sin ingresos ni procedimientos relevantes.

Finalmente, se identifica un grupo caracterizado por la ausencia de hospitalizaciones y procedimientos mayores, situado cerca del origen del plano factorial. Este perfil representa a asegurados con una situación sanitaria estable, sin eventos clínicos graves recientes y con una utilización moderada o baja del sistema sanitario.

Para un análisis detallado de la contribución de cada categoría a las dimensiones factoriales, así como de las coordenadas exactas de las categorías en el espacio factorial, puede consultarse el Anexo 4, donde se muestran las tablas completas de contribuciones e información factorial.

Por lo tanto, los resultados del MCA permiten identificar patrones claramente diferenciados de perfil sanitario y socio-clínico entre los asegurados, proporcionando una visión estructurada y sintética de la heterogeneidad existente en la población analizada. Esta información resulta especialmente útil como base para análisis posteriores orientados a segmentación, clasificación y diseño de estrategias de gestión del riesgo y del coste sanitario.

5.4. MCA combinado con análisis de conglomerados (k-means y jerárquico)

5.4.1. Justificación del método y selección de variables

Tal y como se ha indicado previamente en la sección de datos y en el análisis descriptivo general, la base de datos no presenta valores faltantes ni inconsistencias estructurales relevantes. En consecuencia, no ha sido necesario aplicar procedimientos adicionales de depuración o imputación, centrándose el preprocesado únicamente en recodificaciones puntuales de variables categóricas, motivadas por la baja frecuencia de algunas modalidades. Estas recodificaciones se han tenido en cuenta específicamente en el presente análisis con el objetivo de explorar distintas configuraciones de variables y evaluar su impacto sobre los resultados obtenidos.

Para este análisis se seleccionaron tres variables categóricas: estado civil, consumo de tabaco y frecuencia de consumo de alcohol. La elección de esta combinación responde a criterios tanto estadísticos como interpretativos. Entre las distintas alternativas evaluadas, esta configuración permite alcanzar un mayor porcentaje de inercia explicada en las dos primeras dimensiones factoriales, lo que facilita una representación bidimensional clara y directamente interpretable. Otras combinaciones de variables ofrecían resultados igualmente coherentes, pero requerían la incorporación de una tercera dimensión para lograr niveles de inercia similares, lo que habría dificultado la interpretación gráfica y conceptual del análisis.

5.4.2. Resumen de inercia y elección del plano factorial

La Tabla 8 recoge los autovalores y el porcentaje de inercia explicada asociado a cada dimensión.

Tabla 8. Autovalores e inercia explicada del MCA

Dimensión	Autovalor	% Varianza (inercia)	% Acumulada
Dim 1	0.3367	20.2004	20.2004
Dim 2	0.3356	20.1384	40.3388
Dim 3	0.3332	19.9937	60.3324
Dim 4	0.3314	19.8861	80.2185
Dim 5	0.3297	19.7815	100.00

Las dos primeras dimensiones concentran conjuntamente en torno al 40 % de la inercia total, lo que justifica su utilización como plano principal de análisis. La primera dimensión recoge el contraste estructural más relevante entre categorías, mientras que la segunda dimensión introduce una diferenciación adicional que complementa la interpretación del eje principal.

Aunque las dimensiones restantes presentan autovalores no despreciables, se opta por restringir el análisis al plano formado por las dos primeras dimensiones. Esta decisión es coherente con la práctica habitual en este tipo de análisis y permite mantener un equilibrio adecuado entre capacidad explicativa e interpretabilidad, evitando representaciones excesivamente complejas.

Las coordenadas factoriales y las contribuciones de las categorías a las distintas dimensiones se recogen en los anexos correspondientes, en concreto Anexo 5 (Tabla 13 y Tabla 14). Estas medidas permiten identificar qué modalidades desempeñan un papel más relevante en la construcción de cada eje y constituyen la base para la interpretación del mapa factorial.

Las coordenadas factoriales representan la posición de cada categoría en el espacio definido por las dimensiones seleccionadas. Estas coordenadas permiten interpretar las relaciones de proximidad y oposición entre las distintas modalidades de las variables analizadas.

En términos generales, categorías situadas próximas entre sí en el plano factorial tienden a aparecer asociadas en los perfiles observados, mientras que categorías alejadas o situadas en direcciones opuestas reflejan patrones de comportamiento diferenciados. Asimismo, las categorías localizadas más lejos del origen desempeñan un papel más relevante en la construcción de la estructura factorial, mientras que aquellas cercanas al origen tienen una menor capacidad discriminante dentro del plano considerado.

Las contribuciones de las categorías permiten cuantificar el peso relativo de cada modalidad en la construcción de las dimensiones factoriales. Este análisis resulta fundamental para interpretar el significado sustantivo de cada eje antes de observar el mapa factorial.

El análisis conjunto de coordenadas y contribuciones permite anticipar la estructura esperada en el mapa factorial y proporciona una base sólida para la interpretación posterior, evitando interpretaciones basadas únicamente en la representación gráfica.

5.4.3. Mapa Factorial

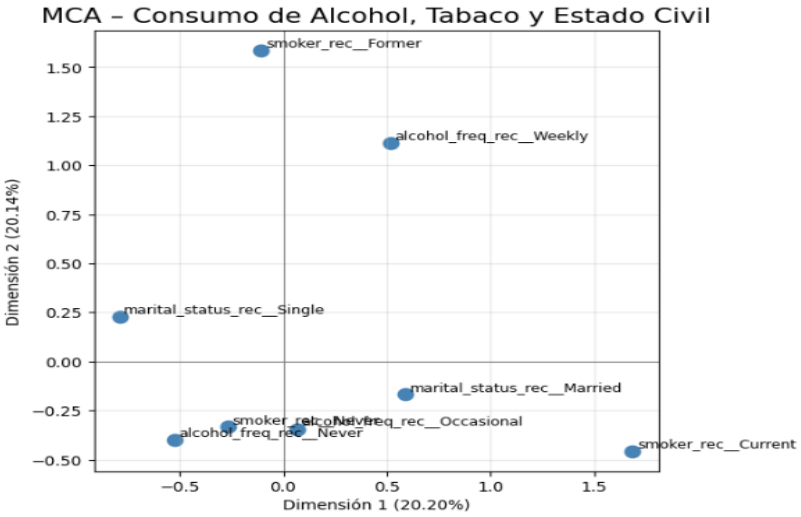

Figura 6. Plano Factorial

En el plano definido por las dos primeras dimensiones se observa una estructura clara de separación entre categorías. La Dimensión 1 está principalmente asociada al estado civil y al consumo de tabaco, destacando la oposición entre la categoría *smoker_rec_Current* y las categorías *marital_status_rec_Single* y *alcohol_freq_rec_Never*. La categoría *marital_status_rec_Married* se sitúa en el mismo polo que el consumo actual de tabaco, reforzando el contraste a lo largo de este eje.

La Dimensión 2 introduce una diferenciación adicional, especialmente vinculada a perfiles de exfumadores y consumo semanal de alcohol, situándose las categorías *smoker_rec_Former* y *alcohol_freq_rec_Weekly* en el extremo superior del plano. Esta interpretación es coherente con las coordenadas factoriales y con las contribuciones de las categorías, que identifican aquellas modalidades que construyen de forma más intensa cada dimensión.

5.4.4. Análisis de conglomerados sobre las coordenadas factoriales

Con el objetivo de reforzar la interpretación del mapa factorial y sintetizar la estructura observada, se aplicó un análisis de conglomerados sobre las coordenadas factoriales de las categorías en las dos primeras dimensiones. Este procedimiento se emplea con un enfoque descriptivo, orientado a agrupar categorías próximas en el espacio factorial y facilitar la identificación de bloques homogéneos.

En primer lugar, se utilizó un clustering jerárquico mediante el método de Ward, que agrupa las categorías minimizando la variabilidad interna de los conglomerados. El análisis del dendrograma (Anexo 5, Figura 10) sugiere una partición natural en tres clusters, ya que este número permite capturar la estructura principal sin fragmentar en exceso la información.

Posteriormente, se aplicó un clustering no jerárquico k-means con el mismo número de conglomerados (k = 3), con el fin de contrastar la estabilidad de la partición obtenida. La elevada coincidencia entre ambos métodos respalda la robustez de los grupos identificados.

5.4.5. Mapas de los Clusters

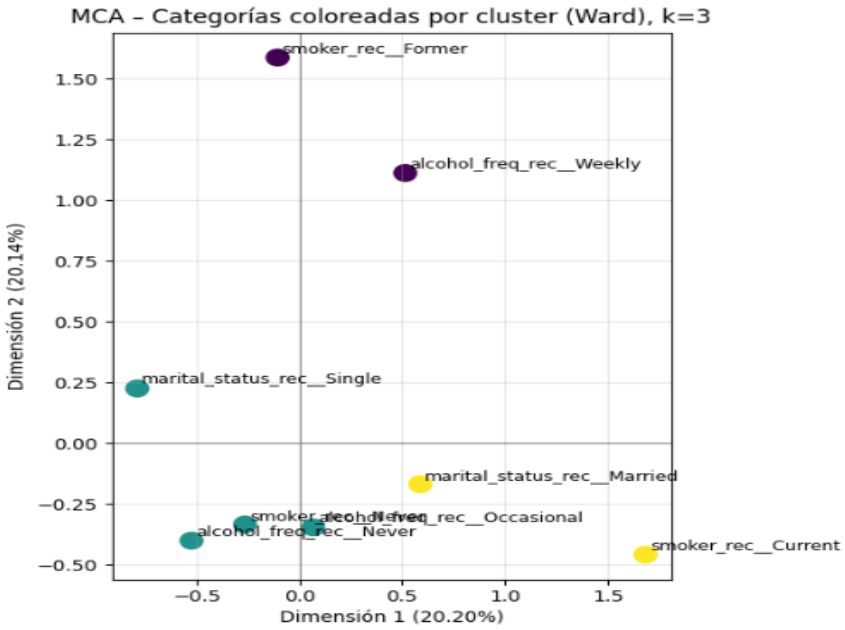

Figura 7. Clustering Jerárquico

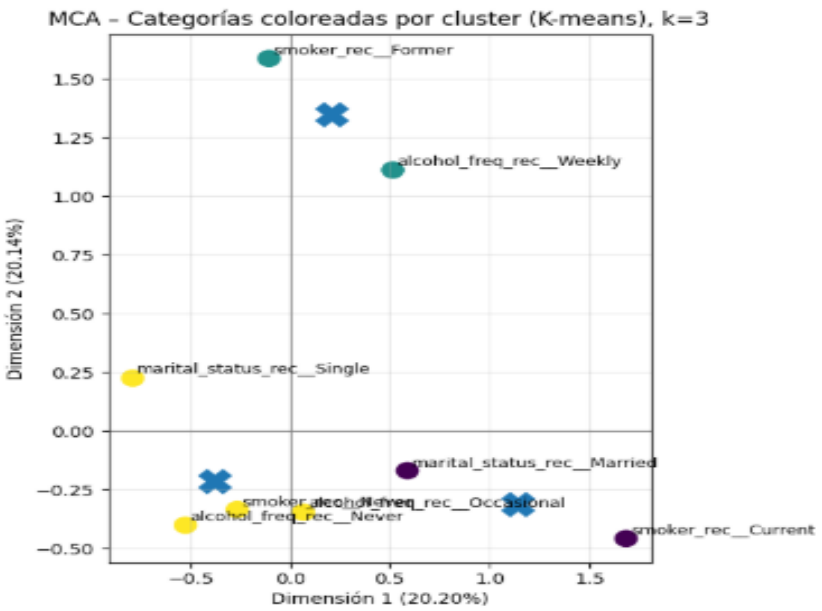

Figura 8. Clustering K-Means

5.4.6. Interpretación conjunta de los clusters

El primer conglomerado agrupa categorías asociadas a un consumo de alcohol relativamente regular y a perfiles de consumo de tabaco pasado, lo que sugiere un patrón vinculado a hábitos de consumo moderados o históricos.

El segundo conglomerado reúne categorías relacionadas con la ausencia o baja frecuencia de consumo de sustancias, junto con el estado civil soltero. Este grupo se localiza más próximo al origen del plano factorial, indicando un perfil más homogéneo y menos extremo en comparación con los otros clusters.

El tercer conglomerado está formado por categorías asociadas al consumo actual de tabaco y al estado civil casado, que aparecen situadas en posiciones más extremas del plano factorial, especialmente a lo largo de la primera dimensión. Este grupo define uno de los polos más marcados del espacio factorial y desempeña un papel clave en la diferenciación estructural observada.

5.4.7. Conclusiones de este análisis

El MCA aplicado a las variables de estado civil, consumo de tabaco y frecuencia de consumo de alcohol permite identificar una estructura coherente de asociaciones entre categorías, que se manifiesta de forma consistente tanto en el plano factorial como en los análisis de conglomerados posteriores.

Las dos primeras dimensiones proporcionan una representación bidimensional adecuada de las relaciones principales entre las categorías analizadas, mientras que el análisis de contribuciones y coordenadas facilita la interpretación sustantiva de los ejes. La aplicación combinada de clustering jerárquico y k-means refuerza la interpretación del mapa factorial y confirma la existencia de tres grupos estables y bien diferenciados. En vista de los resultados anteriores, este análisis pone de manifiesto distintos polos de comportamiento relacionados con hábitos de consumo y situación personal, ilustrando el valor del MCA como herramienta exploratoria en el estudio de variables categóricas dentro de un contexto multivariante.

5.5. Análisis Discriminante Lineal

El Análisis Discriminante Lineal se aplicó para evaluar la capacidad de un conjunto de variables clínicas, económicas y de utilización del seguro para discriminar entre tres grupos de asegurados definidos según su coste médico anual (Low, Medium y High). Con este objetivo, se estimó en primer lugar un modelo discriminante completo con 29 predictores y, posteriormente, un modelo reducido obtenido mediante selección stepwise, comparando en ambos casos su capacidad clasificatoria y su interpretabilidad.

La variable dependiente *cost_group* se construyó a partir de *annual_medical_cost* dividiendo su distribución en tres cuantiles de igual frecuencia, etiquetados como Low, Medium y High. Este procedimiento garantiza que cada grupo contenga aproximadamente un tercio de las observaciones, lo que evita problemas de desbalanceo y facilita una comparación homogénea del rendimiento del modelo entre categorías de coste.

5.5.1. Modelo discriminante completo

El modelo completo incluye 29 variables numéricas que recogen información sobre edad, indicadores de riesgo y cronicidad, utilización de servicios (visitas, procedimientos, hospitalizaciones) y características económicas del seguro, como primas, importes y número de reclamaciones, deducible y copago. Tras estandarizar todas las variables explicativas, se estimó un modelo LDA con tres grupos, obteniéndose dos funciones discriminantes canónicas (LD1 y LD2).

Rendimiento de clasificación del modelo completo

La matriz de clasificación del modelo completo muestra una capacidad discriminante global del 68,31%, con una separación especialmente marcada entre los extremos de coste.

Tabla 9. Matriz de clasificación del modelo discriminante completo

Real \ Predicho	Low_pred	Medium_pred	High_pred
Low_real	24.930	8.403	0
Medium_real	11.727	21.155	451
High_real	958	10.151	22.225

El grupo High presenta una precisión muy elevada (≈ 0,98) y una sensibilidad en torno al 0,67, mientras que los grupos Low y Medium muestran valores de precisión y sensibilidad más moderados. La mayor parte de los errores de clasificación se concentran en confusiones entre grupos adyacentes (Low–Medium y Medium–High), mientras que la confusión directa entre los extremos (Low–High) es prácticamente inexistente.

Este patrón es esperable dado que los grupos se definen a partir de terciles: el grupo Medium actúa como un grupo frontera, recogiendo perfiles intermedios que presentan un mayor solapamiento con los extremos, lo que dificulta su discriminación perfecta respecto a los grupos Low y High. Las métricas detalladas por clase se recogen en el Anexo 6.

En términos prácticos, el modelo es especialmente eficaz para identificar asegurados de alto coste, mientras que el grupo intermedio reúne perfiles heterogéneos que, por construcción, comparten zonas de solapamiento con los grupos adyacentes.

Funciones discriminantes del modelo completo

El análisis de la matriz de estructura revela que la primera función discriminante (LD1) está fuertemente asociada a variables económicas y de gasto del seguro, como annual_premium, total_claims_paid y avg_claim_amount, que presentan las cargas absolutas más elevadas en dicha función. LD1 puede interpretarse, por tanto, como un eje económico–financiero que ordena a los asegurados según la magnitud de las primas y el volumen económico de las reclamaciones y pagos, separando especialmente los perfiles de coste bajo y alto.

La segunda función discriminante (LD2) muestra mayores cargas en indicadores de carga de enfermedad y utilización sanitaria (por ejemplo, *chronic_count*, *is_high_risk*, *visits_last_year*, *hospitalizations_last_3yrs*), así como en recuentos de procedimientos y reclamaciones. Esta función recoge una dimensión principalmente clínica y de intensidad de uso del sistema, que refina la discriminación dentro de los perfiles intermedios, aunque su contribución a la separación global es menor que la de LD1. Las tablas correspondientes a los coeficientes estandarizados y a la matriz de estructura del modelo completo se muestran en el Anexo 6 (Tabla 20 y Tabla 21).

Por lo tanto, las funciones LD1 y LD2 revelan que la combinación de un eje económico–financiero y otro clínico–asistencial resulta suficiente para estructurar la variabilidad del coste médico anual, lo que justifica la búsqueda posterior de modelos más parsimoniosos que preserven esta estructura básica.

5.5.2. Modelo discriminante reducido (*stepwise*)

Con el objetivo de obtener un modelo más parsimonioso y fácilmente interpretable, se aplicó un procedimiento de selección stepwise basado en la reducción sucesiva de la Lambda de Wilks y en la prueba F parcial. Solo se incorporaron aquellas variables cuya inclusión producía una mejora apreciable del modelo ($\Delta\lambda \geq 0{,}001$ y $F \geq 10$).

El procedimiento stepwise seleccionó siete variables con contribución discriminante claramente significativa:

annual_premium *total_claims_paid* *chronic_count* *claims_count*

is_high_risk *hospitalizations_last_3yrs* *avg_claim_amount*

Una vez incorporadas estas variables, ninguna de las restantes aportó mejoras adicionales, por lo que el algoritmo se detuvo automáticamente. El modelo reducido se ajustó utilizando únicamente estos siete predictores estandarizados. La matriz de clasificación obtenida se muestra a continuación.

Tabla 10. Matriz de clasificación del modelo discriminante stepwise

Real \ Predicho	Low_pred	Medium_pred	High_pred
Low_real	25.502	7.830	1
Medium_real	12.215	20.702	416
High_real	816	10.369	22.149

El porcentaje global de aciertos del modelo reducido (68,35%) es prácticamente idéntico al del modelo completo, lo que indica que la capacidad discriminante se mantiene a pesar de la reducción sustancial del número de variables. La estructura de errores es también muy similar, con buena separación entre los extremos de coste y mayor solapamiento en el grupo intermedio, lo que confirma que el modelo stepwise captura la esencia del patrón discriminante con un conjunto de predictores mucho más compacto.

Funciones discriminantes y centroides del modelo stepwise

En el modelo stepwise, la primera función discriminante (LD1) está claramente dominada por variables económicas del seguro. La prima anual (*annual_premium*) presenta el coeficiente de mayor magnitud en LD1 (–1,2690), seguida de *avg_claim_amount* y *total_claims_paid*, lo que confirma que este eje resume el nivel global de gasto anual y volumen económico de siniestros.

En esta función, valores más negativos de LD1 se asocian a perfiles de alto coste (High), mientras que valores positivos corresponden a perfiles de bajo coste (Low), actuando LD1 como el principal eje de ordenación de los asegurados según su gasto sanitario.

La segunda función discriminante (LD2) está principalmente asociada con la carga de enfermedad y la utilización intensiva del sistema sanitario, destacando los coeficientes positivos de chronic_count, claims_count, is_high_risk, hospitalizations_last_3yrs y avg_claim_amount, y el coeficiente negativo de total_claims_paid. Esta función caracteriza a los asegurados en función de su complejidad clínica y su frecuencia de uso de servicios, diferenciando perfiles con alta intensidad de episodios y reclamaciones, pero no necesariamente asociados a los mayores importes acumulados, lo que aporta una dimensión complementaria dentro de los perfiles de gasto, especialmente en el grupo Medium.

Tabla 11. Centroides discriminantes del modelo stepwise

cost_group	LD1	LD2
Low	0,9517	–0,1011
Medium	0,3419	0,1388
High	–1,2935	–0,0377

Los centroides reflejan una separación muy clara a lo largo de LD1, con el grupo Low situado en valores positivos, el grupo High en valores negativos y el grupo Medium en una posición intermedia. En LD2 las diferencias son más sutiles, con un ligero desplazamiento del grupo Medium hacia valores superiores, lo que refuerza su carácter de grupo frontera con mayor heterogeneidad clínica y de uso de servicios. La Figura 9 ilustra la proyección de las observaciones en el plano LD1–LD2, donde se aprecia la separación principal inducida por LD1 y los matices introducidos por LD2.

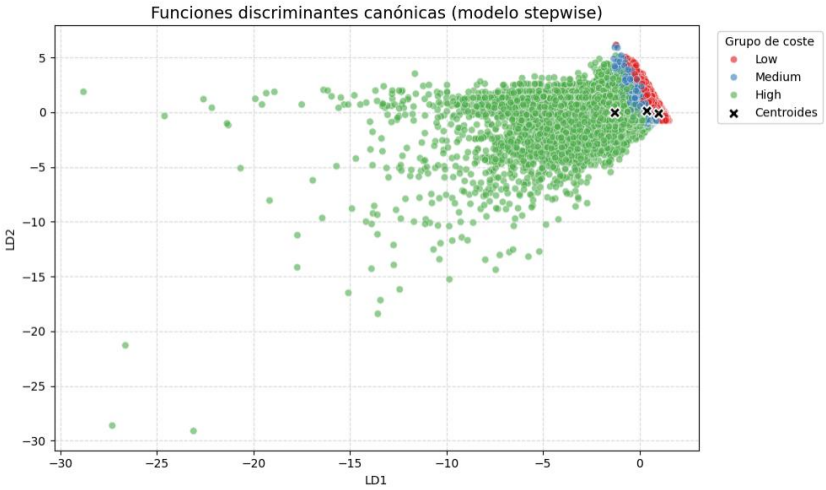

Figura 9. Funciones discriminantes canónicas (LD1–LD2) del modelo stepwise

Por todo lo anterior, los resultados del LDA corroboran la importancia central de las variables económicas del seguro y de la carga de enfermedad en la discriminación entre niveles de coste, en línea con los ejes latentes identificados previamente mediante PCA y MCA.

6. Conclusiones

El análisis desarrollado en este trabajo ha permitido abordar el estudio del coste médico anual desde una perspectiva multivariante completa, adecuada a la complejidad y heterogeneidad del conjunto de datos considerado. La combinación de distintas técnicas estadísticas ha facilitado no solo la reducción de la dimensionalidad del problema, sino también una interpretación coherente de los factores que intervienen en la generación del gasto sanitario.

A través del Análisis de Componentes Principales se ha comprobado que gran parte de la variabilidad del sistema puede explicarse mediante un número reducido de dimensiones latentes, principalmente asociadas a variables económicas del seguro y a indicadores de coste y utilización sanitaria. La fuerte correlación entre primas, pagos y cuantías reclamadas confirma que estas variables constituyen el núcleo estructural del gasto médico, y pone de manifiesto la utilidad del PCA como herramienta de síntesis y apoyo a la modelización posterior.

La modelización del coste médico mediante regresión ha mostrado que, aunque el poder explicativo de los modelos es moderado, los resultados son coherentes con la naturaleza multifactorial del fenómeno analizado. En este contexto, el uso de componentes principales permite reducir la multicolinealidad entre predictores y facilita una interpretación más clara de los grandes ejes explicativos del coste, reforzando la utilidad práctica del enfoque basado en PCA frente a modelos construidos directamente sobre variables originales altamente correlacionadas.

El Análisis de Correspondencias Múltiples aplicado a variables categóricas relacionadas con hábitos de consumo y situación personal ha revelado patrones de asociación bien definidos entre categorías. La representación factorial ha permitido identificar oposiciones y proximidades interpretables, que han sido reforzadas mediante la aplicación de técnicas de clustering sobre las coordenadas factoriales. Este enfoque ha facilitado la identificación de grupos homogéneos de categorías y ha contribuido a una caracterización más clara de perfiles de comportamiento dentro del conjunto de asegurados.

En lo que respecta al Análisis Discriminante Lineal, los resultados obtenidos muestran una capacidad de clasificación razonable de los asegurados en grupos de bajo, medio y alto coste. La separación entre los grupos extremos es especialmente clara, mientras que los mayores errores se concentran en el grupo intermedio, lo cual resulta coherente con su definición basada en terciles del coste y su papel como grupo frontera. La comparación entre el modelo completo y el modelo reducido mediante selección stepwise pone de manifiesto que la información discriminante se concentra en un conjunto reducido de variables, principalmente económicas y de carga clínica, permitiendo obtener un modelo más parsimonioso sin pérdida apreciable de rendimiento.

Los resultados obtenidos evidencian que el análisis multivariante constituye una herramienta adecuada para el estudio del coste sanitario en entornos de alta dimensionalidad, ya que permite integrar información de distinta naturaleza, identificar estructuras latentes y construir modelos interpretables. El enfoque seguido en este trabajo ilustra cómo la aplicación coordinada de técnicas exploratorias y predictivas puede aportar una visión global y coherente del problema, con potencial interés para la segmentación de asegurados y el apoyo a la toma de decisiones en contextos de gestión sanitaria.

7. Referencias

[1] C. Barcia Portillo, “Análisis Estadístico Multivariante.” Accessed: Jan. 21, 2026. [Online]. Available: https://tesiunamdocumentos.dgb.unam.mx/pd2001/295701/295701.pdf

[2] Kaiser Family Foundation, “Health Care Costs: A Primer 2012: Key Information on Health Care Costs and Their Impact,” May 2012.

8. Anexos

Anexo 1. Descripción detallada de las variables.

Variable	Descripción
person_id	Identificador único para cada individuo.
age	Edad del individuo (18–90 años).
sex	Género (Hombre/Mujer).
region	Región geográfica.
urban_rural	Tipo de zona donde vive la persona (urbana o rural).
income	Ingresos anuales en USD.
education	Nivel educativo alcanzado.
marital_status	Estado civil.
employment_status	Tipo/estado de empleo.
household_size	Número de personas en el hogar.
dependents	Número de personas dependientes económicamente.
bmi	Índice de Masa Corporal (IMC).
smoker	Estado de consumo de tabaco (fumador/no fumador).
alcohol_freq	Frecuencia de consumo de alcohol.
visits_last_year	Número de visitas a proveedores de salud en el último año.
hospitalizations_last_3yrs	Número de hospitalizaciones en los últimos tres años.
days_hospitalized_last_3yrs	Total de días hospitalizado en los últimos tres años.
medication_count	Número de medicamentos activos prescritos.
systolic_bp	Presión arterial sistólica (mmHg).
diastolic_bp	Presión arterial diastólica (mmHg).
ldl	Nivel de colesterol LDL (mg/dL).
hba1c	Hemoglobina A1c (%), indicador de control de glucosa.
plan_type	Tipo de plan de seguro (p.ej., HMO, PPO, EPO).
network_tier	Nivel de la red del seguro (Bronce, Plata, Oro, Platino).
deductible	Deducible anual del seguro (USD).
copay	Copago por servicio sanitario.
policy_term_years	Duración de la póliza en años.

policy_changes_last_2yrs	Número de veces que se modificó la póliza en los últimos dos años.
provider_quality	Calificación de calidad del proveedor/aseguradora.
risk_score	Puntuación de riesgo en salud (normalizada).
annual_medical_cost	Coste médico anual total (USD).
annual_premium	Prima anual del seguro (USD).
monthly_premium	Prima mensual del seguro (USD).
claims_count	Número de reclamaciones de seguro presentadas en un año.
avg_claim_amount	Importe promedio por reclamación (USD).
total_claims_paid	Total pagado en reclamaciones (USD).
chronic_count	Número de enfermedades crónicas diagnosticadas.
hypertension	Indicador de hipertensión (0 = No, 1 = Sí).
diabetes	Indicador de diabetes (0 = No, 1 = Sí).
asthma	Indicador de asma (0 = No, 1 = Sí).
copd	Indicador de EPOC (0 = No, 1 = Sí).
cardiovascular_disease	Indicador de enfermedad cardiovascular (0 = No, 1 = Sí).
cancer_history	Historial de cáncer (0 = No, 1 = Sí).
kidney_disease	Indicador de enfermedad renal crónica (0 = No, 1 = Sí).
liver_disease	Indicador de enfermedad hepática (0 = No, 1 = Sí).
arthritis	Indicador de artritis (0 = No, 1 = Sí).
mental_health	Indicador de condición de salud mental diagnosticada (0 = No, 1 = Sí).
proc_imaging_count	Número de procedimientos de imagen (rayos X, MRI, CT, etc.) por año.
proc_surgery_count	Número de procedimientos quirúrgicos realizados.
proc_physio_count	Número de procedimientos/sesiones psicológicas o psiquiátricas.
proc_consult_count	Número de consultas con especialistas (cardiólogo, oncólogo, etc.).
proc_lab_count	Número de pruebas de laboratorio realizadas.
is_high_risk	Indicador de alto riesgo en salud (0 = No, 1 = Sí).
had_major_procedure	Indicador de haber tenido un procedimiento médico importante en el último año (0 = No, 1 = Sí).

Tabla 12. Estadísticos descriptivos de las variables

Variable	Media	Desviación estándar	Mínimo	Mediana	Máximo	skew	kurtosis
person_id	50000,5	28867,658	1	50000,5	100000	0	-1,2
age	47,522	15,989	0	48	100	0,006	-0,068
income	49873,905	46800,214	1100	36200	1061800	3,39	22,34
household_size	2,431	1,075	1	2	9	0,726	0,59
dependents	0,898	0,951	0	1	7	1,062	1,119
bmi	26,991	4,995	12	27	50,4	0,016	-0,04
visits_last_year	1,928	1,738	0	2	25	1,598	5,063
hospitalizations_last_3yrs	0,094	0,305	0	0	3	3,225	10,172
days_hospitalized_last_3yrs	0,373	1,373	0	0	21	4,258	20,51
medication_count	1,236	1,209	0	1	11	1,143	1,67
systolic_bp	117,809	15,369	61	117	183	0,263	-0,011
diastolic_bp	73,605	8,901	40	73	114	0,251	0,017
ldl	119,975	30,262	30	120	248,3	0,02	-0,054
hba1c	5,606	0,846	3,54	5,44	11,94	2,637	8,887
deductible	1226,725	1019,619	500	1000	5000	2,497	6,561
copay	19,52	10,286	10	20	50	1,225	1,455
policy_term_years	5,518	2,869	1	6	10	-0,005	-1,225
policy_changes_last_2yrs	0,051	0,225	0	0	2	4,4	19,027
provider_quality	3,599	0,594	1,5	3,6	5	-0,067	-0,168
risk_score	0,52	0,251	0	0,505	1	0,161	-0,722
annual_medical_cost	3009,452	3127,463	55,55	2082,575	65724,9	4,03	32,559
annual_premium	582,32	399,584	211,67	463,585	10962,55	4,365	39,951

monthly_premium	48,527	33,299	17,64	38,63	913,55	4,365	39,951
claims_count	1,622	2,03	0	1	23	2,087	6,429
avg_claim_amount	656,512	1072,66	0	318,015	30010,53	4,642	45,738
total_claims_paid	1377,879	2305,465	0	642,545	72517,95	4,938	53,982
chronic_count	0,725	0,806	0	1	6	0,978	0,648
hypertension	0,203	0,403	0	0	1	1,473	0,171
diabetes	0,086	0,28	0	0	1	2,955	6,732
asthma	0,059	0,235	0	0	1	3,748	12,05
copd	0,036	0,186	0	0	1	4,985	22,855
cardiovascular_disease	0,051	0,22	0	0	1	4,074	14,597
cancer_history	0,022	0,145	0	0	1	6,596	41,514
kidney_disease	0,015	0,12	0	0	1	8,088	63,418
liver_disease	0,015	0,121	0	0	1	8,045	62,723
arthritis	0,108	0,311	0	0	1	2,521	4,355
mental_health	0,13	0,336	0	0	1	2,199	2,834
proc_imaging_count	0,509	0,75	0	0	7	1,627	3,127
proc_surgery_count	0,159	0,464	0	0	6	3,473	14,311
proc_physio_count	0,508	0,747	0	0	7	1,606	3,008
proc_consult_count	0,509	0,754	0	0	7	1,656	3,33
proc_lab_count	0,509	0,75	0	0	7	1,63	3,154
is_high_risk	0,368	0,482	0	0	1	0,548	-1,699
had_major_procedure	0,17	0,375	0	0	1	1,76	1,097

Anexo 2. Análisis descriptivo de las variables de la base de datos.

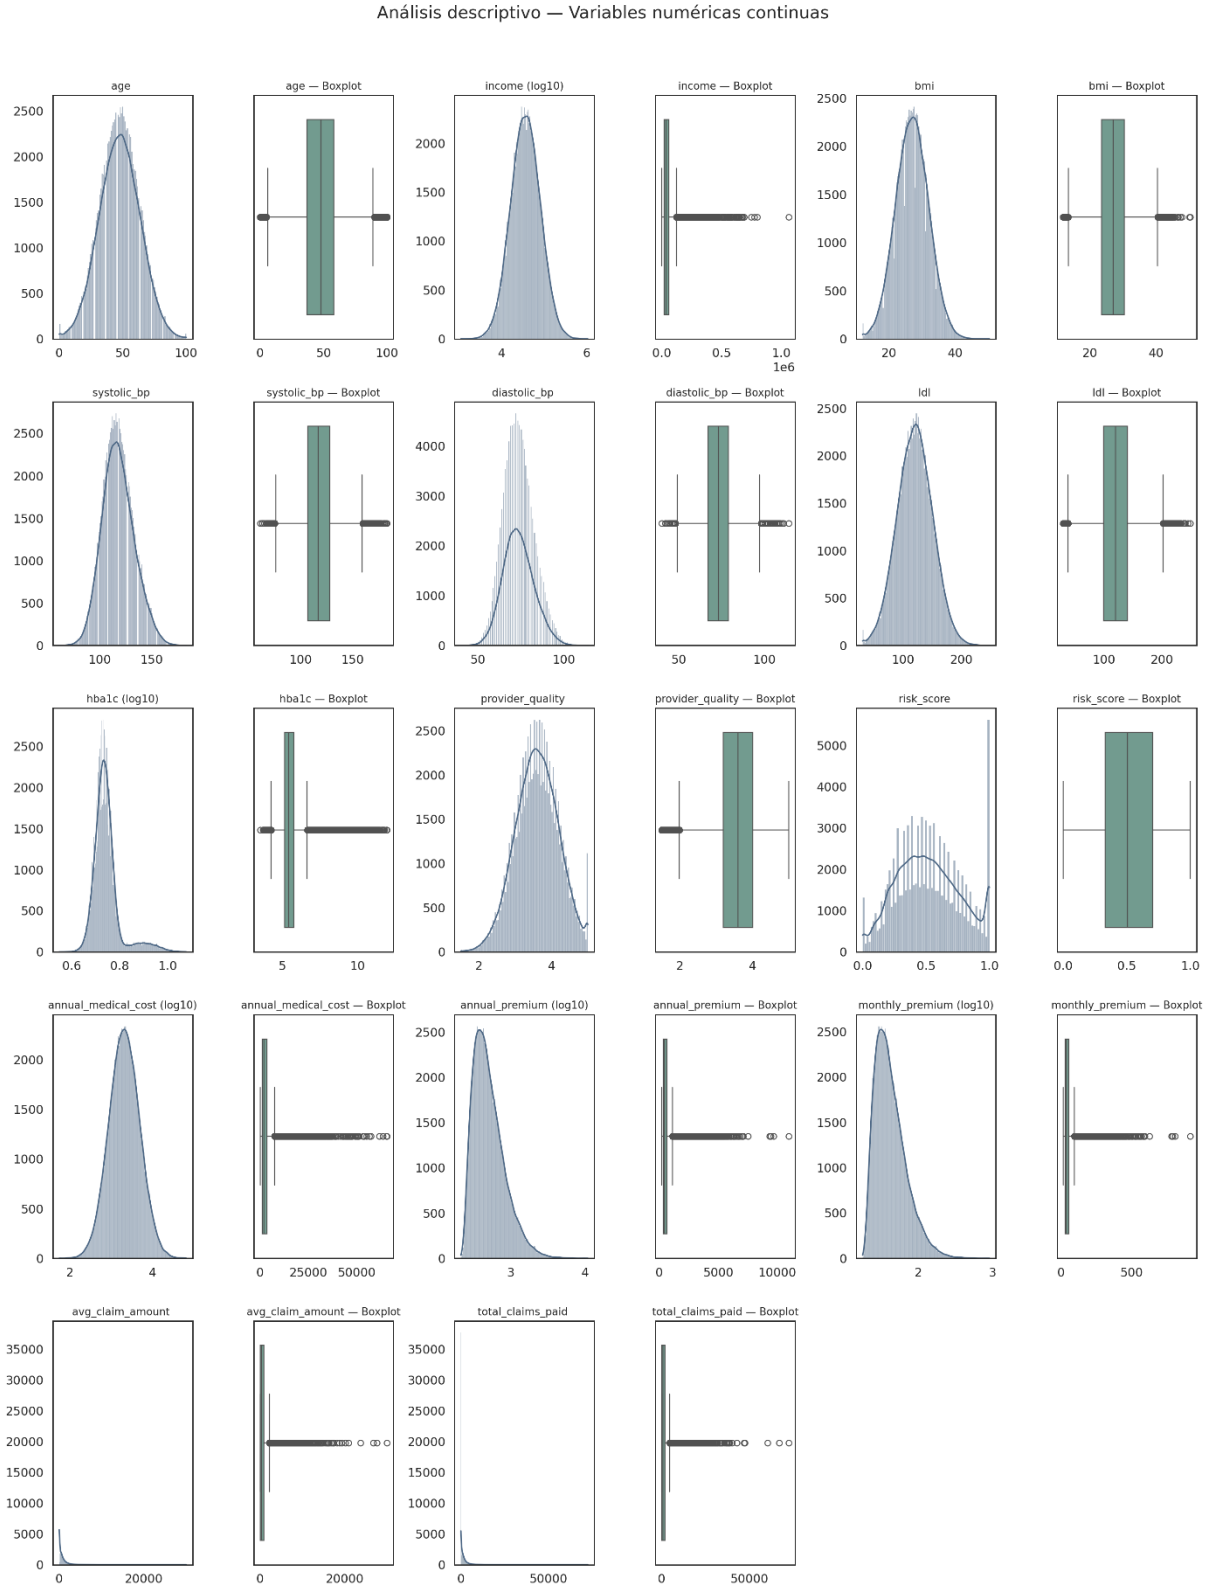

Análisis descriptivo — Variables numéricas discretas

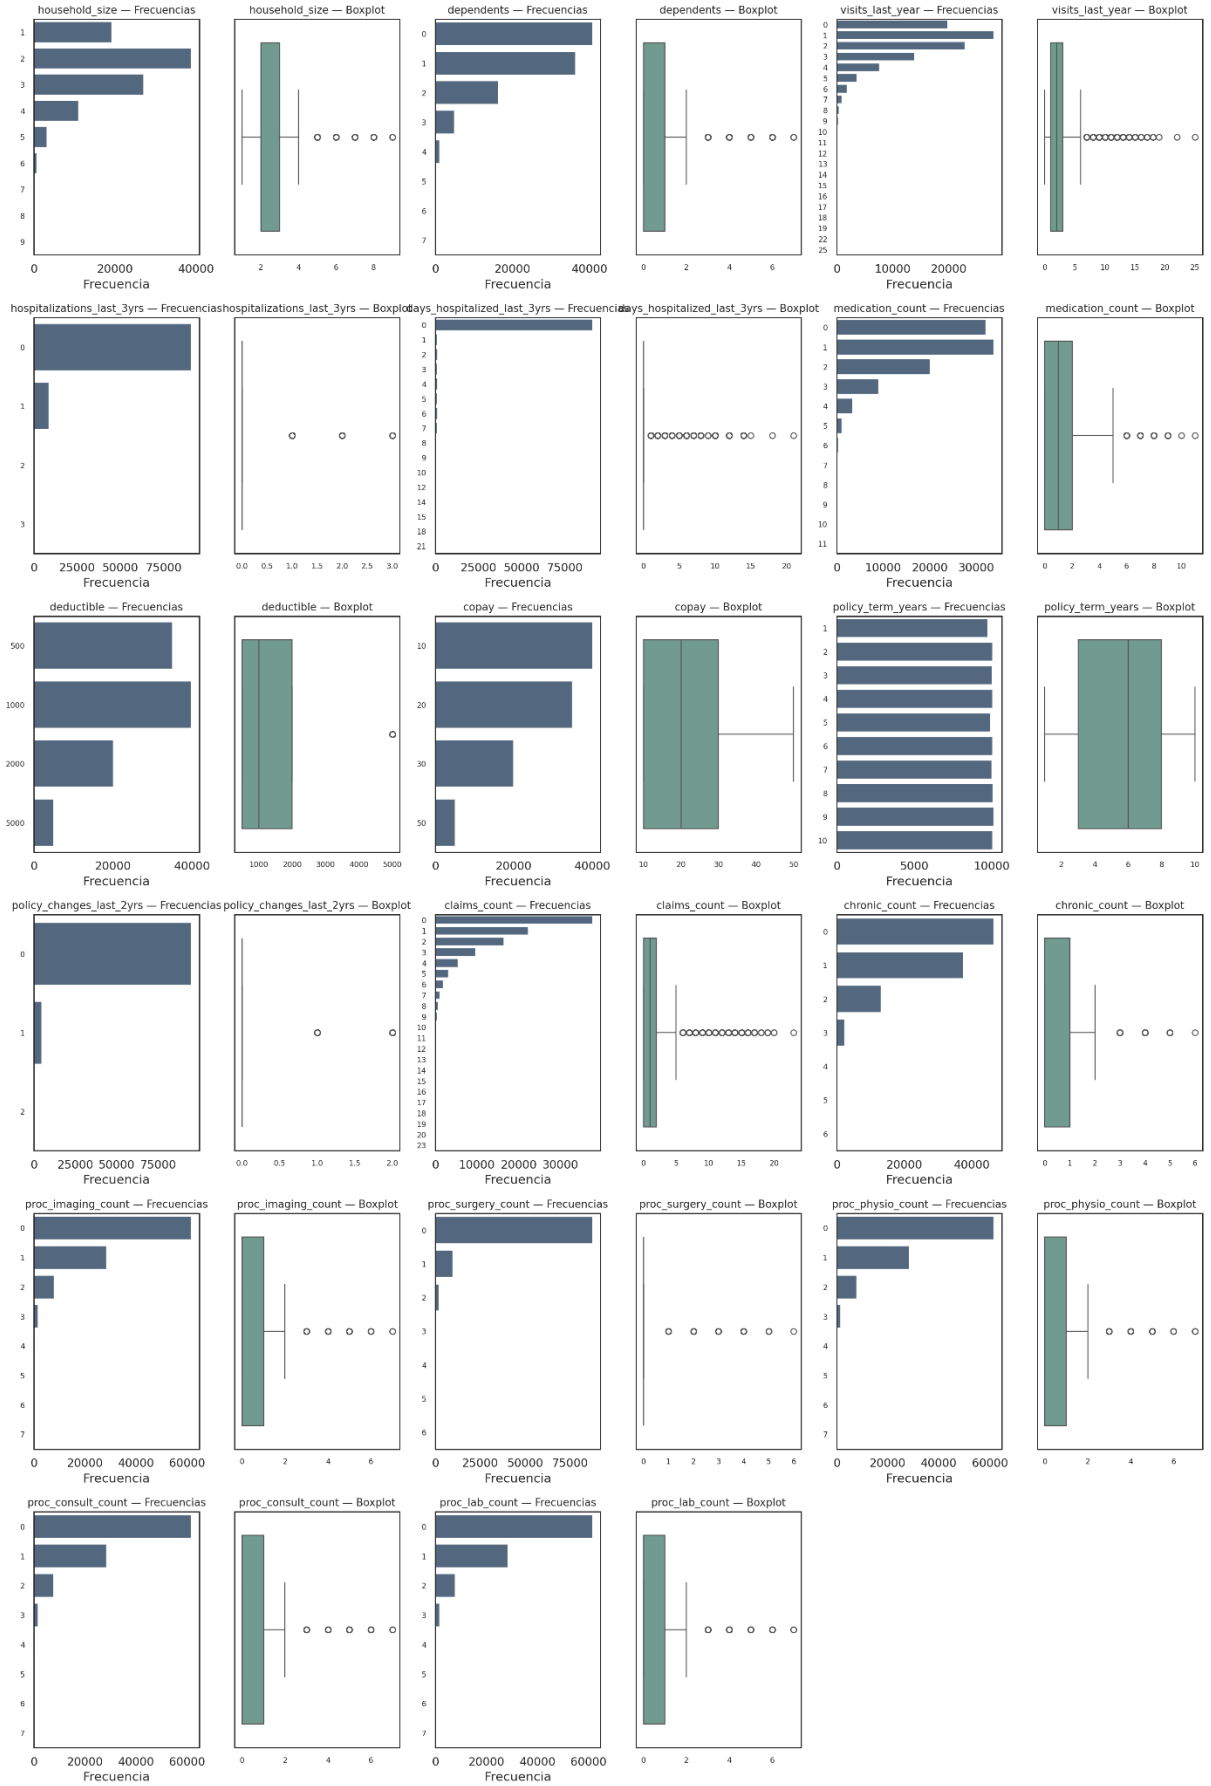

Análisis descriptivo — Variables categóricas

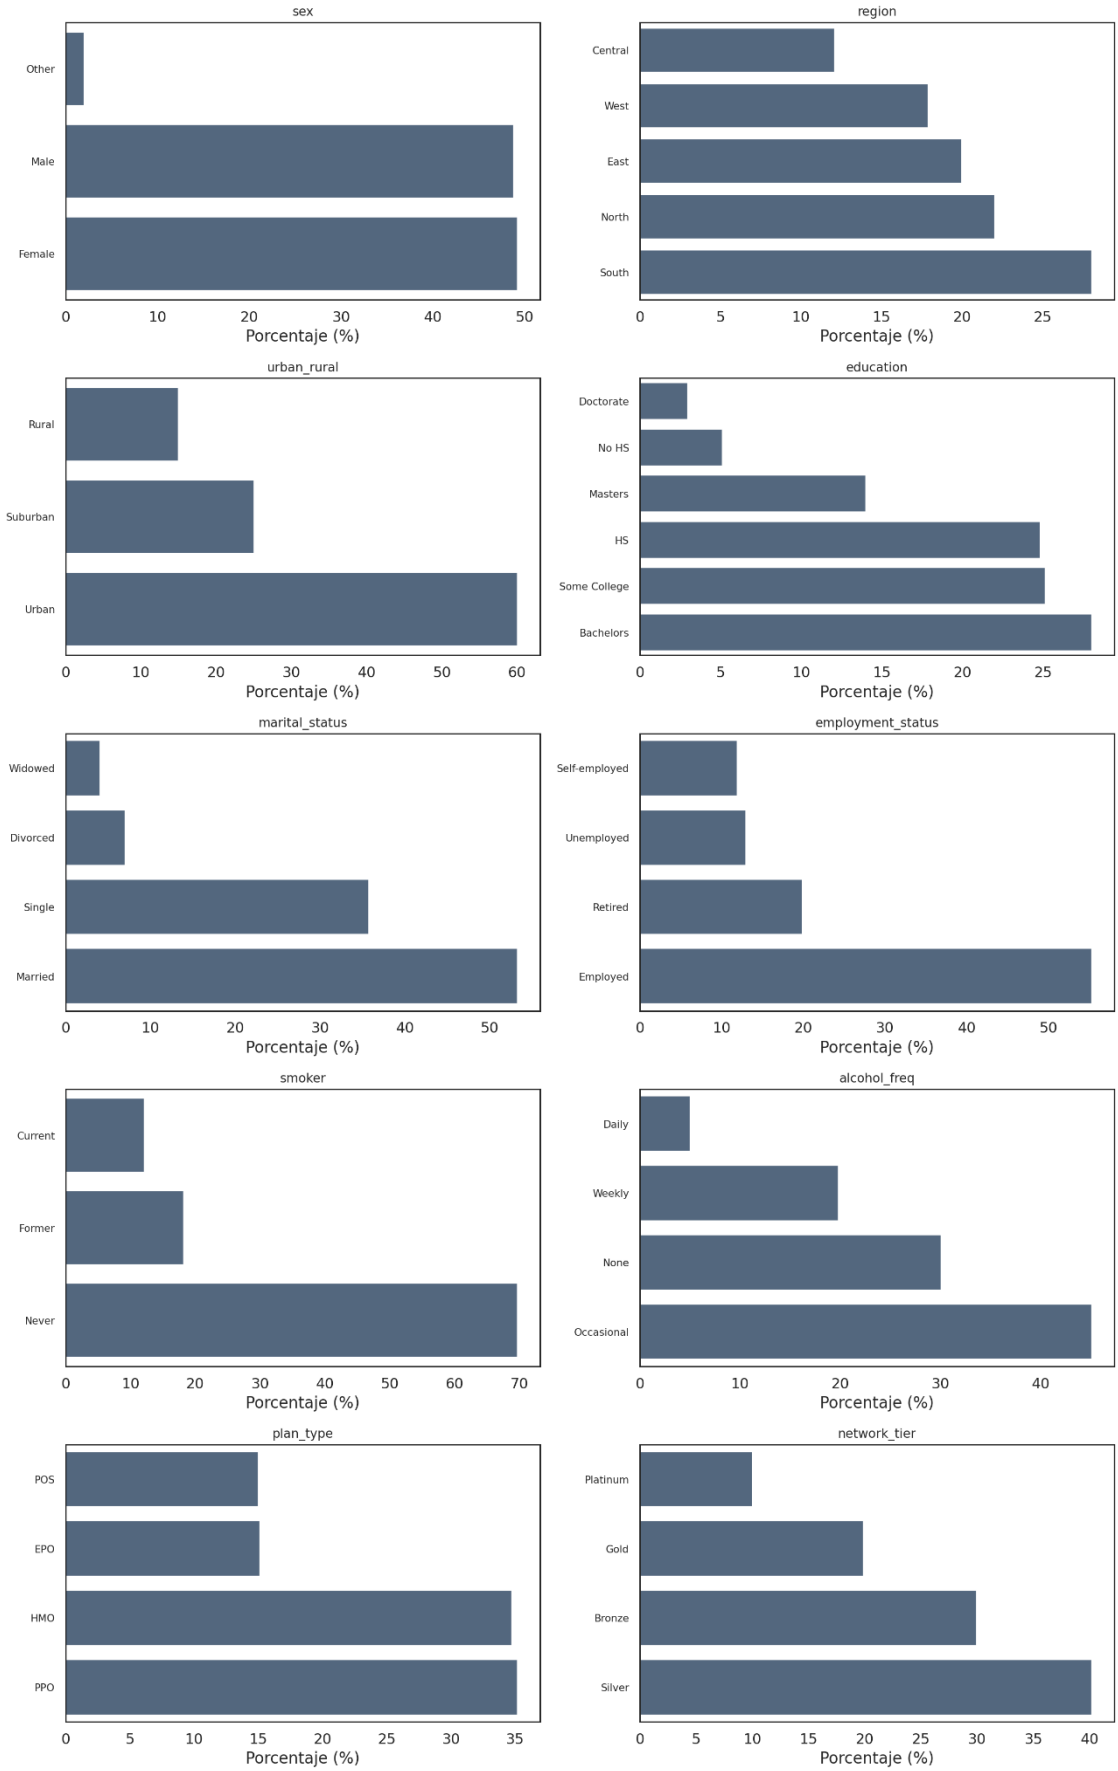

Análisis descriptivo — Variables binarias

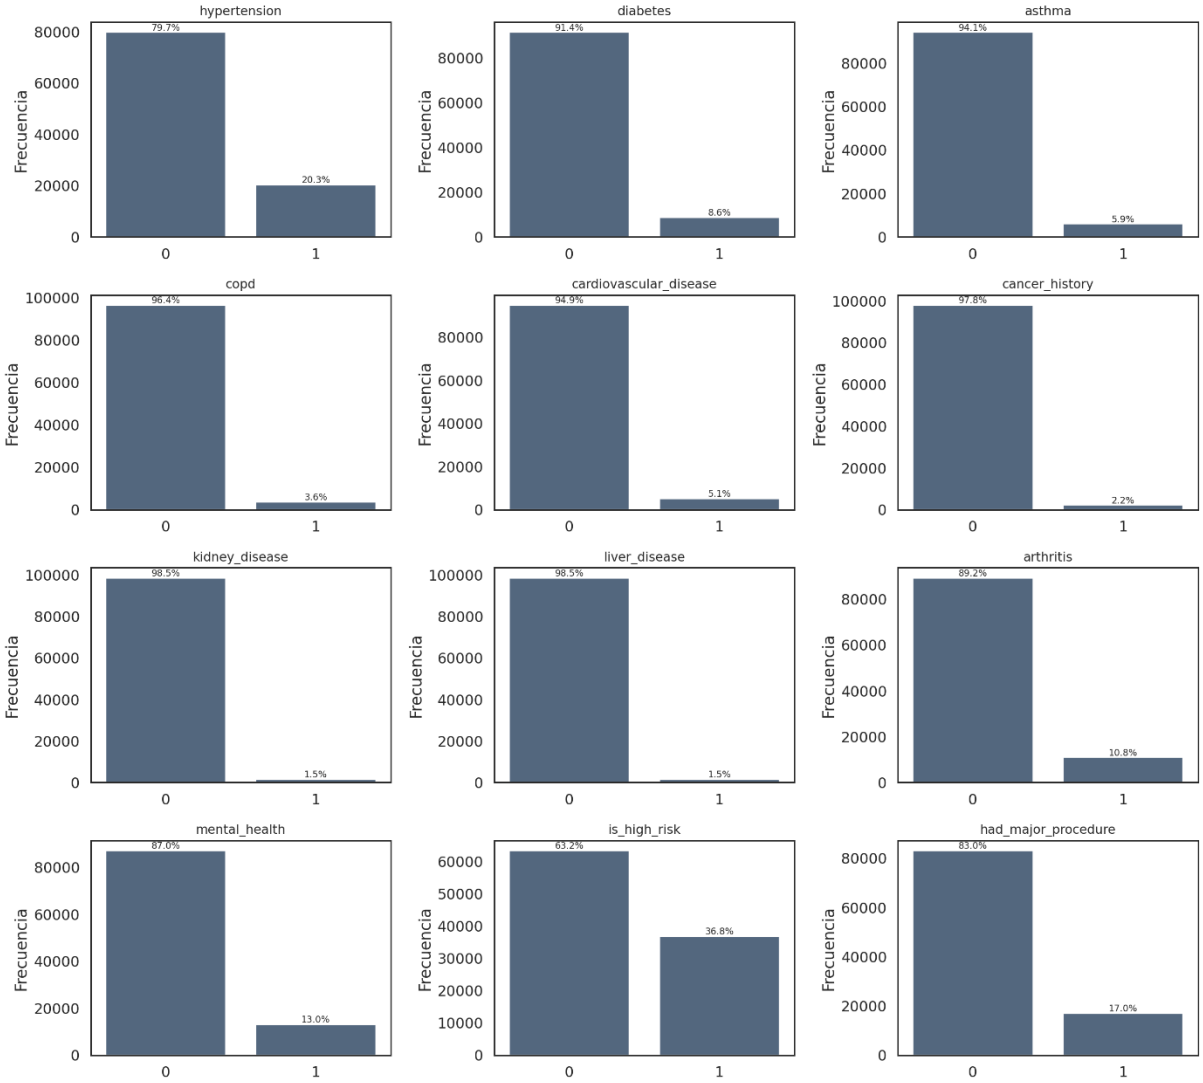

Anexo 3. Matriz de correlaciones entre las variables originales.

Matriz de correlaciones entre las variables originales utilizadas en el Análisis de Componentes Principales. Esta matriz se emplea como punto de partida del PCA, dado que las variables presentan escalas de medida heterogéneas.

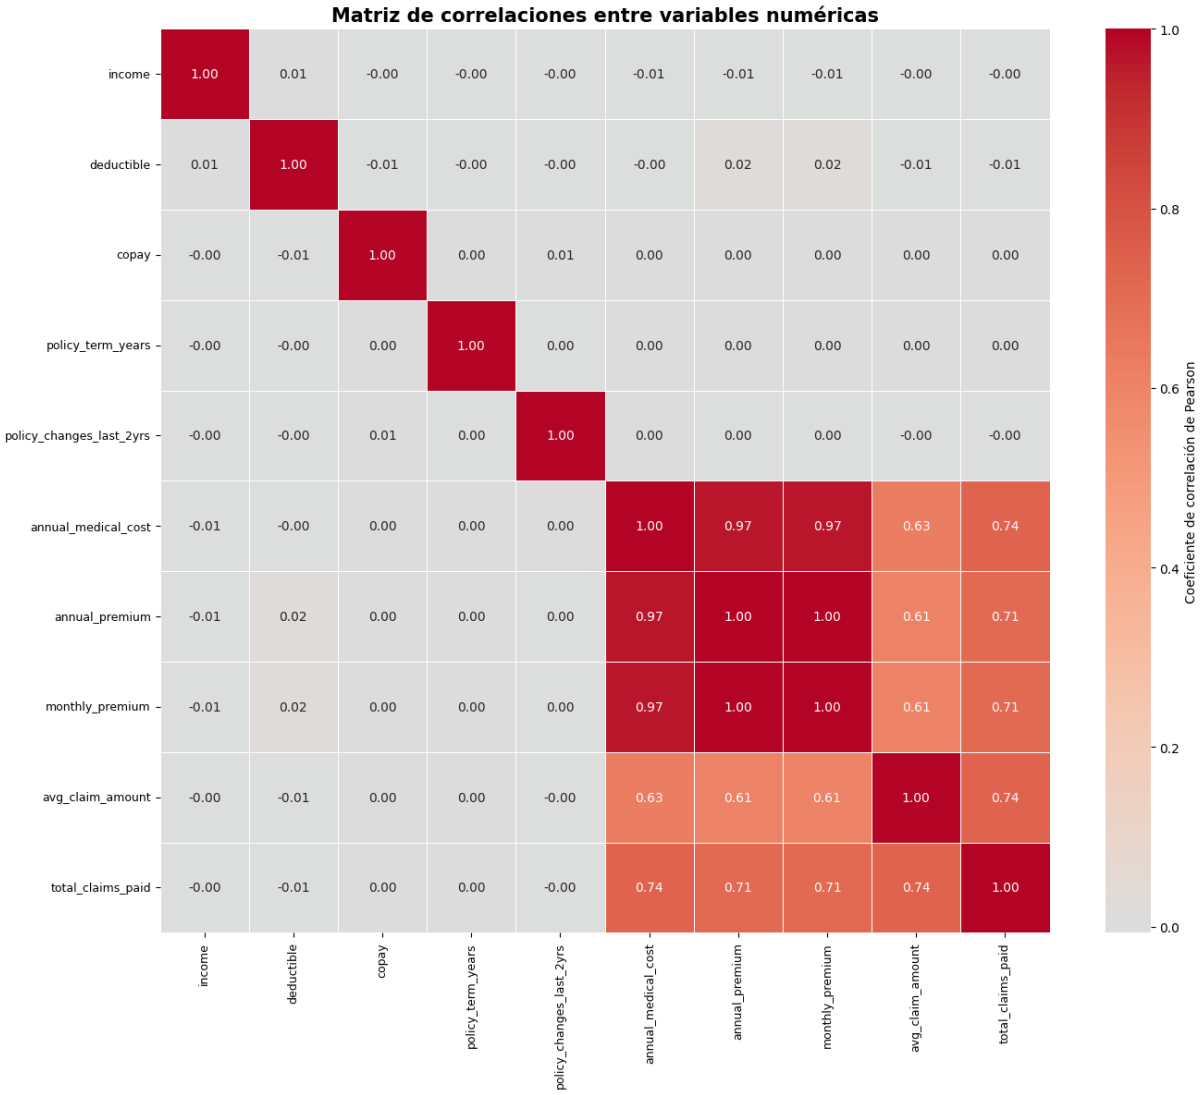

Anexo 4. Análisis de Correspondencia Múltiple.

Tabla 13. Contribución de las categorías a cada dimensión factorial

Categoría	Dim 1	Dim 2	Dim 3	Dim 4	Dim 5	Dim 6	Dim 7	Dim 8
grupo_edad_joven	0.0183	0.0204	0.0315	0.1242	0.5972	0.0598	0.0476	0.0003
grupo_edad_adulto	0.0057	0.0058	0.0062	0.0383	0.1071	0.0007	0.0226	0.0023
grupo_edad_mayor	0.0798	0.0838	0.1024	0.0544	0.0673	0.0575	0.2778	0.0114
patologias_cronicas_ninguna	0.1186	0.0015	0.0212	0.0053	0.0052	0.0009	0.2124	0.0182
patologias_cronicas_alguna	0.1032	0.0013	0.0185	0.0046	0.0045	0.0008	0.1848	0.0159
hospitalizado_no	0.0048	0.0351	0.0000	0.0004	0.0002	0.0000	0.0096	0.0005
hospitalizado_si	0.0488	0.3560	0.0002	0.0036	0.0020	0.0001	0.0977	0.0046
had_major_procedure_0	0.0150	0.0558	0.0025	0.0001	0.0000	0.0002	0.0008	0.0261
had_major_procedure_1	0.0735	0.2728	0.0120	0.0006	0.0000	0.0009	0.0038	0.1275
is_high_risk_0	0.1167	0.0400	0.0006	0.0010	0.0001	0.0002	0.0001	0.0146
is_high_risk_1	0.2005	0.0688	0.0010	0.0017	0.0001	0.0003	0.0001	0.0252
smoker_Current	0.0396	0.0349	0.4736	0.0185	0.0142	0.1032	0.0459	0.0687
smoker_Former	0.0004	0.0030	0.0384	0.3250	0.1403	0.2923	0.0018	0.0141
smoker_Never	0.0053	0.0025	0.1498	0.0549	0.0200	0.0201	0.0124	0.0289
grupo_coste_bajo_coste	0.0510	0.0019	0.0089	0.0351	0.0015	0.0225	0.0002	0.1922
grupo_coste_medio_coste	0.0466	0.0000	0.0023	0.2302	0.0199	0.2403	0.0152	0.1729
grupo_coste_alto_coste	0.0720	0.0166	0.1310	0.1022	0.0204	0.2004	0.0672	0.2767

Tabla 14. Coordenadas de las categorías en las dimensiones factoriales

Categoría	Dim 1	Dim 2	Dim 3	Dim 4	Dim 5	Dim 6
grupo_edad_joven	-0.7449	0.6480	0.7043	1.3794	2.9957	-0.9440
grupo_edad_adulto	-0.1192	0.0993	0.0896	-0.2203	-0.3648	-0.0296
grupo_edad_mayor	1.1048	-0.9345	-0.9035	0.6491	0.7149	0.6581
patologias_cronicas_ninguna	-0.7154	0.0661	0.2186	0.1073	-0.1055	0.0433
patologias_cronicas_alguna	0.6226	-0.0575	-0.1902	-0.0934	0.0918	-0.0377
hospitalizado_no	-0.1030	-0.2296	-0.0042	-0.0198	0.0146	0.0026
hospitalizado_si	1.0456	2.3305	0.0421	0.2009	-0.1485	-0.0265
had_major_procedure_0	-0.1907	-0.3032	0.0557	-0.0125	-0.0003	0.0144
had_major_procedure_1	0.9329	1.4833	-0.2726	0.0614	0.0015	-0.0704
is_high_risk_0	-0.6088	0.2943	0.0306	-0.0402	0.0117	-0.0161
is_high_risk_1	1.0464	-0.5058	-0.0526	0.0691	-0.0201	0.0278
smoker_Current	0.8100	-0.6277	2.0215	0.3937	-0.3415	-0.9175
smoker_Former	-0.0683	0.1502	0.4704	-1.3487	0.8778	1.2616
smoker_Never	-0.1231	0.0701	-0.4743	0.2829	-0.1693	-0.1691
grupo_coste_bajo_coste	-0.3924	-0.0617	-0.1185	0.2315	-0.0468	0.1827
grupo_coste_medio_coste	0.6050	-0.0046	-0.0974	-0.9569	0.2786	-0.9644
grupo_coste_alto_coste	1.3566	0.5381	1.3203	1.1498	-0.5091	1.5880

Anexo 5. Frecuencia de las categorías utilizadas en el MCA combinado con k-means

Tabla 15.Frecuencias Relativas de las Categorías

Variable	Categoría	%
Marital_Status	Married	53.252%
	Single	35.725%
	Divorced	6.984%
	Widowed	4.049%
Smoker	Never	69.709%
	Former	18.163%
	Current	12.128%
Alcohol_freq	Occasional	45.078%
	Weekly	19.833%
	Daily	5.006%
	Never	30.083%

Coordenadas factoriales en MCA + Clustering

Tabla 16. Coordenadas Factoriales de las Variables

Categoría	Dim 1	Dim 2	Dim 3	Dim 4	Dim 5
marital_status_rec_Married	0.5881	-0.1681	0.0565	-0.2874	-0.5341
marital_status_rec_Single	-0.7892	0.2256	-0.0758	0.3856	0.7168
smoker_Current	1.6842	-0.4572	0.6175	1.5469	1.1941
smoker_Former	-0.1063	1.5863	-0.2123	0.8638	-1.0895
smoker_Never	-0.2653	-0.3338	-0.0521	-0.4942	0.0761
alcohol_freq_rec_Never	-0.5250	-0.4002	1.2369	0.3382	-0.4940
alcohol_frec_rec_Occasional	0.0668	-0.3455	-1.0026	0.2879	-0.0802
alcohol_freq_rec_Weekly	0.5147	1.1117	0.3215	-0.9320	0.7437

A partir de la tabla de coordenadas factoriales, se identifica qué categorías discriminan más en cada dimensión atendiendo a los valores más alejados del origen.

1. Categorías más discriminantes en la Dimensión 1 (mayor valor absoluto)
   - smoker_rec__Current (+1.6842) define el extremo positivo del eje.
   - marital_status_rec__Single (−0.7892) y marital_status_rec__Married (+0.5881) estructuran gran parte del contraste en esta dimensión.
   - alcohol_freq_rec__Never (−0.5250) refuerza el polo negativo asociado a bajo/no consumo.
2. Categorías más discriminantes en la Dimensión 2
   - smoker_rec__Former (+1.5863) y alcohol_freq_rec__Weekly (+1.1117) dominan el polo superior de la dimensión.
   - En sentido negativo, smoker_rec__Current (−0.4572) y las categorías de alcohol bajo o nulo (aprox. entre −0.35 y −0.40) consolidan el polo inferior.
3. Categorías cercanas al origen (menor capacidad discriminante en este plano)
   - alcohol_freq_rec__Occasional (x≈0.07; y≈−0.35) y smoker_rec__Never (x≈−0.27; y≈−0.33) presentan coordenadas menos extremas, por lo que aportan matices, pero no determinan por sí solas el eje principal.

En síntesis, la Dimensión 1 queda principalmente definida por smoker_rec__Current y el estado civil, mientras que la Dimensión 2 está dominada por smoker_rec__Former y alcohol_freq_rec__Weekly.

Tabla 17.Contribuciones de las distintas categorías

Categoría	Dim 1	Dim 2	Dim 3	Dim 4	Dim 5
marital_status_rec_Married	0.1962	0.0161	0.0018	0.0476	0.1653
marital_status_rec_Single	0.2633	0.0216	0.0025	0.0639	0.2218
smoker_Current	0.3406	0.0252	0.0463	0.2919	0.1748
smoker_Former	0.0020	0.4539	0.0082	0.1363	0.2180
smoker_Never	0.0486	0.0771	0.0019	0.1712	0.0041
alcohol_freq_rec_Never	0.0821	0.0478	0.4604	0.0346	0.0742
alcohol_frec_rec_Occasional	0.0020	0.0534	0.4533	0.0376	0.0029
alcohol_freq_rec_Weekly	0.0652	0.3049	0.0257	0.2170	0.1389

A partir de la tabla de contribuciones, se puede identificar qué categorías son las que realmente "construyen" cada dimensión, es decir, cuáles aportan más peso a la definición de los ejes.

1. Dimensión 1: Las contribuciones más altas se concentran en:
   - smoker_rec__Current: 0.3406
   - marital_status_rec__Single: 0.2633
   - marital_status_rec__Married: 0.1962

Esto indica que la Dimensión 1 está explicada principalmente por el tabaquismo (ser fumador actual) y por el estado civil (contraste soltero/casado). En cambio, categorías con contribuciones prácticamente nulas en este eje, como smoker_rec__Former (0.0020) o alcohol_freq_rec__Occasional (0.0020), tienen un papel marginal en la definición de esta dimensión.

2. Dimensión 2: En esta dimensión destacan claramente:
   - smoker_rec__Former: 0.4539
   - alcohol_freq_rec__Weekly: 0.3049

Estas dos categorías concentran la mayor parte del peso del eje, mientras que el resto aporta contribuciones secundarias, por ejemplo, smoker_rec__Never (0.0771) y las categorías de alcohol Never u Occasional (en torno a 0.05). Esto sugiere que la Dimensión 2 queda esencialmente definida por el contraste asociado a exfumador y consumo semanal de alcohol, con matices añadidos por las categorías de no fumar y bajo/no consumo.

Denograma Clustering Jerárquico

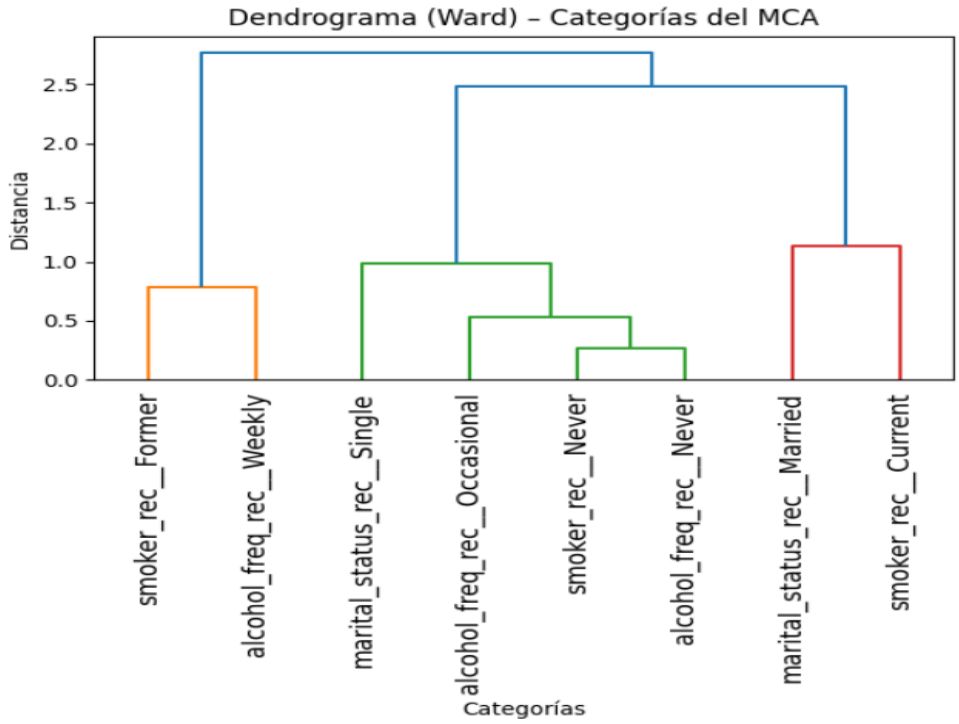

Figura 10. Dendograma del MCA

El dendrograma (método de Ward) resume cómo se van agrupando las categorías del MCA según su similitud: cuanto más baja es la unión (menor "distancia"), más parecidas son. En el gráfico se aprecian tres bloques naturales antes del gran salto de distancia (aprox. por encima de 2–2.5), lo que sugiere una partición estable en 3 grupos.

Por un lado, aparece un cluster muy compacto formado por smoker_rec__Former y alcohol_freq_rec__Weekly, que se unen a baja distancia, indicando un perfil conjunto muy definido. En el extremo opuesto se agrupan marital_status_rec__Married y smoker_rec__Current, también con unión relativamente cercana, reflejando otro patrón diferenciado. Entre ambos queda un grupo intermedio donde marital_status_rec__Single se asocia con alcohol_freq_rec__Occasional y, más cerca, con las categorías de no consumo (smoker_rec__Never y alcohol_freq_rec__Never), formando un bloque más "moderado/abstemio".

Anexo 6. Análisis Discriminante Lineal.

Frecuencia absoluta de los grupos Low, Medium y High definidos a partir de *annual_medical_cost* mediante partición en terciles.

Tabla 18. Distribución de la variable de coste (cost_group)

Grupo	Número de casos
Low	33.333
Medium	33.333
High	33.334
Total	**100.000**

Precisión, recall y F1-score para cada grupo de coste (Low, Medium, High), junto con la precisión global del modelo discriminante con 29 variables.

Tabla 19. Métricas de clasificación por grupo – modelo completo

Clase	Precision	Recall	F1-score	Support
High	0,9801	0,6667	0,7936	33.334
Low	0,6628	0,7479	0,7028	33.333
Medium	0,5328	0,6347	0,5793	33.333
Accuracy	—	—	**0,6831**	100.000
Macro avg	0,7252	0,6831	0,6919	100.000
Weighted avg	0,7252	0,6831	0,6919	100.000

Coeficientes (scalings) de LD1 y LD2 para cada variable predictora incluida en el modelo completo, obtenidos mediante *LinearDiscriminantAnalysis*.

Tabla 20. Coeficientes estandarizados de las funciones discriminantes – modelo completo

Variable	LD1	LD2
age	-0.0531	0.3176
income	0.0114	-0.0218
household_size	0.0003	-0.0724
dependents	0.0009	0.0990
bmi	-0.0509	0.2568
systolic_bp	0.0072	0.0374
diastolic_bp	-0.0050	0.0317
ldl	0.0119	0.0644
hba1c	0.0014	-0.0157
chronic_count	-0.1594	0.5323
medication_count	-0.0107	0.0294
hypertension	-0.0143	0.0137
diabetes	0.0041	-0.0266
cardiovascular_disease	0.0031	0.0124
is_high_risk	-0.0962	0.0776
visits_last_year	-0.0551	0.2071
hospitalizations_last_3yrs	-0.0528	0.3307
days_hospitalized_last_3yrs	-0.0414	-0.2074
proc_imaging_count	0.0038	-0.0492
proc_surgery_count	0.0023	-0.0263
proc_consult_count	-0.0053	0.0129
proc_lab_count	-0.0033	-0.0097
proc_physio_count	0.0061	-0.0211
deductible	0.0286	-0.0085
copay	0.0056	0.0115
claims_count	-0.1004	0.2998
avg_claim_amount	-0.2692	0.4772
total_claims_paid	0.3060	-1.1549

annual_premium	-1.2658	-0.0255

Correlaciones entre las variables originales y las funciones discriminantes LD1 y LD2, ordenadas según la carga absoluta en LD1.

Tabla 21. Matriz de estructura – modelo completo

Variable	LD1	LD2
annual_premium	-0.9695	-0.2166
total_claims_paid	-0.7076	-0.3009
avg_claim_amount	-0.6564	-0.1393
chronic_count	-0.4408	0.5395
is_high_risk	-0.3917	0.5126
visits_last_year	-0.2864	0.3068
days_hospitalized_last_3yrs	-0.2759	0.0273
hospitalizations_last_3yrs	-0.2587	0.0997
claims_count	-0.2556	0.2278
hypertension	-0.2351	0.3185
systolic_bp	-0.2251	0.3982
age	-0.2089	0.4178
diastolic_bp	-0.1853	0.3021
medication_count	-0.1768	0.2394
diabetes	-0.1549	0.1462
hba1c	-0.1214	0.1083
cardiovascular_disease	-0.1139	0.1580
proc_surgery_count	-0.1127	0.1127
bmi	-0.0813	0.2473
proc_lab_count	-0.0762	0.0754
proc_consult_count	-0.0751	0.0979
proc_imaging_count	-0.0750	0.0328
proc_physio_count	-0.0603	0.0640
ldl	-0.0234	0.1202
income	0.0126	-0.0143
household_size	-0.0037	0.0099

dependents	-0.0029	0.0308
copay	0.0027	0.0068
deductible	0.0009	-0.0057

Coeficientes (scalings) de LD1 y LD2 para las siete variables seleccionadas (*annual_premium, chronic_count, is_high_risk, avg_claim_amount, total_claims_paid, claims_count, hospitalizations_last_3yrs*).

Tabla 22. Coeficientes estandarizados de las funciones discriminantes – modelo stepwise

Variable	LD1	LD2
annual_premium	-1.2690	0.0010
chronic_count	-0.1575	0.5131
is_high_risk	-0.1364	0.3929
avg_claim_amount	-0.2749	0.5490
total_claims_paid	0.3050	-1.2788
claims_count	-0.1360	0.4818
hospitalizations_last_3yrs	-0.0881	0.1577

Correlaciones entre las variables del modelo reducido y las funciones discriminantes LD1 y LD2, destacando las cargas asociadas a la dimensión económica y a la carga de enfermedad / utilización.

Tabla 23. Matriz de estructura – modelo stepwise

Variable	LD1	LD2
annual_premium	-0.9714	-0.2180
total_claims_paid	-0.7090	-0.3165
avg_claim_amount	-0.6577	-0.1395
chronic_count	-0.4413	0.6042
is_high_risk	-0.3921	0.5735
hospitalizations_last_3yrs	-0.2591	0.1154
claims_count	-0.2560	0.2566

Anexo 7. PCA combinado con análisis de regresión.

La validación del modelo se descompone en tres bloques principales: normalidad, independencia y homocedasticidad de los residuos.

Normalidad:

En primer lugar, la normalidad de los residuos se analizó a partir de los gráficos de probabilidad acumulada (P–P plots) y de los estadísticos descriptivos básicos de los errores. En las Figuras 11 y 12, correspondientes respectivamente al modelo con variables fisiológicas y al modelo basado en componentes principales, se observa que los puntos se apartan de forma clara de la diagonal teórica, especialmente en los extremos de la distribución, lo que pone de manifiesto que los residuos no siguen una distribución normal. Este comportamiento se traduce en una fuerte asimetría y en la presencia de colas largas, características que se reflejan visualmente en la acumulación de puntos en determinadas regiones del gráfico.

No obstante, los residuos presentan media prácticamente nula, cumpliéndose la propiedad de media cero de los errores propia de los modelos estimados mediante mínimos cuadrados ordinarios con término independiente. Asimismo, la falta de normalidad observada resulta coherente con la naturaleza del coste médico anual, una variable fuertemente asimétrica y dominada por valores extremos asociados a individuos con gastos sanitarios elevados, lo que dificulta el cumplimiento estricto de este supuesto.

En resumen, aunque la hipótesis de normalidad de los residuos no se satisface, este resultado no invalida el análisis realizado y debe interpretarse como una limitación inherente al fenómeno estudiado.

```
==================== DIAGNÓSTICO RESIDUOS ====================
Media(residuos) = 0.000000
Var(residuos)   = 8856344.965301
Durbin-Watson   = 2.0063  (≈2 sugiere no autocorrelación)
```

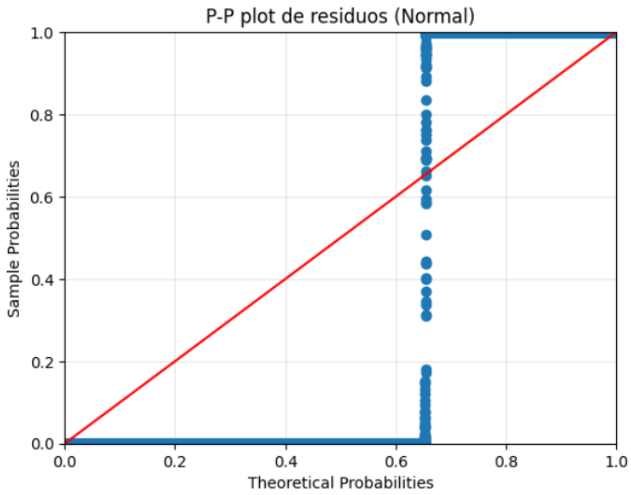

Figura 11. Gráfico P-P de los residuos del modelo con las variables fisiológicas.

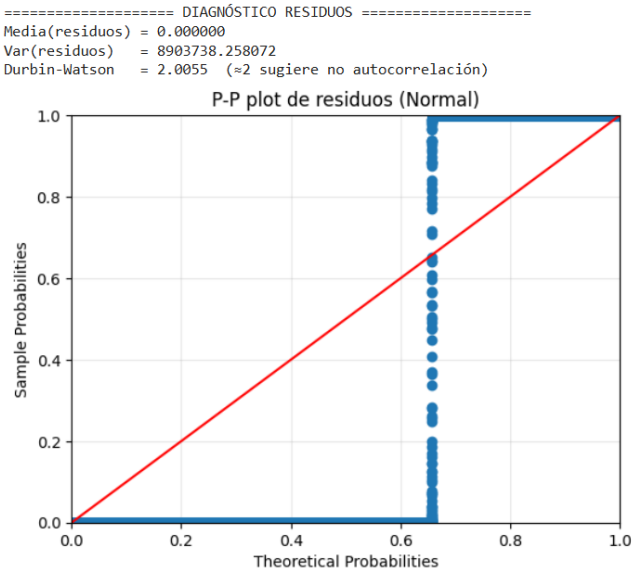

Figura 12. Gráfico P-P de los residuos del modelo con las componentes principales.

Independencia:

En cuanto a la independencia de los errores, ésta se evaluó mediante la representación gráfica de los residuos en función del orden de aparición de las observaciones, junto con el análisis del estadístico de Durbin–Watson. Tal y como se observa en las Figuras 13 y 14, correspondientes a ambos modelos considerados, los residuos se distribuyen de forma aleatoria alrededor del valor cero a lo largo de todo el índice de observación, sin apreciarse tendencias, agrupamientos sistemáticos ni patrones cíclicos que indiquen la presencia de autocorrelación. Este resultado se ve reforzado por los valores del estadístico de Durbin–Watson, próximos a 2 en ambos casos, lo que sugiere ausencia de autocorrelación serial de primer orden.

Por otro lado, la presencia de residuos positivos de gran magnitud frente a residuos negativos relativamente más acotados responde a la propia naturaleza del coste médico anual, ya que, mientras que el gasto real no puede tomar valores negativos, el modelo puede infraestimar de forma considerable ciertos casos de gasto elevado, generando residuos positivos grandes, mientras que los residuos negativos se encuentran limitados inferiormente.

En definitiva, tanto el análisis gráfico como el contraste estadístico permiten considerar razonablemente satisfecha la hipótesis de independencia de los errores en ambos modelos.

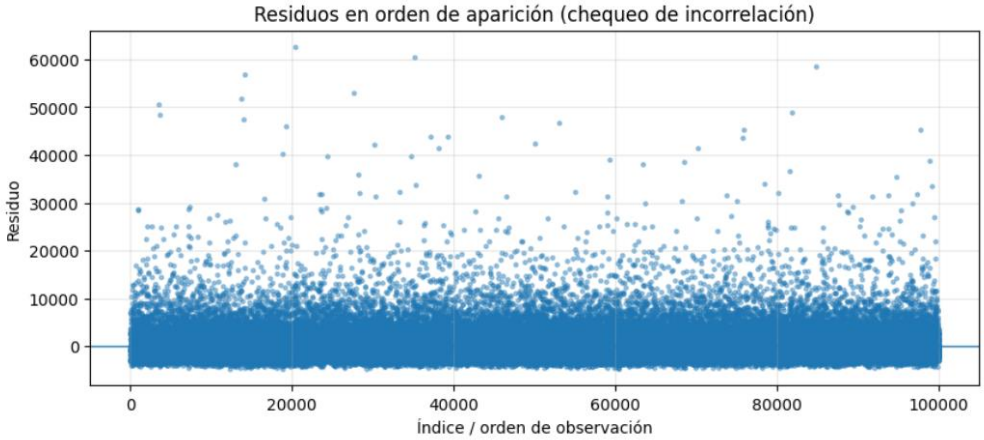

Figura 13. Residuos en función del orden de observación para el modelo con las variables fisiológicas.

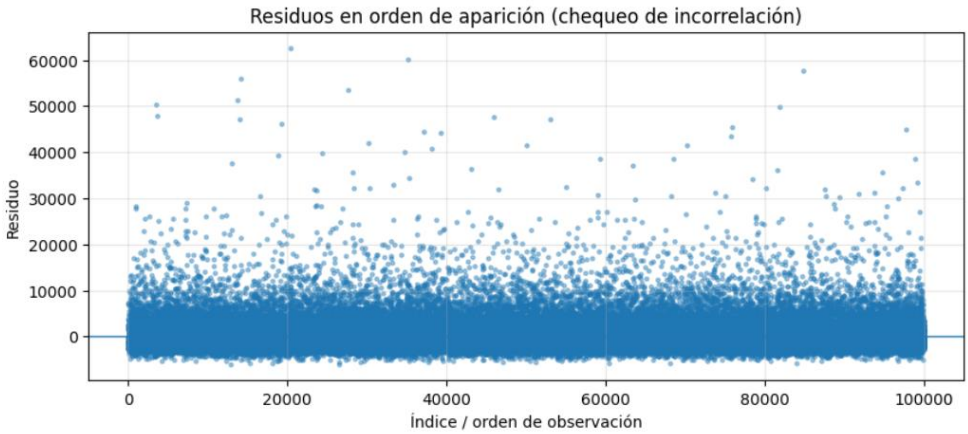

Figura 14. Residuos en función del orden de observación para el modelo con las componentes principales.

Homocedasticidad:

Para último, la homocedasticidad de los errores se evaluó mediante una regresión auxiliar de los residuos al cuadrado respecto a las variables explicativas incluidas en cada uno de los modelos considerados. Los resultados obtenidos, mostrados en las Figuras X e Y, indican que el modelo auxiliar resulta globalmente significativo en ambos casos, lo que sugiere que la varianza de los errores depende del nivel de las variables explicativas. Si bien el coeficiente de determinación de dicha regresión es reducido, este hecho es coherente con el elevado tamaño muestral del estudio, que permite detectar relaciones estadísticamente significativas incluso cuando la proporción de varianza explicada es limitada.

En conclusión, los resultados ponen de manifiesto que la hipótesis de homocedasticidad no se cumple estrictamente en ninguno de los dos modelos. Sin embargo, este comportamiento es consistente con la naturaleza del coste médico anual, caracterizado por una elevada heterogeneidad entre individuos, especialmente en aquellos perfiles asociados a mayores niveles de gasto sanitario, por lo que la presencia de heterocedasticidad debe interpretarse como una característica estructural del fenómeno analizado y no como una deficiencia de la especificación del modelo.

```
==================== REGRESIÓN AUXILIAR: residuos^2 ~ X ====================
                            OLS Regression Results
==============================================================================
Dep. Variable:                      y   R-squared:                       0.010
Model:                            OLS   Adj. R-squared:                  0.010
Method:                 Least Squares   F-statistic:                     261.3
Date:                Sat, 24 Jan 2026   Prob (F-statistic):          9.33e-224
Time:                        17:30:21   Log-Likelihood:            -1.9213e+06
No. Observations:              100000   AIC:                         3.843e+06
Df Residuals:                   99995   BIC:                         3.843e+06
Df Model:                           4
Covariance Type:            nonrobust
==============================================================================
                 coef    std err          t      P>|t|      [0.025      0.975]
------------------------------------------------------------------------------
const      -9.003e+06    1.6e+06     -5.639      0.000   -1.21e+07   -5.87e+06
risk_score  2.061e+07   6.93e+05     29.754      0.000    1.92e+07     2.2e+07
hba1c       1.246e+06   2.03e+05      6.132      0.000    8.48e+05    1.64e+06
bmi         -366.2240    3.4e+04     -0.011      0.991   -6.71e+04    6.63e+04
ldl         1432.9061   5605.553      0.256      0.798   -9553.909    1.24e+04
==============================================================================
Omnibus:                   260756.493   Durbin-Watson:                   2.007
Prob(Omnibus):                  0.000   Jarque-Bera (JB):       8467144965.477
Skew:                          30.379   Prob(JB):                         0.00
Kurtosis:                    1427.227   Cond. No.                     1.20e+03
==============================================================================
```

Figura 15. Regresión auxiliar de los residuos² para el análisis de la homocedasticidad (variables fisiológicas).

```
==================== REGRESIÓN AUXILIAR: residuos^2 ~ X ====================
                            OLS Regression Results
==============================================================================
Dep. Variable:                      y   R-squared:                       0.011
Model:                            OLS   Adj. R-squared:                  0.011
Method:                 Least Squares   F-statistic:                     281.4
Date:                Sat, 24 Jan 2026   Prob (F-statistic):          4.67e-241
Time:                        17:29:14   Log-Likelihood:            -1.9210e+06
No. Observations:              100000   AIC:                         3.842e+06
Df Residuals:                   99995   BIC:                         3.842e+06
Df Model:                           4
Covariance Type:            nonrobust
==============================================================================
                 coef    std err          t      P>|t|      [0.025      0.975]
------------------------------------------------------------------------------
const       8.904e+06   1.68e+05     52.855      0.000    8.57e+06    9.23e+06
CP1         2.933e+06   9.97e+04     29.408      0.000    2.74e+06    3.13e+06
CP2         2.493e+06   1.55e+05     16.034      0.000    2.19e+06     2.8e+06
CP3         2.389e+05   1.68e+05      1.425      0.154   -8.97e+04    5.68e+05
CP4         2.208e+05   1.69e+05      1.307      0.191    -1.1e+05    5.52e+05
==============================================================================
Omnibus:                   259532.271   Durbin-Watson:                   2.006
Prob(Omnibus):                  0.000   Jarque-Bera (JB):       8101263370.598
Skew:                          30.020   Prob(JB):                         0.00
Kurtosis:                    1396.090   Cond. No.                         1.69
==============================================================================

Notes:
[1] Standard Errors assume that the covariance matrix of the errors is correctly specified.
```

Figura 16. Regresión auxiliar de los residuos² para el análisis de la homocedasticidad (componentes principales).