

Análisis y modelización predictiva de la generación eólica mensual en España 2020–2024

Rafael Macian Castilla, Patricia Rodrigo Barrio y Víctor Rodríguez Albendea
Universitat Politècnica de València, Valencia, España

Resumen

En este trabajo se presenta el análisis de una serie temporal de generación eólica mensual en España con el objetivo de predecir su evolución futura a partir de datos comprendidos entre 2020 y 2024. El tratamiento de la serie incluye un análisis descriptivo detallado mediante descomposición STL, la comparación de distintos modelos de suavizado deterministas (SES, Holt y Holt-Winters) y la construcción de un modelo ARIMA estacional siguiendo la metodología Box–Jenkins. Finalmente, se selecciona y valida un modelo $ARIMA(0,0,4)(1,1,0)_{12}$ ajustado sobre la serie transformada mediante Box–Cox, que se utiliza para realizar predicciones mensuales y evaluar su utilidad en la planificación del sistema eléctrico.

1. Introducción

La energía eólica se ha consolidado en la última década como una de las principales fuentes renovables del sistema eléctrico español, desempeñando un papel clave en la transición energética y en la reducción de emisiones asociadas a la generación convencional. Según datos de Red Eléctrica de España, la eólica no solo aporta un porcentaje creciente del mix eléctrico, sino que además presenta una variabilidad significativa asociada a las condiciones meteorológicas que la hacen especialmente interesante desde la perspectiva del análisis y la predicción [1].

La producción eólica está fuertemente condicionada por patrones atmosféricos de escala diaria, mensual y estacional. Estudios como el de García-Bustamante et al. confirman que la variabilidad del viento en la península ibérica responde a la dinámica de la circulación atmosférica europea, generando ciclos claros que afectan directamente a la generación eléctrica renovable [2].

En este contexto, la previsión de la generación eólica adquiere un papel estratégico. Tal y como señala la International Energy Agency, la integración eficiente de energías renovables exige sistemas de predicción robustos capaces de anticipar las fluctuaciones del recurso eólico, especialmente en horizontes temporales cortos [3]. Modelizar la evolución temporal de la generación eólica permite mejorar la planificación operativa, optimizar el uso de tecnologías de respaldo y aumentar la fiabilidad del sistema eléctrico.

Con estos motivos, en el presente trabajo se analiza una serie temporal mensual correspondiente a la generación total real eólica nacional (MW) entre enero de 2020 y diciembre de 2024, obtenida de la plataforma ESIOS de Red Eléctrica de España. El análisis desarrollado se estructura en varias etapas: en primer lugar, se lleva a cabo un estudio descriptivo detallado de la serie, identificando sus componentes fundamentales. Posteriormente, se ajustan distintos modelos deterministas de suavizado con el fin de evaluar su capacidad predictiva. A continuación, se construye un modelo ARIMA siguiendo la metodología clásica Box–Jenkins, validando rigurosamente los residuos y comparando modelos alternativos. Finalmente, se emplea el modelo óptimo para realizar predicciones y discutir los resultados obtenidos.

El objetivo final es obtener un modelo predictivo sólido y parsimonioso que capture de forma adecuada la dinámica temporal de la generación eólica y aporte información valiosa para la toma de decisiones en el ámbito energético.

1.1. Datos de la serie

La serie temporal empleada en este análisis recoge la generación total real eólica nacional en España, medida en megavatios (MW) y proporcionada por la plataforma oficial ESIOS de Red Eléctrica de España.

Los datos originales se registran cada cinco minutos, pero para este estudio se han agregado a frecuencia mensual, con el fin de obtener una serie más estable y adecuada para las técnicas de análisis y predicción utilizadas en la asignatura.

El periodo analizado abarca desde enero de 2020 hasta diciembre de 2024, lo que proporciona un total de 60 observaciones mensuales. Esta información constituye la base del estudio, permitiendo evaluar la evolución del recurso eólico a lo largo de cinco años caracterizados por una notable variabilidad atmosférica.

El primer paso en el tratamiento de una serie temporal consiste en visualizar sus valores frente al tiempo, ya que esta representación inicial permite detectar posibles patrones de tendencia, estacionalidad, cambios de nivel o variaciones en la amplitud. En la Figura 1 se muestra la evolución mensual de la generación eólica durante el periodo estudiado.

Evolución mensual de la generación eólica en España (2020–2024)




Figura 1. Serie temporal de generación eólica mensual en España

1.2. Análisis descriptivo

Una vez visualizada la serie temporal, el siguiente paso consiste en estudiar sus componentes estructurales. De forma general, toda serie temporal puede descomponerse en cuatro elementos fundamentales:

- **Tendencia (T):** evolución a largo plazo.
- **Componente estacional (S):** patrones que se repiten con periodicidad fija, típicamente anual.
- **Componente cíclica (C):** oscilaciones de mayor duración asociadas a factores externos o macroestructurales.

- **Componente irregular o aleatoria (I):** fluctuaciones imprevisibles que no siguen patrones sistemáticos.

Para analizar estas componentes, se ha utilizado la descomposición STL (*Seasonal-Trend decomposition using Loess*) implementada en R mediante la función `stl()`. Esta metodología permite separar de forma flexible las variaciones estacionales, la tendencia suave y los residuos. El resultado se muestra en la Figura 2.




Figura 2. Descomposición STL de la generación eólica mensual

La componente de tendencia refleja la evolución a largo plazo de la generación eólica. En la serie se observa que:

- Entre 2020 y mediados de 2021, la tendencia muestra un crecimiento sostenido, indicando un aumento progresivo en los niveles medios de generación eólica.
- A partir de 2022 y hasta mediados de 2023, la tendencia permanece relativamente estable, con pequeñas oscilaciones.
- Durante 2024, la tendencia muestra una ligera disminución, aunque sin descensos bruscos.

En conjunto, la tendencia indica que la producción eólica mensual se ha mantenido en un nivel medio elevado y estable, con variaciones moderadas a lo largo del periodo analizado.

La componente estacional recoge los patrones que se repiten cada 12 meses, característicos de series energéticas muy dependientes de las condiciones climáticas.

En esta serie, la estacionalidad es marcada, regular y perfectamente reconocible:

- Máximos en los meses fríos (noviembre–marzo), coincidiendo con mayor actividad de viento.
- Mínimos en los meses cálidos (junio–agosto), coincidiendo con periodos de menor actividad atmosférica.

Estos ciclos se repiten prácticamente de manera idéntica cada año, lo que es coherente con estudios climáticos sobre la variabilidad del viento en España [2].

La componente aleatoria o irregular contiene las fluctuaciones no explicadas por la tendencia ni la estacionalidad [4][5]. En la serie se aprecian:

- Picos puntuales, tanto positivos como negativos, asociados a anomalías atmosféricas (temporales intensos, periodos anticiclónicos prolongados, etc.).
- Ausencia de un patrón sistemático, lo que indica que la estructura principal de la serie está bien capturada por las otras dos componentes.
- Una magnitud de residuos relativamente constante a lo largo del tiempo, lo que sugiere estabilidad en la varianza y ausencia de cambios estructurales relevantes.

La descomposición STL confirma que la serie presenta una estacionalidad anual muy fuerte y una tendencia suave y estable, por lo que se justifica plenamente el uso posterior de modelos deterministas estacionales (como Holt–Winters) y modelos ARIMA estacionales con periodo $s = 12$.

2. Modelos deterministas

Los modelos deterministas para la predicción de series temporales se basan en la existencia de patrones sistemáticos en los datos históricos, asumiendo que dichos patrones pueden describirse mediante ecuaciones que no dependen del componente aleatorio de la serie [4][5]. Su objetivo principal es explicar la evolución pasada y proyectar valores futuros a partir de estructuras temporales como la tendencia o la estacionalidad.

Este tipo de modelos considera que la tendencia evoluciona de manera determinista en función del tiempo y se dividen principalmente en dos familias:

- Medias móviles, que suavizan la serie mediante promedios sucesivos.
- Métodos de suavizado exponencial, que otorgan mayor peso a las observaciones más recientes.

La elección del modelo adecuado depende del comportamiento de la serie analizada, y su idoneidad se evalúa mediante el análisis de los errores de predicción, comparando distintas configuraciones para seleccionar la que proporcione mejor precisión.

2.1. Pre – selección de modelos válidos

Los modelos de suavizado mediante medias móviles resultan apropiados cuando la serie no presenta ni una tendencia marcada ni patrones estacionales definidos [4][5]. Sin embargo, en el caso de la serie de generación eólica mensual, estas condiciones no se cumplen, ya que la serie muestra una tendencia suavemente variable a lo largo del periodo y una estacionalidad muy clara con periodicidad anual.

Por ello, se descarta la aplicación de modelos basados exclusivamente en medias móviles para la predicción de esta serie.

Por otro lado, los modelos de suavizado exponencial asignan pesos decrecientes a las observaciones históricas en función de su cercanía temporal, modulados mediante sus constantes de suavizado [4]. Este enfoque permite incorporar información sobre la tendencia y la estacionalidad, lo que los convierte en una herramienta adecuada para series con estructuras temporales más complejas.

Dentro de los modelos de suavizado exponencial se distinguen tres variantes principales:

- Suavizado Exponencial Simple (SES): adecuado para series sin tendencia ni estacionalidad.
- Modelo de Holt (suavizado exponencial doble), el cual incorpora tendencia.
- Modelo de Holt-Winters (suavizado exponencial triple): incorpora tendencia y estacionalidad.

Dado que la serie analizada presenta estacionalidad anual pronunciada y una tendencia suavizada, se preseleccionan como modelos válidos para su predicción las versiones de Holt y Holt-Winters, mientras que el modelo SES queda descartado por no contemplar estos componentes.

2.2. Análisis de los modelos

Previo al análisis de los modelos deterministas preseleccionados, es importante señalar que, con el fin de evaluar adecuadamente el error de predicción, se ha optado por realizar las predicciones utilizando los primeros 55 valores de los 60 disponibles. De esta forma, los últimos cinco valores de la serie se reservan como muestra de validación, lo que permite comparar las predicciones generadas por cada modelo con los valores reales y analizar su capacidad predictiva.

2.2.1. Modelo de suavizado exponencial

El modelo de suavizado exponencial simple se basa en actualizar la predicción en función del valor observado más reciente y del error cometido en el periodo anterior [4][5]. Para ello, utiliza una constante de suavizado α , que determina el peso que recibe la observación más reciente:

$$F_{t+1} = \alpha Y_t + (1 - \alpha)F_t$$

Ecuación 1. Modelo del suavizado exponencial simple

donde F_t es la predicción en el instante t , F_{t+1} la predicción para el periodo siguiente, Y_t el valor observado y una constante de suavizado (α) que oscila entre 0 y 1. Cuanto mayor es el valor de α , más peso se otorga a los valores recientes; cuando α es pequeño, el modelo suaviza fuertemente y reacciona con lentitud ante cambios en la serie.

En la Figura 3 se muestra el resultado del ajuste del modelo SES aplicado a la serie de generación eólica mensual, mientras que en la Figura 4 se representa la descomposición del modelo en sus componentes internos (nivel y predicción).




Figura 3. Serie temporal junto con la predicción mediante suavizado exponencial simple (línea roja)




Figura 4. Componentes del modelo SES: nivel y $xhat$

Tras aplicar el modelo de suavizado exponencial simple, se observa en la Figura 3 que la serie predicha (línea roja) no reproduce adecuadamente la estructura temporal real de la generación eólica mensual. Aunque el modelo trata de seguir los valores observados, las predicciones presentan oscilaciones que no llegan a captar ni la magnitud ni el patrón estacional característico de la serie.

El valor estimado de la constante de suavizado es:

$$\alpha = 0,6957929$$

Este valor relativamente alto indica que el modelo da un peso considerable a las observaciones más recientes, reaccionando de forma rápida ante los cambios en la serie. Sin embargo, a pesar de esta capacidad de reacción no consigue capturar los picos máximos eólicos, no reproduce los mínimos estacionales característicos de los meses de verano y genera predicciones con demasiada variabilidad, que oscilan sin reflejar la estructura real subyacente.

La Figura 4, que muestra los componentes $xhat$ y $level$, evidencia que el modelo intenta ajustarse a los valores observados, pero aun así no logra representar correctamente ni la tendencia ni el patrón estacional anual que caracteriza a esta serie energética.

En conjunto, el modelo de suavizado exponencial simple no resulta adecuado para esta serie, ya que no contempla la estacionalidad ni la tendencia suave que la definen, lo que limita claramente su capacidad predictiva.

2.2.2. Modelo de Holt

El modelo de Holt, o modelo de suavizado exponencial doble, extiende el suavizado simple incorporando una segunda ecuación destinada a capturar la tendencia de la serie temporal [4][5]. Para ello utiliza dos parámetros de suavizado (α y β) que permiten actualizar simultáneamente el nivel y la pendiente estimada en cada instante. El modelo se expresa mediante las siguientes ecuaciones:

$$L_t = \alpha Y_t + (1 - \alpha)(L_{t-1} + b_{t-1})$$

$$b_{t-1} = \beta(L_t - L_{t-1}) + (1 - \beta)b_{t-1}$$

$$F_{t+m} = L_t + b_t m$$

Ecuación 2. Modelo de Holt o suavizado exponencial doble

Siendo L_t la estimación del nivel de la serie y b_t la estimación de la pendiente en el instante t . De este modo, la predicción a m pasos vista se obtiene como la suma del nivel y la tendencia proyectada. El resultado de aplicar el modelo de Holt en la serie temporal es:




Figura 5. Serie temporal y ajuste del modelo de Holt (línea roja).

Valores ajustados por el modelo Holt




Figura 6. Componentes del modelo de Holt: $xhat$, nivel y tendencia.

El ajuste del modelo de Holt muestra que la serie suavizada (línea roja) sigue parcialmente la evolución de los valores observados, aunque sin llegar a reproducir la variabilidad completa de la serie. El parámetro estimado para el nivel es relativamente alto ($\alpha = 0,6976$), lo que hace que el modelo responda con rapidez a los cambios recientes. Por el contrario, el valor $\beta = 0$ indica que no se detecta una tendencia lineal significativa, lo que se refleja en una componente de pendiente completamente plana. Como resultado, el modelo actúa de forma muy similar al suavizado exponencial simple, ajustando el nivel, pero sin incorporar información sobre tendencia.

2.2.3. Modelo de Holt -Winters

El modelo de Holt-Winters es una extensión del modelo de suavizado exponencial doble que incorpora explícitamente la estacionalidad dentro de la estructura de suavizado. Esto lo convierte en un método especialmente adecuado cuando la serie presenta simultáneamente nivel, tendencia y estacionalidad, como ocurre en nuestra serie de generación eólica mensual. La diferencia fundamental respecto al modelo de Holt es la inclusión de una tercera ecuación destinada a capturar la estacionalidad, que puede modelarse de forma aditiva o multiplicativa.

En nuestro caso, debido a la gran presencia de ruido en la serie, consideramos que la estacionalidad es aditiva, ya que la amplitud de los ciclos se mantiene aproximadamente constante y no depende proporcionalmente del nivel de la serie, tal y como se aprecia en la descomposición STL previamente analizada.

Por ello, el modelo Holt-Winters empleado es el de estructura aditiva, cuyas ecuaciones son:

$$\text{nivel: } L_t = \alpha(Y_t - S_t - s) + (1 - \alpha)(L_t - 1 + b_t - 1)$$

$$\text{tendencia: } b_t = \beta(L_t - L_{t-1}) + (1 - \beta)b_{t-1}$$

$$\text{estacionalidad: } S_t = \gamma(Y_t - L_t) + (1 - \gamma)S_{t-s}$$

$$\text{predicción: } \hat{Y}_{t+m} = L_t + m b_t + S_{t-s+m}$$

Ecuación 3. Modelo de Holt Winters con estacionalidad aditiva

De este modelo, s es el número de periodos que abarca la estacionalidad, L_t es nivel de la serie, b_t es la tendencia de la serie, S_t es la componente estacional y F_{t+m} es la predicción a m periodos.

En este tipo de modelos es posible quedarse en un óptimo local, en vez de encontrar el óptimo global. Es por ello por lo que se prueba con varios valores de las constantes de suavizado para comprobar que no se queda estancado en un óptimo local antes de buscar las constantes de suavizado óptimas para el modelo.

Tras realizar el análisis tanto gráfico como numérico del modelo de Holt-Winters, cuyos resultados completos se recogen en el Anexo 2, se evaluó la estabilidad del proceso de optimización utilizando dos aproximaciones distintas:

- (i) el comando `HoltWinters()` de la librería base de R
- (ii) el procedimiento automático del paquete `forecast`.

En primer lugar, se ejecutó el modelo Holt-Winters aditivo mediante la función `HoltWinters()`, probando tres conjuntos distintos de valores iniciales para los parámetros α , β y γ . Tal como se muestra en la tabla incluida en el Anexo 2, los tres ajustes (m1, m2 y m3) convergieron a los mismos valores finales:

$$\alpha = 0.0078, \quad \beta = 1.000, \quad \gamma = 0.4260$$

obteniendo todos un RMSE prácticamente idéntico (≈ 1107.59). Este resultado indica que la optimización es estable, no depende de las condiciones iniciales y no se queda atrapada en óptimos locales, lo que confirma que el modelo Holt-Winters base está bien identificado para nuestra serie.

Posteriormente, se ajustó el mismo modelo utilizando el algoritmo automático del paquete `forecast`, tanto con inicialización libre (m4) como forzada a “optimal” (m5). En ambos casos se obtuvieron los mismos parámetros óptimos:

$$\alpha = 0.0087, \quad \beta = 0.0087, \quad \gamma = 0.0004$$

con un RMSE notablemente menor (944.6527).

Dado que el criterio de selección es emplear el modelo con menor RMSE, el ajuste realizado con la librería `forecast` constituye el modelo Holt-Winters óptimo para nuestra serie. La figura siguiente recoge la predicción obtenida con este modelo:




Gráfico 1. Modelo de Holt Winters con las constantes de suavizado óptimas

A partir de la predicción obtenida, las constantes de suavizado óptimas estimadas por el modelo Holt-Winters multiplicativo ajustado con la librería `forecast` son $\alpha = 0.0067$, $\beta = 0.0067$ y $\gamma = 0.0004$. El valor tan reducido de α indica que el nivel de la serie se actualiza de forma muy lenta, lo cual es coherente con la elevada variabilidad observada. El parámetro β prácticamente nulo refleja que la tendencia permanece estable y apenas requiere actualización. Por último, el valor pequeño de γ muestra que la estacionalidad es relativamente regular y no exige ajustes reactivos en cada periodo.

2.3. Comparativa entre modelos deterministas

Una forma de comparar los distintos modelos deterministas es mediante el RMSE (*Root Mean Square Error*). Este parámetro mide cuánto se separa la predicción que hemos realizado de la serie temporal observada; cuanto menor es su valor, mejor es el ajuste, ya que indica que la predicción reproduce de forma más fiel el comportamiento real de la serie.

Los resultados de este análisis se recogen en la Tabla 1, donde se muestran los valores de RMSE obtenidos para los tres modelos deterministas empleados: suavizado exponencial simple (S.E.S), método de Holt y modelo de Holt-Winters. Es importante señalar que la elección del modelo más adecuado depende siempre del objetivo que se persiga, puesto que no todos los modelos son óptimos para todas las situaciones.

Modelo Determinista	RMSE
S.E.S. ($\alpha=0,6957929$)	1104.245
Holt ($\alpha=0.6976$; $\beta=0.0000$)	1238.304
Holt -Winters ($\alpha=0.0087$; $\beta=0.0087$; $\gamma=0.0004$)	944.6527

Tabla 1. Comparativa RMSE entre modelos deterministas.

En este caso es evidente que el modelo de Holt-Winters estimado mediante forecast es el que presenta el menor valor de RMSE (943.7203), por lo que es el modelo que mejor reproduce el comportamiento histórico de la serie. Este valor confirma que, cuando la serie presenta simultáneamente nivel, tendencia y una estacionalidad marcada, el modelo Holt-Winters resulta más adecuado que los métodos más simples como S.E.S o Holt, que no incorporan todos los componentes necesarios para capturar correctamente la dinámica temporal observada.

Si el objetivo final de este análisis fuera realizar una predicción fiable para los próximos periodos, el modelo Holt-Winters seleccionado sería el más apropiado, ya que integra los tres elementos fundamentales de la serie: nivel, tendencia y estacionalidad.

En consecuencia, para obtener la expresión final del modelo predictivo, basta con sustituir los valores óptimos de los parámetros de suavizado ($\alpha=0.0087$, $\beta=0.0087$ y $\gamma=0.0004$) en las ecuaciones del modelo Holt-Winters aditivo, que quedan del siguiente modo:

$$L_t = 0.0087 (Y_t - S_{t-s}) + (1 - 0.0087)(L_{t-1} + b_{t-1})$$

$$b_t = 0.0087 (L_t - L_{t-1}) + (1 - 0.0087) b_{t-1}$$

$$S_t = 0.0004 (Y_t - L_t) + (1 - 0.0004) S_{t-s}$$

y la predicción m periodos adelante viene dada por:

$$\hat{Y}_{t+m} = L_t + m b_t + S_{t-s+m}$$

Ecuación 4. Modelo de Holt-Winters

3. Modelos ARIMA

3.1. Metodología Box - Jenkins

La serie de datos analizada no es estacionaria, ya que para cumplir esta propiedad sería necesario que presentara media y varianza constantes, además de no mostrar estacionalidad. Por este motivo, y con el fin de aplicar correctamente la metodología Box-Jenkins, se realizan una serie de transformaciones previas que permiten obtener una serie final aproximadamente estacionaria.

3.1.1. Estudio de la varianza y transformación Box-Cox

En primer lugar, se estudia la estabilidad de la varianza. Para ello, se emplea el comando `BoxCox.lambda()`, que permite estimar el parámetro λ de la transformación Box-Cox. Un valor de $\lambda = 1$ indicaría que no es necesaria la transformación, mientras que un valor de $\lambda = 0$ correspondería a una transformación logarítmica. En el caso de la serie de generación eólica mensual con la que estamos trabajando se obtiene el valor:

$$\lambda = -0.167384.$$

Dado que este valor es próximo a cero, resulta adecuado aplicar una transformación logarítmica, que puede escribirse mediante la expresión general de Box-Cox como:

$$Z_t^{(\lambda)} = \frac{Y_t^\lambda - 1}{\lambda},$$

donde Y_t es la serie original de generación eólica y $Z_t^{(\lambda)}$ la serie transformada.




Figura 7. A la izquierda la serie temporal y a la derecha la transformación Box - Cox de la serie temporal

Como se observa en la Figura 7, la serie transformada presenta una amplitud de fluctuaciones más homogénea, lo que sugiere que la varianza queda estabilizada tras la transformación.

3.1.2. Estacionariedad en media y diferenciación regular

A continuación, se analiza la estacionariedad en media de la serie transformada mediante el estudio de los correlogramas ACF y PACF, representados en la Figura 8. En estos gráficos no se aprecia el patrón característico de un decrecimiento lento de las autocorrelaciones asociado a la presencia de una tendencia determinista fuerte.




Figura 8. f.a.s y f.a.p de la serie temporal

Para confirmar este resultado, se emplea la función `ndiffs()`, que indica que no es necesaria la aplicación de una diferenciación regular, obteniéndose:

$$d = 0.$$

Por tanto, tras la transformación Box-Cox, la serie puede considerarse estacionaria en media, sin necesidad de aplicar el operador de diferencia regular.

3.1.3. Estacionalidad y diferenciación estacional

Dado que la serie es de frecuencia mensual, se analiza la posible presencia de estacionalidad no estacionaria mediante el comando `nsdiffs()`. El resultado obtenido indica que es necesaria una diferenciación estacional, con:

$$D = 1, s = 12.$$

En consecuencia, se aplica una diferencia estacional anual a la serie transformada, obteniendo la serie:

$$W_t = \nabla_{12} Z_t^{(\lambda)} = Z_t^{(\lambda)} - Z_{t-12}^{(\lambda)}.$$

La Figura 9 muestra la evolución temporal de la serie diferenciada estacionalmente, mientras que sus correlogramas ACF y PACF evidencian que, tras esta transformación, la serie no presenta estacionalidad residual ni dependencia de largo plazo, pudiendo considerarse estacionaria tanto en media como en estacionalidad.




Figura 9. Serie temporal con media y varianza constantes




Figura 10. f.a.s y f.a.p de la serie transformada y diferenciada

3.1.4. Identificación y selección del modelo ARIMA

Tras alcanzar la estacionariedad de la serie mediante la transformación Box–Cox (denominado W_t a partir de ahora), se procede a la identificación del modelo ARIMA.

En lo que sigue se utilizará la notación habitual $ARIMA(p, d, q)(P, D, Q)_{12}$, donde (p, q, d) representa la parte regular del modelo y (P, Q, D) la componente estacional de periodo $s = 12$.

A partir del análisis de los correlogramas ACF y PACF de la serie estacionaria (Figura 10) y siguiendo el principio de parsimonia, se proponen varios modelos tentativos de la forma:

$$ARIMA(p, 0, q)(P, 1, Q)_{12}.$$

Los distintos modelos considerados, junto con los códigos empleados para su ajuste y los valores del criterio de información de Akaike (AIC) obtenidos, se recogen en el Anexo 4. La comparación mediante AIC permite seleccionar el modelo con mejor equilibrio entre ajuste y complejidad. En este caso, el modelo seleccionado es:

$$W_t \sim ARIMA(0,0,4)(1,1,0)_{12}$$

De esta manera, se ajusta el modelo seleccionado, obteniéndose los siguientes parámetros estimados:

$$\begin{aligned} \theta_1 &= -0.0347, & \theta_2 &= -0.0837, \\ \theta_3 &= -0.0647, & \theta_4 &= 0.6219, \\ \Phi_1 &= -0.6286 \end{aligned}$$

donde los cuatro primeros corresponden a la parte de media móvil regular de orden 4 y el último al término autorregresivo estacional de primer orden. La varianza del error se estima como:

$$\sigma^2 = 0.001191.$$

La log-verosimilitud del modelo es:

$$\log(\text{verosimilitud}) = 90.07,$$

y el criterio de información de AIC toma el valor:

$$AIC = -168.14.$$

siendo este el menor entre los modelos tentativos considerados (véase Anexo 4).

4. Validación del modelo escogido

4.1. Análisis de la significación de los parámetros

Se llevó a cabo el análisis de significación de los parámetros del modelo $ARIMA(0,0,4)(1,1,0)_{12}$ utilizando el software R. Para ello, se empleó la función `coeftest()` del paquete `lmtest`.

Los resultados obtenidos se recogen en la Tabla 2, donde se muestran los errores estándar, los valores del estadístico z y los correspondientes p valores asociados a cada coeficiente del modelo.

	Estimate	Std. Error	z value	Pr(> z)	
ma1	-0.03468	0.141289	-0.2445	0.8061	.
ma2	-0.08367	0.142811	-0.5859	0.5579	.
ma3	0.06468	0.127907	-0.5057	0.6130	.
ma4	0.62192	0.153749	4.0451	5.23e-05	***
sar1	-0.62856	0.135863	-4.6264	3.72e-06	***

Tabla 2. Análisis de significación de los parámetros del modelo $ARIMA(0,0,4)(1,1,0)_{12}$. (Elaboración propia a partir de R)

A la vista de los resultados, se observa que no todos los parámetros del modelo resultan estadísticamente significativos al nivel habitual del 5 %. En particular, los coeficientes correspondientes a los términos de media móvil de orden uno, dos y tres presentan p valores elevados, por lo que no se puede rechazar la hipótesis nula de que dichos parámetros sean nulos.

Sin embargo, el coeficiente **ma4**, asociado al término de media móvil de orden cuatro, y el coeficiente **sar1**, correspondiente al término autorregresivo estacional de primer orden, resultan altamente significativos, con p valores inferiores a 0.001. Esto indica que ambos parámetros desempeñan un papel fundamental en la explicación de la dinámica temporal de la serie.

En consecuencia, el comportamiento de la serie de generación eólica mensual queda principalmente determinado por la dependencia de corto plazo capturada por el término $MA(4)$ y por la dependencia estacional anual modelizada mediante el término AR estacional, lo que resulta coherente con la estructura observada en la serie y con los resultados obtenidos en la etapa de identificación.

4.2. Análisis de los residuos: Ruido blanco

Para que la metodología Box–Jenkins sea válida, es necesario que los residuos del modelo ajustado se comporten como un proceso de ruido blanco, es decir, que presenten media nula, varianza constante, independencia temporal y una distribución aproximadamente normal.

En esta sección se analizan estas propiedades a partir de los residuos obtenidos del modelo

$$ARIMA(0,0,4)(1,1,0)_{12}.$$

4.2.1. Distribución normal de media nula y varianza constante

Con el objetivo de evaluar la distribución de los residuos, se representa su evolución temporal, un histograma y un papel probabilístico normal (Q–Q plot), que se muestran en la Figura 11.




Figura 11. Comprobación de hipótesis de normalidad de los residuos mediante: la representación de los residuos (superior), un histograma (inferior izquierda) y el papel probabilístico normal (inferior derecha)

En el gráfico superior se observa que los residuos oscilan alrededor de cero a lo largo de todo el periodo analizado, sin presentar cambios bruscos ni patrones sistemáticos. Esto sugiere que la media de los residuos es aproximadamente nula y que la varianza se mantiene estable en el tiempo, sin evidencias de heterocedasticidad.

El histograma de los residuos muestra una distribución aproximadamente simétrica y centrada en cero. Aunque no se observa una normalidad perfecta, no se aprecian asimetrías acusadas ni colas excesivamente pesadas que invaliden dicha aproximación.

Por su parte, el gráfico Q-Q indica que la mayor parte de los cuantiles empíricos se alinean razonablemente con la recta teórica de una distribución normal. Las ligeras desviaciones observadas en los extremos son moderadas y no comprometen la hipótesis de normalidad aproximada de los residuos.

En conjunto, estos resultados permiten aceptar que los residuos del modelo siguen una distribución aproximadamente normal, con media nula y varianza constante, cumpliendo así uno de los supuestos fundamentales de la metodología Box-Jenkins.

4.2.2. Estudio de la correlación de los residuos

Una vez analizadas la normalidad, la media nula y la varianza constante de los residuos, el siguiente paso en la validación del modelo consiste en comprobar la ausencia de autocorrelación, requisito fundamental para que los residuos puedan considerarse un proceso de ruido blanco y, por tanto, para que la metodología Box-Jenkins sea válida.

Para ello, se estudian en primer lugar las funciones de autocorrelación simple (ACF) y parcial (PACF) de los residuos del modelo ajustado, que se muestran en la Figura 12.




Figura 12. Correlogramas de los residuos del modelo

A partir de los correlogramas se observa que todos los coeficientes de autocorrelación y autocorrelación parcial, salvo el correspondiente al retardo cero, se encuentran dentro de las bandas de confianza, lo que indica que no existe dependencia temporal significativa entre los residuos. No se aprecian

patrones sistemáticos ni picos aislados que sugieran autocorrelación remanente.

Con el objetivo de confirmar formalmente esta conclusión, se aplica el test de Ljung-Box, que contrasta la hipótesis nula de ausencia de autocorrelación conjunta hasta un determinado número de retardos:

$$H_0: \rho_1 = \rho_2 = \dots = \rho_k = 0$$

H_1 : al menos uno de los coeficientes es distinto de cero

El estadístico de contraste viene dado por:

$$Q^* = N(N+2) \sum_{k=1}^K \frac{r_k^2}{N-k},$$

donde r_k representa el coeficiente de autocorrelación simple de orden k , K es el número de retardos considerados y N es el tamaño muestral.

El test se ha aplicado para distintos valores de K , obteniéndose los siguientes resultados:

- $K = 6$: p valor = 0.8062
- $K = 12$: p valor = 0.9512
- $K = 18$: p valor = 0.8987
- $K = 24$: p valor = 0.9644

En todos los casos, los p valores son claramente superiores al nivel de significación $\alpha = 0.05$. Por tanto, no se rechaza la hipótesis nula de ausencia de autocorrelación, pudiendo afirmarse, con un nivel de confianza del 95 %, que los residuos del modelo no presentan correlación serial.

Este resultado se ve reforzado por el gráfico resumen de los p valores del test de Ljung-Box para distintos retardos, donde se observa que los p -valores se mantienen sistemáticamente por encima del umbral de significación.




Figura 13. Resumen del diagnóstico de incorrelación de los residuos.

En consecuencia, se concluye que los residuos del modelo $ARIMA(0,0,4)(1,1,0)_{12}$ pueden considerarse independientes, cumpliendo así uno de los supuestos fundamentales de la metodología Box–Jenkins.

4.2.3. Conclusión del análisis de residuos

A partir de los resultados obtenidos en los apartados anteriores, puede concluirse que los residuos del modelo definido cumplen adecuadamente los supuestos necesarios para ser considerados un proceso de ruido blanco. Los análisis realizados muestran que los residuos presentan media nula y varianza constante, no exhiben patrones de autocorrelación ni estacionalidad, y cumplen el supuesto de independencia, tal y como confirman los correlogramas y el test de Ljung–Box.

Por tanto, el modelo ajustado resulta adecuado desde el punto de vista estadístico y puede emplearse con garantías para la realización de predicciones.

5. Comparación con modelos alternativos

A partir del análisis previo y manteniendo la misma estructura identificada, se ajusta en primer lugar el modelo ARIMA sobre la serie original de generación eólica mensual, sin aplicar ningún tipo de transformación. Este enfoque presenta una mayor interpretabilidad, ya que trabaja directamente con los valores observados de la serie. El modelo obtenido es:

$$Z_t \sim ARIMA(0,0,4)(1,1,0)_{12}$$

cuya expresión en términos del operador de retardos viene dada por:

$$(1 - \Phi_1 B^{12}) \nabla_{12} Z_t = (1 - \theta_1 B - \theta_2 B^2 - \theta_3 B^3 - \theta_4 B^4) a_t$$

Los parámetros estimados del modelo son:

$$\theta_1 = -0.2024, \theta_2 = -0.0986,$$

$$\theta_3 = -0.3052, \theta_4 = 0.9223, \Phi_1 = -0.6373$$

con una varianza del error estimada, log de verosimilitud y AIC de:

$$\sigma^2 = 1\,046\,145.$$

$$\log(\text{verosimilitud}) = -407.21, \text{ AIC} = 826.42.$$

En segundo lugar, dado que el parámetro de la transformación Box–Cox estimado previamente es cercano a cero, se considera a continuación un modelo ARIMA aplicado a la serie transformada mediante logaritmos:

$$W_t = \log(Z_t)$$

Sobre esta serie se ajusta el modelo:

$$W_t \sim ARIMA(0,0,4)(1,1,0)_{12}$$

El ajuste proporciona una varianza del error estimada, una log-verosimilitud y un AIC de:

$$\sigma^2 = 0.02288:$$

$$\log(\text{verosimilitud}) = 19.12, \text{ AIC} = -26.24$$

Por último, el tercer modelo alternativo que consideraremos será el resultante de utilizar la función `auto.arima( , lambda = "auto")`, que selecciona automáticamente el ajuste tras realizar una transformación Box–Cox a los datos. Donde es Z_t la serie original y definimos la serie transformada mediante Box–Cox como:

$$W_t^{(\lambda)} = \frac{Z_t^\lambda - 1}{\lambda}$$

El modelo obtenido es:

$$Z_t^{(\lambda)} \sim \text{ARIMA}(0,0,4)(1,1,0)_{12}$$

donde el parámetro de la transformación Box–Cox toma el valor:

$$\lambda = -0.167384$$

Los parámetros estimados del modelo son:

$$\theta_1 = -0.0347, \theta_2 = -0.0837$$

$$, \theta_3 = -0.0647, \theta_4 = 0.6219, \Phi_1 = -0.6286$$

La varianza del término de error se estima como:

$$\sigma^2 = 0.001191$$

mientras que la log-verosimilitud y el criterio de información de Akaike toman los valores:

$$\log(\text{verosimilitud}) = 90.07, AIC = -168.14$$

Para realizar la comparación entre modelos, hay que tener en cuenta sus AIC. El modelo que tenga un menor valor de AIC será el que mejor se ajusta a nuestros datos. En la siguiente tabla se encuentran resumidos estos valores:

Serie	Ajuste	AIC
$Z_t^{(\lambda)}$	ARIMA(0,0,4)(1,1,0) ₁₂	−168.14
Z_t	ARIMA(0,0,4)(1,1,0) ₁₂	826.42
$\ln(Z_t)$	ARIMA(0,0,4)(1,1,0) ₁₂	−26.24
$Z_t^{(\lambda)}$	ARIMA(0,0,4)(1,1,0) ₁₂	−168.14

Tabla 3. Comparación de modelos alternativos mediante el AIC.

En la Tabla 3 se observa que el modelo ajustado sobre la serie sin transformación presenta el peor valor del AIC, reflejando un ajuste claramente inferior. El modelo con transformación logarítmica mejora el ajuste, aunque sigue siendo peor que el obtenido mediante la transformación Box–Cox. Finalmente, los modelos ajustados sobre la serie transformada mediante Box–Cox, tanto el identificado mediante la metodología Box–Jenkins como el obtenido con `auto.arima( , lambda = "auto")`, coinciden en estructura, en el valor del parámetro $\lambda = -0.167384$ y en el AIC, siendo estos los de mejor ajuste.

En consecuencia, una vez seleccionado el modelo ARIMA ajustado sobre la serie $Z_t^{(\lambda)}$ como modelo definitivo, se observa que la estructura identificada mediante la metodología Box–Jenkins coincide exactamente con la obtenida a través del procedimiento automático `auto.arima`. Esta coincidencia confirma la adecuación del modelo seleccionado y elimina la necesidad de repetir el análisis de significación de los parámetros y el diagnóstico del ajuste.

La significación estadística de los coeficientes estimados se recoge en la Tabla 2, donde se observa que únicamente los parámetros `ma4` y `sar1` resultan claramente significativos, siendo los principales responsables de capturar la dinámica temporal de la serie, mientras que el resto de términos presentan una contribución menor desde el punto de vista individual.

La validación del modelo se completa con el análisis de los residuos, presentado en el apartado 4.2, el cual confirma que estos se comportan como un proceso de ruido blanco, cumpliéndose las hipótesis básicas de independencia, media nula y varianza constante exigidas por la metodología Box–Jenkins.

Por lo tanto, el modelo ARIMA seleccionado se considera adecuadamente validado y apto para su utilización con fines predictivos.

6. Explotación del modelo escogido

Finalmente, el modelo escogido para realizar las predicciones es el siguiente:

$$W_t = \left(\frac{Z_t^\lambda - 1}{\lambda} \right) \sim ARIMA(0,0,4)(1,1,0)_{12}$$

donde

$$\lambda = -0.167384$$

y donde:

$$\begin{aligned} \theta_1 &= -0.0347, \theta_2 = -0.0837, \\ \theta_3 &= -0.0647, \theta_4 = 0.6219, \Phi_1 = -0.6286 \end{aligned}$$

6.1. Desarrollo de la ecuación explícita de predicción

Desarrollando la forma explícita del modelo $W_t \sim ARIMA(0,0,4)(1,1,0)_{12}$:

$$\begin{aligned} \phi(B) \Phi(B^{12}) \nabla_{12}^1 \nabla^0 W_t &= \theta(B) \theta(B^{12}) a_t + c \\ (1) (1 - \Phi_1 B^{12}) (1 - B^{12}) W_t &= (1 + \theta_1 B + \theta_2 B^2 + \theta_3 B^3 \\ &\quad + \theta_4 B^4) a_t + c \\ [1 - (1 + \Phi_1) B^{12} + \Phi_1 B^{24}] W_t &= [1 + \theta_1 B + \theta_2 B^2 + \theta_3 B^3 \\ &\quad + \theta_4 B^4] a_t + c \\ W_t - (1 + \Phi_1) W_{t-12} + \Phi_1 W_{t-24} &= a_t + \theta_1 a_{t-1} + \theta_2 a_{t-2} + \theta_3 a_{t-3} \\ &\quad + \theta_4 a_{t-4} + c \end{aligned}$$

$$\begin{aligned} W_t &= (1 + \Phi_1) W_{t-12} - \Phi_1 W_{t-24} + a_t + \theta_1 a_{t-1} \\ &\quad + \theta_2 a_{t-2} + \theta_3 a_{t-3} + \theta_4 a_{t-4} + c \end{aligned}$$

Considerando los parámetros obtenidos previamente:

$$\theta_1 = -0.0347, \theta_2 = -0.0837,$$

$$\theta_3 = -0.0647, \theta_4 = 0.6219, \Phi_1 = -0.6286$$

El modelo queda:

$$\begin{aligned} W_t &= 0.3714 W_{t-12} + 0.6286 W_{t-24} + a_t \\ &\quad - 0.0347 a_{t-1} - 0.0837 a_{t-2} \\ &\quad - 0.0647 a_{t-3} + 0.6219 a_{t-4} \end{aligned}$$

$$\text{Donde } W_t = \left(\frac{Z_t^\lambda - 1}{\lambda} \right), \lambda = -0.167384$$

6.2. Uso del modelo escogido para predecir con el ordenador

En primer lugar, las predicciones obtenidas de forma automática con la función `forecast()`, se resumen en la siguiente tabla:

Mes	Z_t
ene. 2025	11057.980
feb. 2025	8076.369
mar. 2025	6850.635
abr. 2025	6372.540
may. 2025	6666.238
jun. 2025	4904.178
jul. 2025	5394.139
ago. 2025	5580.921
sep. 2025	5467.013
oct. 2025	7688.673
nov. 2025	8376.874
dic. 2025	7531.230

Tabla 4. Predicciones obtenidas con `forecast()`

Conviene recordar que, al trabajar con la función `Arima` del paquete `forecast`, la parametrización de los términos de medias móviles se realiza con el signo opuesto al utilizado en los apuntes de la asignatura y en García-Díaz (2016). Por tanto, para que la ecuación explícita del modelo sea coherente con los coeficientes estimados que devuelve `auto.arima` (`ma1`, `ma2`, ...), se ha mantenido la convención empleada por `forecast` al sustituir los parámetros. De este modo, los signos finales de los términos MA quedan determinados por el propio valor estimado de cada θ_i , garantizando la consistencia entre el desarrollo teórico y la implementación en R.

Representando dichas predicciones de forma gráfica se obtiene:




Figura 14. Gráfico plot() de 24 meses predichos.

Como podemos observar en el gráfico, la predicción se ajusta a lo que intuitivamente se puede esperar de la serie. Además, cabe recalcar que se han calculado los siguientes 24 meses (en lugar de 12) para poder analizar de forma más sencilla la eficiencia a la hora de seguir la evolución natural de la serie.

6.3. Comprobación manual de las predicciones obtenidas con el ordenador

Asimismo, con tal de contrastar los resultados obtenidos de forma automática, se ha realizado unas predicciones analíticas a partir de la ecuación explícita del modelo ARIMA. Para ello, es necesario disponer de los datos de los 24 meses anteriores al mes a predecir, además de los residuos estimados de los últimos 4 meses antes de predecir (por la forma que tiene nuestra ecuación explícita). A continuación, se muestran los datos necesarios:

Mes	Z_t	W_t
ene. 2023	10056.448	4.696839
feb. 2023	6936.145	4.614890
mar. 2023	8983.567	4.672487
abr. 2023	6758.325	4.608968
may. 2023	7292.514	4.626242
jun. 2023	4301.550	4.501713
jul. 2023	5218.013	4.548558
ago. 2023	5749.343	4.571512
sep. 2023	4984.122	4.537572
oct. 2023	7718.524	4.638992
nov. 2023	9576.835	4.686348
dic. 2023	7824.055	4.642024
ene. 2024	7589.133	4.635209
feb. 2024	9817.277	4.691682
mar. 2024	8052.160	4.648417

abr. 2024	6401.754	4.596524
may. 2024	5743.746	4.571283
jun. 2024	6164.062	4.587771
jul. 2024	5708.256	4.569827
ago. 2024	5308.847	4.552670
sep. 2024	6414.499	4.596983
oct. 2024	7638.463	4.636660
nov. 2024	6723.074	4.607772
dic. 2024	7064.325	4.619050

Tabla 5. Valores de la serie y su transformación Box-Cox, para los últimos 24 meses de la serie.

Mes	a_t
sep. 2024	0.0568959
oct. 2024	-0.0015677
nov. 2024	-0.0842643
dic. 2024	-0.0142730

Tabla 6. Valor de los residuos estimados de los últimos 4 meses de la serie.

Tomando estos datos en consideración, se ha implementado en R un procedimiento que reproduce el cálculo analítico establecido en la metodología Box-Jenkins, utilizando los valores observados de la serie correspondientes a los 24 meses anteriores, requeridos por la presencia de retardos estacionales en la ecuación del modelo, así como los residuos estimados de los cuatro últimos meses, asociados a la parte de media móvil. A partir de estos datos, las predicciones se han obtenido de forma secuencial, calculando cada periodo de predicción mediante la sustitución directa de los valores disponibles en la ecuación explícita del modelo y considerando nulos los errores futuros.

De esta forma se obtienen los siguientes resultados:

Mes	$\widehat{W}_t$	$\widehat{Z}_t$
ene. 2025	4.716983	11058.189
feb. 2025	4.649082	8076.333
mar. 2025	4.612067	6850.718
abr. 2025	4.595470	6372.562
may. 2025	4.605831	6666.294
jun. 2025	4.533675	4904.117
jul. 2025	4.556457	5394.122
ago. 2025	4.564514	5580.937
sep. 2025	4.559637	5466.965
oct. 2025	4.638126	7688.676
nov. 2025	4.657165	8376.979
dic. 2025	4.633491	7531.257

Tabla 7. Predicciones obtenidas de forma manual.

Por último, las predicciones obtenidas en la serie transformada se han reexpresado en la escala original de la variable mediante la aplicación de la inversa de la transformación Box–Cox. Este paso se ha implementado directamente en R utilizando la función correspondiente, lo que permite obtener las predicciones en términos de la serie original Z_t .

De este modo, las predicciones analíticas pueden compararse de forma directa con las proporcionadas por la función `forecast`, que devuelve automáticamente los resultados en la escala original de la serie, facilitando así la comparación entre ambos procedimientos.

$\widehat{Z}_t$	
Forecast	A mano
11057.980	11058.189
8076.369	8076.333
6850.635	6850.718
6372.540	6372.562
6666.238	6666.294
4904.178	4904.117
5394.139	5394.122
5580.921	5580.937
5467.013	5466.965
7688.673	7688.676
8376.874	8376.979
7531.230	7531.257

Tabla 8. Comparativas de las predicciones propias y las obtenidas con `forecast()`.

Como se observa en la tabla, las predicciones obtenidas mediante la aplicación analítica de la ecuación explícita del modelo y las proporcionadas por la función `forecast()` son prácticamente idénticas en todos los periodos considerados. Esta elevada coincidencia confirma que el procedimiento de predicción analítica ha sido implementado correctamente y que reproduce fielmente el mecanismo interno del modelo ARIMA ajustado. Las ligeras diferencias observadas en algunos valores pueden atribuirse a diferencias en la forma en que ambos procedimientos gestionan internamente el cálculo de las predicciones, sin que ello afecte de manera apreciable a los resultados finales.

7. Conclusión

Tras realizar el análisis y la predicción en profundidad para la serie de generación eólica mensual en España, se concluye que el modelo que mejor describe y predice su comportamiento es el siguiente:

$$W_t = \left(\frac{Y_t^\lambda - 1}{\lambda} \right) \sim \text{ARIMA}(0,0,4)(1,1,0)_{12}$$

con $\lambda = -0.1673844$ y parámetros estimados:

$$\theta_1 = -0.0347, \theta_2 = -0.0837,$$

$$\theta_3 = -0.0647, \theta_4 = 0.6219, \Phi_1 = -0.6286.$$

La elección de este modelo se ha basado en que es el que presenta el menor valor de AIC entre todas las especificaciones consideradas, ofreciendo el mejor compromiso entre ajuste y parsimonia. Las predicciones obtenidas mediante la ecuación explícita del modelo coinciden prácticamente con las generadas por la función `forecast()` de R y, en ambos casos, reproducen de forma coherente la estacionalidad anual y los niveles medios que intuitivamente se esperan para la generación eólica mensual en los próximos meses.

Referencias

- [1] Red Eléctrica de España (REE), "ESIOS: Sistema de Información del Operador del Sistema," 2024. [En línea]. Disponible en: <https://www.esios.ree.es>
- [2] E. García Bustamante, J. F. González Rouco, J. Navarro, E. Xoplaki, P. Jimenez, y J. Montávez, "North Atlantic atmospheric circulation and surface wind in the Northeast of the Iberian Peninsula: Uncertainty and long term downscaled variability," *Clim. Dyn.*, vol. 38, pp. 141-160, 2011, doi: 10.1007/s00382-010-0969-x.
- [3] International Energy Agency (IEA), *Renewables 2023*, Paris: IEA, 2024.
- [4] A. Carrión García, *Análisis de series temporales y técnicas de previsión*. Valencia, España: Servicio de publicaciones Universitat Politècnica de València, 1997.
- [5] J. C. García Díaz, *Predicción en el dominio del tiempo: Análisis de series temporales para ingenieros*. Valencia, España: Editorial de la Universidad Politècnica de Valencia, 2016.

Anexos

Anexo 1: Datos de la serie


Año	Jan	Feb	Mar	Apr
2020	6133.30	6091.70	7472.27	5098.55
2021	9653.20	9436.26	7605.89	5720.58
2022	7197.13	6894.88	8623.10	7672.24
2023	10056.45	6936.15	8983.57	6758.33
2024	7589.13	9817.28	8052.16	6401.75

Año	May	Jun	Jul	Aug
2020	5273.81	4664.14	5579.41	4872.76
2021	6451.97	5119.37	5730.58	4994.64
2022	6105.63	5070.20	5849.44	5645.28
2023	7292.51	4301.55	5218.01	5749.34
2024	5743.75	6164.06	5708.26	5308.85


Año	Sep	Oct	Nov	Dec
2020	5529.06	7611.85	5871.11	9839.43
2021	4404.14	5771.10	8749.78	9198.67
2022	5834.29	6865.26	9331.47	7445.43
2023	4984.12	7718.52	9576.84	7824.06
2024	6414.50	7638.46	6723.07	7064.33

Anexo 2: Diferentes semillas para la determinación del modelo Holt -Winters.


Holt-Winters aditivo



Holt-Winters m2: alfa = 0.3, beta = 0.1, gamma = 0.1




Holt-Winters m3: alfa = 0.8, beta = 0.5, gamma = 0.5



Modelo	α	β	γ	RMSE
m1 (HW estándar)	0.0078	1.0000	0.4260	1107.59
m2 (semillas 0.3, 0.1, 0.1)	0.0078	1.0000	0.4260	1107.59
m3 (semillas 0.8, 0.5, 0.5)	0.0078	1.0000	0.4260	1107.582
m4 (forecast, automático)	0.0087	0.0087	0.0004	944.6527
m5 (forecast, inicial="optimal")	0.0087	0.0087	0.0004	944.6527

Anexo 3: Metodología Box Jenkins



Anexo 4. Identificación y comparación de modelos ARIMA

En este anexo se recogen los modelos ARIMA tentativos propuestos durante la etapa de identificación, así como los valores del criterio de información de Akaike (AIC) utilizados para su comparación.

```

# Modelos tentativos (d = 0, D = 1, s = 12)

fit_1 = arima(ts_eolica_bc, order = c(0,0,1), seasonal = c(0,1,1))

fit_2 = arima(ts_eolica_bc, order = c(1,0,0), seasonal = c(0,1,1))

fit_3 = arima(ts_eolica_bc, order = c(1,0,1), seasonal = c(0,1,1))

fit_4 = arima(ts_eolica_bc, order = c(0,0,1), seasonal = c(1,1,0))

fit_5 = arima(ts_eolica_bc, order = c(1,0,0), seasonal = c(1,1,0))

fit_6 = arima(ts_eolica_bc, order = c(1,0,1), seasonal = c(1,1,1))

# MA regular creciente con SMA(1)

fit_7 = arima(ts_eolica_bc, order = c(0,0,2), seasonal = c(0,1,1))

fit_8 = arima(ts_eolica_bc, order = c(0,0,3), seasonal = c(0,1,1))

fit_9 = arima(ts_eolica_bc, order = c(0,0,4), seasonal = c(0,1,1))

# Combinaciones ARMA moderadas

fit_10 = arima(ts_eolica_bc, order = c(1,0,1), seasonal = c(0,1,1))

fit_11 = arima(ts_eolica_bc, order = c(1,0,2), seasonal = c(0,1,1))

# AR estacional

fit_12 = arima(ts_eolica_bc, order = c(0,0,2), seasonal = c(1,1,0))

fit_13 = arima(ts_eolica_bc, order = c(0,0,3), seasonal = c(1,1,0))

fit_14 = arima(ts_eolica_bc, order = c(0,0,4), seasonal = c(1,1,0))

```

AIC(fit_1, fit_2, fit_3, fit_4, fit_5, fit_6, fit_7, fit_8, fit_9, fit_10, fit_11, fit_12, fit_13, fit_14)

A partir de esos modelos tentativos se obtiene lo siguiente.

Modelo	ARIMA	AIC
fit_1	(0,0,1)(0,1,1) ₁₂	-164.7567
fit_2	(1,0,0)(0,1,1) ₁₂	-164.7229
fit_3	(1,0,1)(0,1,1) ₁₂	-164.3569
fit_4	(0,0,1)(1,1,0) ₁₂	-163.2388
fit_5	(1,0,0)(1,1,0) ₁₂	-163.2351
fit_6	(1,0,1)(1,1,1) ₁₂	-163.3091
fit_7	(0,0,2)(0,1,1) ₁₂	-162.7739
fit_8	(0,0,3)(0,1,1) ₁₂	-160.7744
fit_9	(0,0,4)(0,1,1) ₁₂	-166.5618
fit_10	(1,0,1)(0,1,1) ₁₂	-164.3569
fit_11	(1,0,2)(0,1,1) ₁₂	-162.3658
fit_12	(0,0,2)(1,1,0) ₁₂	-161.3836
fit_13	(0,0,3)(1,1,0) ₁₂	-159.4370
fit_14	(0,0,4)(1,1,0)₁₂	-168.1444

El modelo ARIMA(0,0,4)(1,1,0)₁₂ presenta el menor valor de AIC y, por tanto, es el seleccionado como modelo final.

Anexo 5. Predicciones manuales

1) Ene. 2025

$$\begin{aligned}
\hat{W}_{\text{ene-25}} &= 0.3714 W_{\text{ene-24}} + 0.6286 W_{\text{ene-23}} \\
&\quad - 0.0347 a_{\text{dic-24}} - 0.0837 a_{\text{nov-24}} \\
&\quad - 0.0647 a_{\text{oct-24}} + 0.6219 a_{\text{sep-24}} \\
&= 0.3714(4.635209) + 0.6286(4.696839) \\
&\quad - 0.0347(-0.0142730) \\
&\quad - 0.0837(-0.0842643) \\
&\quad - 0.0647(-0.0015677) \\
&\quad + 0.6219(0.0568959) \\
&= 4.716983
\end{aligned}$$

2) Feb. 2025

$$\begin{aligned}
\hat{W}_{\text{feb-25}} &= 0.3714 W_{\text{feb-24}} + 0.6286 W_{\text{feb-23}} \\
&\quad - 0.0837 a_{\text{dic-24}} - 0.0647 a_{\text{nov-24}} \\
&\quad + 0.6219 a_{\text{oct-24}} \\
&= 0.3714(4.691682) + 0.6286(4.614890) \\
&\quad - 0.0837(-0.0142730) \\
&\quad - 0.0647(-0.0842643) \\
&\quad + 0.6219(-0.0015677) \\
&= 4.649082
\end{aligned}$$

3) Mar. 2025

$$\begin{aligned}
\hat{W}_{\text{mar-25}} &= 0.3714 W_{\text{mar-24}} + 0.6286 W_{\text{mar-23}} \\
&\quad + a_{\text{dic-24}} + 0.6219 a_{\text{nov-24}} \\
&= 0.3714(4.648417) + 0.6286(4.672487) \\
&\quad - 0.0647(-0.0142730) \\
&\quad + 0.6219(-0.0842643) \\
&= 4.612067
\end{aligned}$$

4) Abr. 2025

$$\begin{aligned}
\hat{W}_{\text{abr-25}} &= 0.3714 W_{\text{abr-24}} + 0.6286 W_{\text{abr-23}} \\
&\quad + 0.6219 a_{\text{dic-24}} \\
&= 0.3714(4.596524) + 0.6286(4.608968) \\
&\quad + 0.6219(-0.0142730) \\
&= 4.595470
\end{aligned}$$

12) Dic. 2025

$$\begin{aligned}\hat{W}_{\text{dic-25}} &= 0.3714 W_{\text{dic-24}} + 0.6286 W_{\text{dic-23}} \\ &= 0.3714(4.619050) \\ &\quad + 0.6286(4.642024) = 4.633491\end{aligned}$$

5) May. 2025

$$\begin{aligned}\hat{W}_{\text{may-25}} &= 0.3714 W_{\text{may-24}} + 0.6286 W_{\text{may-23}} \\ &= 0.3714(4.571283) + 0.6286(4.626242) \\ &= 4.605831\end{aligned}$$

6) Jun. 2025

$$\begin{aligned}\hat{W}_{\text{jun-25}} &= 0.3714 W_{\text{jun-24}} + 0.6286 W_{\text{jun-23}} \\ &= 0.3714(4.587771) \\ &\quad + 0.6286(4.501713) = 4.533675\end{aligned}$$

7) Jul. 2025

$$\begin{aligned}\hat{W}_{\text{jul-25}} &= 0.3714 W_{\text{jul-24}} + 0.6286 W_{\text{jul-23}} \\ &= 0.3714(4.569827) \\ &\quad + 0.6286(4.548558) = 4.556457\end{aligned}$$

8) Ago. 2025

$$\begin{aligned}\hat{W}_{\text{ago-25}} &= 0.3714 W_{\text{ago-24}} + 0.6286 W_{\text{ago-23}} \\ &= 0.3714(4.552670) \\ &\quad + 0.6286(4.571512) = 4.564514\end{aligned}$$

9) Sep. 2025

$$\begin{aligned}\hat{W}_{\text{sep-25}} &= 0.3714 W_{\text{sep-24}} + 0.6286 W_{\text{sep-23}} \\ &= 0.3714(4.596983) \\ &\quad + 0.6286(4.537572) = 4.559637\end{aligned}$$

10) Oct. 2025

$$\begin{aligned}\hat{W}_{\text{oct-25}} &= 0.3714 W_{\text{oct-24}} + 0.6286 W_{\text{oct-23}} \\ &= 0.3714(4.636660) \\ &\quad + 0.6286(4.638992) = 4.638126\end{aligned}$$

11) Nov. 2025

$$\begin{aligned}\hat{W}_{\text{nov-25}} &= 0.3714 W_{\text{nov-24}} + 0.6286 W_{\text{nov-23}} \\ &= 0.3714(4.607772) \\ &\quad + 0.6286(4.686348) = 4.657165\end{aligned}$$